

UNIVERSIDADE ESTADUAL PAULISTA

“Júlio de Mesquita Filho”

Pós-Graduação em Ciência da Computação

Alexandre Aparecido Bernardes

**Identificação de Doenças em Folhas Vegetais da Cultura
do Algodão**

UNESP

2011

Alexandre Aparecido Bernardes

**Identificação de Doenças em Folhas Vegetais da Cultura
do Algodão**

Orientador: Prof. Dr. Aledir Silveira Pereira

Dissertação elaborada junto ao Programa de Pós-Graduação em Ciência da Computação – Área de Concentração em Sistemas de Computação/Processamento de Imagens e Visão Computacional, como parte dos requisitos para a obtenção do título de Mestre em Ciência da Computação.

UNESP

2011

Alexandre Aparecido Bernardes

Identificação de Doenças em Folhas Vegetais da Cultura do Algodão

Dissertação apresentada para obtenção do título de Mestre em Ciência da Computação, área de Sistemas de Computação / Processamento de Imagens e Visão Computacional junto ao Programa de Pós-Graduação em Ciência da Computação do Instituto de Biociências, Letras e Ciências Exatas da Universidade Estadual Paulista “Júlio de Mesquita Filho”, Campus de São José do Rio Preto.

BANCA EXAMINADORA

Prof. Dr. Aledir Silveira Pereira
UNESP – São José do Rio Preto
Orientador

Prof. Dr. Adilson Gonzaga
USP – São Carlos

Prof. Dr. Rodrigo Capobianco Guido
UNESP – São José do Rio Preto

São José do Rio Preto, 10 de fevereiro de 2011.

AGRADECIMENTOS

A DEUS por me dar saúde, paz, tranquilidade e também me iluminar e estar presente em todos os momentos de minha vida.

A minha esposa e companheira Elaine Borges Bernardes pelo amor, apoio, incentivo a luta pelos meus ideais e compreensão que me dedicou em todos os momentos dos meus estudos. E aos meus filhos Bruno e Lucas, por fazerem tudo isto valer a pena.

Ao meu orientador Prof. Dr. Aledir Silveira Pereira pela paciência, generosidade em ensinar, além de sua dedicação e confiança depositados em mim. Obrigado!

Ao Prof. Dr. Rodrigo Capobianco Guido, por ter cedido o ambiente MVS, pelos materiais e pela completa disponibilidade para me elucidar em todas as questões suscitadas.

Ao pesquisador em Fitopatologia da EMBRAPA de Campina Grande, Dr. Nelson Dias Suassuna, por ter sempre a boa disposição em elucidar minhas dúvidas na área agrícola e por ter enviado as imagens utilizadas neste trabalho.

A minha mãe Maria Rodrigues Bernardes, ao meu pai João Bernardes, as minhas irmãs Alessandra e Sandra, a minha sogra Ivone, aos meus sobrinhos e família, que acompanharam-me, especialmente com suas orações, carinho e palavras de incentivo.

A meus amigos que conquistei durante esse período e que certamente contribuíram para este trabalho, seja através de sugestões, de apoio, incentivo e, até mesmo, através de momentos de descontração, sempre necessários ao ser humano. Em especial, Adriana, Alex, Camila, Danilo, Jonathan, Roberta, Rodolfo e Tiago.

Aos membros da banca examinadora pelo prestígio, participação, dando seus pareceres e sugestões.

Ao agrônomo da casa da Agricultura de Jales, Dr. Gilberto José B. Pelinson por sempre disponibilizar a atenção e pelo aprendizado na área de Fitopatologia.

A todos meus professores, que desde a minha infância dividiram comigo a única coisa que nos acompanha por toda vida, “o conhecimento”.

Finalmente a todos aqueles que de alguma maneira me ajudaram na concretização deste trabalho.

SUMÁRIO

LISTA DE FIGURAS	vi
LISTA DE TABELAS	ix
RESUMO	xi
ABSTRACT	xii
LISTA DE ABREVIATURAS	xiii
CAPÍTULO 1 - INTRODUÇÃO	1
Organização da Dissertação.....	3
CAPÍTULO 2 - FUNDAMENTAÇÃO TEÓRICA.....	4
2.1 Trabalhos Correlatos	4
2.2 Características dos Tipos de Doenças do Algodão.....	8
2.3. Processamento de Imagens	10
2.3.1 Transformação de Cores	11
Modelo de Cor RGB	11
Transformação de RGB para Níveis de Cinza	12
Transformação de RGB para HSV.....	13
Transformação de RGB para I1I2I3	15
2.4 Extração de Características	16
2.4.1 Descritores Regionais	16
Descritores Simples de Região	17
2.5 Reconhecimento e Interpretação de Padrões	19
2.5.1 Métodos de Decisão Teórica	20
Classificador de Distância Mínima	21
2.6 Classificadores Inteligentes	22
2.7 Transformada <i>Wavelet</i>	25
2.7.1 Transformada <i>Wavelet</i> Discreta (TWD)	28
2.7.2 <i>Wavelets</i> e Processamento de Imagens	32
2.7.3 Famílias de Transformadas <i>Wavelets</i>	34
2.8 Considerações Finais	36
CAPÍTULO 3 – MATERIAL E MÉTODOS	37
3.1 Banco de Imagens	37
3.2 Decomposição das Imagens	39

3.3 Vetor de Características	39
3.4 Ambiente MVS	42
3.5 Uso da MVS para Classificação de Imagens	43
3.5.1 Descrição da Etapa de Classificação entre as Classes SA e LE	44
3.5.2 Descrição da Etapa de Classificação entre as Classes RA, MA e AS	44
3.6 Escolha da MVS de Melhor Desempenho	45
3.7 Processo de Treinamento e de Teste Usando a MVS	46
3.7.1: Estrutura Geral de Classificação	47
3.7.2: Composição dos Vetores de Características para Realizar os Testes	50
3.7.3: Descrição dos Vetores que Armazenaram os Resultados	52
3.7.4: Forma de Obtenção da Tabela de Resultados a Partir do Conjunto de Vetores de Características	53
3.8 Considerações Finais	54
CAPÍTULO 4 – RESULTADOS DOS TESTES COM A MVS	55
4.1 Resultados da Classificação MVS.....	55
4.1.1 Exibição dos Resultados da Etapa de Classificação entre as Classes SA e LE	56
4.1.2 Exibição dos Resultados Obtidos da Etapa de Classificação entre as Classes RA, MA e AS	62
4.2 Resultados do Sistema Final de Classificação	71
4.3 Análise dos Resultados	76
4.4 Resultados Obtidos por Outros Autores em Trabalhos Correlatos.....	78
CAPÍTULO 5 – CONCLUSÕES	80
Trabalhos Futuros	82
REFERÊNCIAS BIBLIOGRÁFICAS	83

LISTA DE FIGURAS

Figura 2.1:	Doenças do Algodão. Em (a) doença Ramulária, (b) Mancha Angular e Mancha de <i>Ascochyta</i>	10
Figura 2.2:	(a) Representação do modelo de cor RGB, (b) cubo de cores RGB.....	12
Figura 2.3:	Decomposição da imagem no padrão RGB (a) em seus respectivos canais de cores: Vermelho (b), Verde (c) e Azul (d).....	12
Figura 2.4:	Imagem convertida em tons de cinza (a) Imagem original (b) Imagem convertida em tons de cinza	13
Figura 2.5:	Representação do espaço de cor HSV. Em (a), hexágono de cores HSV e, (b), o sólido de cores do Sistema HSV	14
Figura 2.6:	Regiões com números de <i>Euler</i> = -1	17
Figura 2.7:	Exemplo de Projeção. Em (a), região original e suas projeções vertical em (b) e horizontal em (c).....	18
Figura 2.8:	Classificação pela distância mínima	22
Figura 2.9:	Separação linear das classes W1 e W2 com base num hiperplano	24
Figura 2.10:	Arquitetura da MVS.....	25
Figura 2.11	Exemplo do fator de escala atuando em uma função <i>wavelet</i>	27
Figura 2.12:	Translação de uma função <i>wavelet</i> . Em (a), Função <i>wavelet</i> $\Psi(t)$ e, em (b), função <i>wavelet</i> transladada.....	27
Figura 2.13:	Exemplos de <i>wavelets</i> ortogonais discretas. Em (a), são exibidas três <i>wavelets</i> de <i>Haar</i> , em três escalas consecutivas em uma grade diádica. Em (b), a <i>wavelet</i> de <i>Meyer</i> e associados a função de escalonamento (à direita). Em (c), <i>wavelet</i> de <i>Daubechies</i> D4, em (d) <i>wavelet</i> de <i>Daubechies</i> D20 e, em (e), <i>wavelet</i> <i>Coiflets</i> C18 (função de escalonamento demonstrado em pontilhado)	30
Figura 2.14:	Decomposição <i>Wavelet</i> Discreta de Multirresolução	31
Figura 2.15:	Árvore de decomposição da <i>wavelet</i> de um sinal.....	31
Figura 2.16:	Esquema de decomposição da <i>wavelet</i>	32
Figura 2.17:	Esquema de decomposição da <i>wavelet</i> até o terceiro nível.....	33
Figura 2.18:	Exemplo de decomposição de uma imagem. Em (a), Imagem Original e, em (b), imagem resultante, após aplicada a TWD no primeiro nível.	33
Figura 2.19:	Formato das respostas ao impulso dos filtros de <i>Haar</i> , <i>Daubechies</i> , <i>Vaidynathan</i> , <i>Beylkin</i> , <i>Coiflets</i> e <i>Symmlets</i>	35

Figura 2.20: Formato das funções de escala dos filtros de <i>Haar</i> , <i>Daubechies</i> , <i>Vaidynathan</i> , <i>Beylkin</i> , <i>Coiflets</i> e <i>Symmlets</i>	35
Figura 2.21: Formato das funções <i>wavelet</i> dos filtros de <i>Haar</i> , <i>Daubechies</i> , <i>Vaidynathan</i> , <i>Beylkin</i> , <i>Coiflets</i> e <i>Symmlets</i>	36
Figura 3.1: Algumas imagens da região foliar sadia do algodoeiro	38
Figura 3.2: Grau de severidade da doença de MA do algodoeiro. Em (a), exibe região com estágio inicial da doença; em (b) grau médio de infecção e, em (c), estágio avançado da doença.....	39
Figura 3.3: Decomposição da imagem em vários canais	39
Figura 3.4: Esquema de decomposição da <i>wavelet</i>	40
Figura 3.5: Exemplo de vetor de características utilizado neste trabalho	40
Figura 3.6: Vetores de características criados somente para o canal de cor R.....	41
Figura 3.7: Arquitetura da MVS utilizada neste trabalho	42
Figura 3.8: Exemplo do sistema de classificação MVS entre duas classes	43
Figura 3.9: Estrutura simplificada do sistema geral de classificação	46
Figura 3.10: Estrutura geral de classificação	47
Figura 3.11: Representação de um conjunto de vetores de características utilizado na fase de testes	51
Figura 4.1: Gráfico referente à porcentagem de acertos do canal R obtido em cada <i>wavelet</i> utilizada neste trabalho	56
Figura 4.2: Gráfico referente à porcentagem de acertos do canal G obtido em cada <i>wavelet</i> utilizada neste trabalho	57
Figura 4.3: Gráfico referente à porcentagem de acertos do canal B obtido em cada <i>wavelet</i> utilizada neste trabalho	58
Figura 4.4: Gráfico referente à porcentagem de acertos do canal H obtido em cada <i>wavelet</i> utilizada neste trabalho	58
Figura 4.5: Gráfico referente à porcentagem de acertos do canal S obtido em cada <i>wavelet</i> utilizada neste trabalho	59
Figura 4.6: Gráfico referente à porcentagem de acertos do canal V obtido em cada <i>wavelet</i> utilizada neste trabalho	60
Figura 4.7: Gráfico referente à porcentagem de acertos do canal I3a obtido em cada <i>wavelet</i> utilizada neste trabalho	60
Figura 4.8: Gráfico referente à porcentagem de acertos do canal I3b obtido em cada <i>wavelet</i> utilizada neste trabalho	61
Figura 4.9: Gráfico referente à porcentagem de acertos dos Níveis de Cinza obtida em cada <i>wavelet</i> utilizada neste trabalho	62
Figura 4.10: Gráfico referente à porcentagem de acertos do canal R obtido em cada <i>wavelet</i> utilizado neste trabalho.....	63
Figura 4.11: Gráfico referente à porcentagem de acertos do canal G obtido em cada <i>wavelet</i> utilizado neste trabalho	64

Figura 4.12: Gráfico referente à porcentagem de acertos do canal B obtido em cada <i>wavelet</i> utilizado neste trabalho	65
Figura 4.13: Gráfico referente à porcentagem de acertos do canal H obtido em cada <i>wavelet</i> utilizado neste trabalho	66
Figura 4.14: Gráfico referente à porcentagem de acertos do canal S obtido em cada <i>wavelet</i> utilizado neste trabalho	67
Figura 4.15: Gráfico referente à porcentagem de acertos do canal V obtido em cada <i>wavelet</i> utilizado neste trabalho	68
Figura 4.16: Gráfico referente à porcentagem de acertos do canal I3a obtido em cada <i>wavelet</i> utilizado neste trabalho	69
Figura 4.17: Gráfico referente à porcentagem de acertos do canal I3b obtido em cada <i>wavelet</i> utilizado neste trabalho	70
Figura 4.18: Gráfico referente à porcentagem de acertos nos Níveis de Cinza obtido em cada <i>wavelet</i> utilizado neste trabalho	71

LISTA DE TABELAS

Tabela 2.1:	Características das famílias de <i>wavelets</i> utilizadas neste trabalho	34
Tabela 3.1:	Tabela de coeficiente e número de suportes utilizados neste trabalho	41
Tabela 3.2:	Relação de imagens que são utilizadas para o treinamento e teste no sistema de classificação MVS entre as classes SA e LE.....	44
Tabela 3.3:	Relação de imagens que são utilizadas para o treinamento e teste no sistema de classificação MVS entre as classes RA, MA e AS	45
Tabela 3.4:	Melhores resultados obtidos entre as classes.....	46
Tabela 3.5:	Relação dos canais utilizados para constituir o conjunto de vetores de características e das imagens que são utilizadas para o treinamento e teste no Sistema 1.....	48
Tabela 3.6:	Relação dos canais utilizados para constituir o conjunto de vetores de características e das imagens que são utilizadas para o treinamento e teste no Sistema 2.....	49
Tabela 3.7:	Relação dos canais utilizados para constituir o conjunto de vetores de características e das imagens que são utilizadas para o treinamento e teste no Sistema 3.....	49
Tabela 3.8:	Relação dos canais utilizados para constituir o conjunto de vetores de características e das imagens que são utilizadas para o treinamento e teste no Sistema 4.....	50
Tabela 3.9:	Descrição dos vetores de características	52
Tabela 3.10:	Descrição dos vetores de respostas	53
Tabela 4.1:	Relação de acertos do canal R de cada <i>wavelet</i> utilizada neste trabalho	56
Tabela 4.2:	Relação de acertos do canal G de cada <i>wavelet</i> utilizada neste trabalho	57
Tabela 4.3:	Relação de acertos do canal B de cada <i>wavelet</i> utilizada neste trabalho	57
Tabela 4.4:	Relação de acertos do canal H de cada <i>wavelet</i> utilizada neste trabalho	58
Tabela 4.5:	Relação de acertos do canal S de cada <i>wavelet</i> utilizada neste trabalho.....	59
Tabela 4.6:	Relação de acertos do canal V de cada <i>wavelet</i> utilizada neste trabalho	59
Tabela 4.7:	Relação de acertos do canal I3a de cada <i>wavelet</i> utilizada neste trabalho	60
Tabela 4.8:	Relação de acertos do canal I3b de cada <i>wavelet</i> utilizada neste trabalho.....	61
Tabela 4.9:	Relação de acertos dos Níveis de Cinza de cada <i>wavelet</i> utilizada neste trabalho.....	62
Tabela 4.10:	Relação de acertos do canal R de cada <i>wavelet</i> utilizada neste trabalho	63

Tabela 4.11: Relação de acertos do canal G de cada <i>wavelet</i> utilizada neste trabalho	63
Tabela 4.12: Relação de acertos do canal B de cada <i>wavelet</i> utilizada neste trabalho	64
Tabela 4.13: Relação de acertos do canal H de cada <i>wavelet</i> utilizada neste trabalho	65
Tabela 4.14: Relação de acertos do canal S de cada <i>wavelet</i> utilizada neste trabalho	66
Tabela 4.15: Relação de acertos do canal V de cada <i>wavelet</i> utilizada neste trabalho	67
Tabela 4.16: Relação de acertos do canal I3a de cada <i>wavelet</i> utilizada neste trabalho	68
Tabela 4.17: Relação de acertos do canal I3b de cada <i>wavelet</i> utilizada neste trabalho	69
Tabela 4.18: Relação de acertos nos Níveis de Cinza de cada <i>wavelet</i> utilizada neste trabalho	70
Tabela 4.19: Resultado dos testes obtidos dos conjuntos de vetores de características. Parte 1 de 5	72
Tabela 4.19: Resultado dos testes obtidos dos conjuntos de vetores de características. Parte 2 de 5	73
Tabela 4.19: Resultado dos testes obtidos dos conjuntos de vetores de características. Parte 3 de 5	74
Tabela 4.19: Resultado dos testes obtidos dos conjuntos de vetores de características. Parte 4 de 5	75
Tabela 4.19: Resultado dos testes obtidos dos conjuntos de vetores de características. Parte 5 de 5	76
Tabela 4.20: Resultados dos testes, em que 105 imagens “Sadias” foram classificadas como:	77
Tabela 4.21: Resultados dos testes, em que 35 imagens “Mancha Angular” foram classificadas como:	77
Tabela 4.22: Resultados dos testes, em que 35 imagens “Ramulária” foram classificadas como:	77
Tabela 4.23: Resultados dos testes, em que 35 imagens “Mancha de <i>Ascochyta</i> ” foram classificadas como	78

LISTA DE ABREVIATURAS

AS	<i>Mancha de Ascochyta</i>
Bey	<i>Beylkin</i>
Coi	<i>Coiflets</i>
Dau	<i>Daubechies</i>
HSV	<i>Hue (Matiz) Saturation (Saturação) Value (Valor)</i>
LE	<i>Lesionada</i>
MA	<i>Mancha Angular</i>
MVS	<i>Máquina de Vetor de Suporte</i>
QMF	<i>Quadrature Mirros Filter</i>
RA	<i>Ramulária</i>
RGB	<i>Red (Vermelho) Green (Verde) Blue (Azul)</i>
RNA	<i>Redes Neurais Artificiais</i>
SA	<i>Sadia</i>
SEDI	<i>Sistemas Eletrônicos Digitais e Imagens</i>
SVM	<i>Support Vector Machine</i>
Sym	<i>Symmlets</i>
TF	<i>Transformada de Fourier</i>
TW	<i>Transformada Wavelet</i>
TWD	<i>Transforma Wavelet Discreta</i>
Vai	<i>Vaidynathan</i>

RESUMO

A manifestação de patógenos nas plantações é a maior causadora de prejuízos nos mais diversos cultivares, podendo ocasionar o aumento dos preços e a perda da qualidade dos produtos cultivados. O quanto antes for identificada a doença, mais cedo é realizado o seu controle através de agrotóxicos, tendendo, dessa forma, a diminuir a sua proliferação e, conseqüentemente, evitando maiores danos. No entanto, muitas vezes, a inspeção visual dos sintomas apresentados pela ocorrência de patógenos em uma folha de planta, não é considerada o suficiente para avaliar e identificar o tipo de doença que está causando a lesão, sendo necessário, para o diagnóstico da doença, uma análise mais detalhada por um agrônomo ou por meio de um exame laboratorial a partir da amostra da doença. Neste contexto, este trabalho realizou a classificação automática de doenças do algodoeiro, a partir da extração de características dos sintomas foliares apresentados em imagens digitais. Utilizou-se para este processo, a energia da transformada *wavelet* para extração de características das imagens e para realizar a classificação foi utilizado a Máquina de Vetor de Suporte (MVS). Ao percorrer o sistema final de classificação, uma imagem pode ser classificada entre cinco tipos de diagnósticos diferentes, como sendo “Sadia” (SA), lesionada com as doenças Ramulária (RA), Mancha Angular (MA) e Mancha de *Ascochyta* (AS), ou identificada pertencente a nenhuma das classes.

Palavras-chave: *wavelet*, máquina de vetor de suporte, mvs, fitopatologia, identificação de doenças em planta.

ABSTRACT

The expression of pathogens in the plantations is the leading cause of damage in several cultivars, which may cause higher prices and loss of quality of crops. The sooner the disease is identified, the sooner it is done through its control of pesticides, tending thus to reduce their proliferation and thus avoiding further damage. However, often the visual inspection of the symptoms presented by the occurrence of pathogens in a leaf, is not considered enough to assess and identify the type of disease that is causing the lesion, being necessary for the diagnosis of disease, a more detailed analysis by an agronomist or through a laboratory test sample from the disease. In this context, this paper carried the automatic classification of diseases of cotton, from the feature extraction of leaf symptoms presented in digital images. It was used for this process, the energy of wavelet transform to extract features from images and to perform the classification, we used the Support Vector Machine (SVM). By walking through the final system of classification, an image can be classified in five types of different diagnoses, as being "Healthy" (SA), with the injured Ramularia diseases (RA), Bacterial Blight (MA) and Ascochyta Blight (AS) or belonging to any of the identified classes.

Palavras-chave: *wavelet, support vector machine, svm, phytopathology, identification of plant diseases.*

CAPÍTULO 1 - INTRODUÇÃO

A arte de cultivar é fundamental para a subsistência humana, mas as manifestações de doenças provocam grandes prejuízos não apenas financeiros, mas também na qualidade e nas colheitas dos produtos, podendo causar perdas consideráveis nas lavouras, caso o grau de proliferação seja grande.

Para minimizar e controlar o aparecimento de patógenos são aplicados pesticidas, que, na maioria das vezes, são prejudiciais à saúde humana. Seu uso excessivo aumenta o custo do combate da doença e alerta para o perigo dos níveis de resíduos tóxicos nos produtos agrícolas. Os pesticidas estão entre os maiores componentes de custos de produção dos cultivos e têm sido identificados como entre os principais contribuintes para a contaminação da água do solo [1].

Visando à redução dos pesticidas, garantir a melhoria na qualidade dos produtos e amenizar os problemas inerentes à produção agrícola, são desenvolvidas aplicações em computação que têm se mostrado um importantíssimo recurso. Essa vertente da computação na agricultura é estudada em vários trabalhos científicos que focam principalmente a identificação e/ou a segmentação de doenças através de sintomas foliares. Os estudos são feitos em diversos cultivos, como: algodão [2], arroz [3, 4, 5], maçãs [6], milho [7], orquídeas [8], pepino [9, 10], rosas [11], seringueira [12], soja [13, 14], trigo [1], uva [15].

Muitas vezes, a olho nu, uma única imagem de uma folha na plantação, em um único momento, não é suficiente para detectar e identificar o tipo de patógeno. O desenvolvimento dos padrões pode dar uma indicação muito melhor do tipo de estresse. Mais informações podem ser recolhidas através de imagens obtidas por: fluorescência, RGB, infravermelho e infravermelho termal [16].

Seguindo essa tendência, este trabalho propõe um método para extrair e classificar automaticamente doenças em folhas de plantas, reduzindo, a necessidade de interação humana e aumentando a precisão de diagnósticos, além de auxiliar agrônomos ou agricultores que não dispõem de conhecimentos específicos (biológico e contextual).

Foram escolhidas, para realizar os testes, imagens de folhas do algodão, tendo em vista que são cultivares de grande importância econômica no mercado brasileiro, sendo consideradas um dos pilares da produção têxtil. A indústria têxtil, no Brasil, tende a consumir, por ano, em torno de um milhão de toneladas de fibra de algodão [17, 18]. Neste contexto, observa-se a relevância dessa cultura na economia, bem como na geração de empregos ligados tanto ao setor agrícola como à indústria têxtil.

O sistema desenvolvido tem o objetivo inicial de identificar a existência ou não de patógenos. Havendo constatação de doença, a imagem passa por outra etapa, que é a classificação automática da doença. Os patógenos testados estão classificados entre os principais que ocorrem no Brasil, que possuem disseminação rápida e que podem ser combatidos com produtos químicos [17, 18, 19, 20]. Três tipos de doenças foram utilizadas na classificação: Ramulária (RA), Mancha Angular (MA) e Mancha de *Ascochyta* (AS). Além de classificar a imagem como não pertencente a nenhuma das classes.

Neste trabalho, são utilizados os padrões de cores RGB, HSV, I3a, I3b e no nível de cinza da imagem. Os canais de cor I3a e I3b são desenvolvidos da modificação da transformação original do padrão de cor I1I2I3 [21]. Foi calculada a energia da transformada *wavelet*, para compor o conjunto de vetores de características, que foram utilizados para realizarem o treinamento da rede da MVS (Máquina de Vetor de Suporte), que fez a classificação das imagens.

Vale ressaltar que, este trabalho faz parte de uma pesquisa maior desenvolvida pelo grupo SEDI (Sistemas Eletrônicos Digitais e Imagens), que desenvolve pesquisas para agricultura de precisão. O projeto em desenvolvimento tem o objetivo de criar um veículo autoguiável que está sendo construído para percorrer a lavoura. Este veículo possuirá uma câmera que irá captando imagens e estas serão tratadas pelo sistema que está em desenvolvimento, identificando as doenças e informando a um sistema de controle que pulveriza fungicidas apenas onde existam doenças nas folhas. O módulo de identificação de doenças foi iniciado por este trabalho.

Organização da Dissertação

O próximo capítulo discorre sobre alguns trabalhos que fizeram o uso de técnicas de processamento de imagens na solução de problemas voltados à área agrícola, seguido das abordagens dos conceitos sobre processamento de imagens, bem como a descrição das técnicas e dos métodos que este trabalho está aplicando.

No capítulo 3, relata-se sobre as características e a aquisição das imagens que estão sendo utilizadas. Além disso, descreve detalhadamente as etapas percorridas para encontrar o melhor descritor para cada classe e depois discorre sobre a metodologia utilizada para criar o sistema final de classificação.

A exibição e a análise dos resultados finais são feitos no capítulo 4, seguidos das conclusões deste e de propostas para trabalhos futuros.

CAPÍTULO 2 - FUNDAMENTAÇÃO TEÓRICA

2.1 Trabalhos Correlatos

As doenças em plantas podem causar redução significativa na colheita em função da baixa qualidade dos produtos, podendo influenciar na economia e na vida das pessoas. As principais operações de processamento de imagens em patógenos ocorridos nas folhas são: segmentar, quantizar e/ou classificar os tipos de doenças.

A segmentação é um processo utilizado para separar áreas de interesses de uma imagem através de características de regiões similares. A subdivisão da imagem deve ser realizada dependendo do problema a ser resolvido. Um exemplo baseado no contexto deste trabalho é a segmentação das folhas em imagens de plantas contendo o fundo uniforme ou capturadas direto da plantação.

Delimitada a área doente da folha torna-se mais fácil quantificar o grau de lesão na planta ou identificar a doença causadora da lesão. A quantificação é o item essencial para fazer o controle da doença, as estimativas da perda do rendimento, da sua resistência e produtividade [14]. A classificação é a parte que faz a identificação do possível patógeno que está causando o problema. Essa operação está associada diretamente ao reconhecimento e à interpretação.

O reconhecimento é um modo de extrair atributos que definem um objeto, a partir dos dados fornecidos pelo seu descritor. A interpretação está associada a atribuir significado a um conjunto de objetos reconhecidos [22]. Através desse processo, é possível adquirir

descritores que podem rotular, a partir de uma imagem foliar, a sua espécie ou os tipos de patógenos.

Nesse contexto, são encontrados diversos trabalhos referentes à área de processamento de imagens no domínio agrícola, sendo alguns relacionados abaixo:

- Weizheng [14] desenvolveu um método, para identificar e calcular a região lesionada da folha de soja. Foi utilizado o limiar Otsu para separar a folha de um fundo uniforme. A segmentação foi realizada no canal H do sistema de cor HSI, com o objetivo de minimizar o distúrbio da mudança de iluminação e da veia da folha. Essa segmentação foi feita usando o operador de Sobel, seguida da escolha de um limiar para binarizar a imagem, mostrando somente a área afetada. Então, fez-se o cálculo para computar o nível da lesão na folha, comparando a área de seu espaço ocupado em relação à dimensão da folha. Foram estipulados 5 níveis para definir o nível de severidade demonstrado pelo avanço da doença. Não foi apresentado a porcentagem de acerto dos resultados.

- Boissard [11] realizou a detecção precoce e a contagem da mosca branca em folhas de rosas através da combinação da visão computacional, processamento de imagens, aprendizagem e técnicas baseadas no conhecimento. Os testes foram realizados em duas classes. A primeira corresponde ao conjunto de folhas sem infestação da mosca branca e, na segunda, são utilizadas amostras de folhas contendo pelos menos uma mosca. No primeiro teste, foram utilizadas 102 imagens, obtendo 0% de falsos negativos e 3,1% de falsos positivos. No segundo teste foram usadas 60 amostras, tendo atingido 29,6% de falsos negativos e 2,0% de falsos positivos. Na média geral, o trabalho obteve 11% de falsos negativos e 2,7% de falsos positivos.

- Camargo [21] realizou um método, para identificar o sintoma visual de doenças em plantas através da análise de imagens coloridas. A imagem é segmentada, analisando a distribuição dos níveis de intensidade em um histograma. Uma vez que a imagem foi segmentada, a região extraída foi processada para remover aqueles *pixels* que não são considerados parte da região alvo. Este procedimento foi realizado analisando a vizinhança de cada *pixel* e a mudança do gradiente entre eles. Os testes foram realizados em vinte imagens de cinco cultivares: algodão, milho, banana, alfafa e soja. Para avaliar a exatidão do algoritmo, a imagem manualmente segmentada foi comparada com aquelas segmentadas automaticamente. A média da porcentagem dos *pixels* corretamente identificados foi de 76,6% e de 11,9% a dos *pixels* identificados incorretamente.

– Cui [13] usou um sensor multispectral da imagem, a fim de implementar a detecção antecipada da doença, ferrugem da soja, possibilitar o tratamento adiantado de fungicidas e desenvolver um controle mais eficaz. Com esse sensor, constatou-se que, cada grau de infestação da doença apresentou diferentes refletâncias dentro de uma faixa de banda espectral. Com isso, foi possível detectar a gravidade de lesão da doença, propiciando seu controle, antes de atingir graus de infestação maiores.

– Moshou [1] fez a detecção automática da ferrugem amarela no trigo, utilizando medidas de refletância e redes neurais. Em seu trabalho, conseguiu aumentar o desempenho de classificação de 95% para mais de 99%, usando 5137 espectros de folhas do trigo.

– Anthonys [4] desenvolveu um sistema de reconhecimento, para classificar três tipos de doenças do arroz: brusone, queima da bainha e mancha marrom. Após a aquisição das imagens, foi aplicado o método Sobel, para detectar as bordas, para, posteriormente, fazer extração de características de forma, textura e cores das manchas das doenças. Em seguida, foi aplicado o processo de classificação da função de pertinência, utilizado para discriminar os tipos de doenças. A análise dos resultados mostrou que, neste trabalho, foi atingido mais de 70% de precisão na classificação de cerca de 50 imagens de amostras.

– Na pesquisa de Sanyal [3], foi realizada a identificação da existência de dois tipos de doenças do arroz, mancha marrom e brusone. Foram usados dois tipos de classificadores um para cor e outro para textura. A extração de característica de cor é computada a partir do padrão de cor RGB e as feições texturais foram adquiridas da intensidade da imagem. Para a combinação dos classificadores, foi realizada a concatenação do descritor de cor, com o de textura. A partir disto, o classificador da RNA (Rede Neural Artificial), MLP (*Multilayer Perceptron- Perceptron de Múltiplas Camadas*) foi alimentado. Desse modo, foi possível segmentar as regiões lesionadas. A análise quantitativa dos resultados mostrou que 89,26% dos *pixels* foram corretamente identificados.

Quanto à classificação de determinados grupos, em nosso caso os patógenos, observou-se a grande utilização das RNAs. A RNA é uma subárea da Inteligência Artificial, “que trata de concepções em hardware e software que exibem a capacidade de aprender com a experiência” [24].

Em vista disso, são relacionadas abaixo algumas pesquisas que fazem o uso das RNAs na classificação de patógenos:

– No trabalho do Huang [8], ele fez a classificação de quatro classes de orquídeas. Uma classe refere-se à folha sadia e as outras três classes referem-se a tipos de doenças:

podridão bacteriana, mancha bacteriana marrom e podridão negra. Para extração de características, utilizou-se a matriz de coocorrência aplicando os descritores de contraste, uniformidade, homogeneidade, diferença inversa, probabilidade máxima, variância diagonal, entropia e diferença. Os ângulos utilizados foram 0°, 45°, 90° e 135°. A média de precisão na classificação entre as três doenças foi de 89,6% e, na distinção de uma folha doente e sadia, atingiu a taxa de 97,2% de acerto. Vale ressaltar que os testes foram realizados somente com imagens de folhas lesionadas.

- Abdullah [12] implementou dois modelos de RNA, para classificação de três doenças foliares da seringueira. Um modelo baseou-se apenas no domínio do *pixel* RGB e outro na análise dos componentes principais dos valores de gradação dos *pixels* de cada imagem. O sistema desenvolvido utilizou 600 amostras, para realizar o treinamento e 200 amostras para os testes da RNA. Os resultados, neste trabalho, mostraram que ambos os modelos têm produzido cerca de 70% na precisão de diagnósticos, com mais de 80% de sucesso para sensibilidade. No entanto, aplicando o modelo da análise dos componentes principais, a rede tem tamanho menor. Os testes foram feitos somente com imagens de um tipo das doenças.

- O trabalho de Meunkaewjinda [15] propõe um sistema híbrido, para distinguir doenças da folha da uva. Este trabalho divide-se em três partes principais: segmentação da cor da folha da uva, segmentação das doenças foliares e análise e classificação de doenças. Foi utilizado um mapa de recurso de auto-organização com uma RNA, para implementar um sistema capaz de reconhecer as cores da folha e segmentar as regiões foliares. A segmentação das regiões lesionadas foi utilizada para modificar o mapa de auto-organização de características com algoritmos genéticos. A imagem resultante é filtrada por *wavelets* de Gabor, que proporcionam uma análise mais eficiente. Os vetores de características são novamente aplicados para classificar os tipos de doenças foliares. A classificação é feita em três classes: doença verrugose, ferrugem e nenhuma doença. Foram obtidos 86,03% de acertos da classificação das imagens entre essas três classes.

- Phadikar [25] criou quatro RNAs, para identificar dois tipos de doenças do arroz, brusone e mancha marrom. As RNAs foram treinadas com quatro formas diferentes, os tipos de treinamento foram: os valores do componente de cor RGB das regiões lesionadas; dos dados obtidos da transformada de Fourier, aplicados na área lesionada; rotação arbitrária de 50% da área lesionada; e transformada de Fourier com rotação arbitrária de 50% da área lesionada. Entre as técnicas de treinamento, a RNA treinada com os valores do componente

de cor RGB foi a que apresentou melhor resultado, com 92% de acertos. Para o treinamento e teste das RNAs foram utilizadas 300 amostras para cada fase.

Embora haja um padrão correspondente de reconhecimento para identificação, quantificação e classificação de doenças, o método de observação a olho nu é a principal prática adotada da produção. Pelo motivo da diferença de conhecimento pessoal e experiência prática, as mesmas amostras são classificadas em diferentes classes por peritos diferentes. Consequentemente, o resultado é geralmente subjetivo e é impossível medir precisamente a extensão e o tipo da doença. Embora o método manual possa ser usado para melhorar a exatidão, ele é raramente usado na prática, devido ao incômodo e demorado processo de operação.

2.2 Características dos Tipos de Doenças do Algodão

Existem diversos fatores que provocam estresse na cotonicultura, como deficiência hídrica ou de nutrientes, geadas, ventos frios, altas temperaturas, plantas daninhas, doenças e pragas. Quaisquer ocorrências dessas perturbações podem causar danos severos na produção do algodoeiro.

Os prejuízos causados pelas plantas daninhas não restringem somente ao cultivo do algodão. Os seus danos abrangem a maior parte dos cultivares. As plantas daninhas competem por nutrientes, água e luz, afetando a qualidade do produto colhido. Além disso, elas são empecilhos durante as colheitas [26].

Outro agravante nas plantações é a infestação de pragas, causadas pelos ataques de insetos. São muitas espécies de insetos que infestam a cultura do algodoeiro, como: broca-da-raiz, tripés, pulgão do algodão, lagarta-da-maçã, ácaros, lagarta-rosada, bicudo-do-algodoeiro, percevejo-rajado, percevejo-manchador, lagarta-militar, dentre outras.

O algodoeiro é suscetível à manifestação de vários tipos de doenças, que podem ser causadas por fungos, bactérias e vírus [16]. Entre as principais doenças pode-se destacar: mancha de *Ascochyta*, ferrugem tropical, mancha angular, mancha de alternária, mancha branca ou ramulária, mosaico comum, mosaico das nervuras, murcha de *fusarium*, murcha de *verticillium* e ramulose.

Contudo, a concepção deste trabalho está focada na identificação de doenças foliares causadas por bactérias, fungos e vírus. Dentre as várias doenças pertencentes a essa categoria,

foram selecionadas três da cotonicultura. As doenças escolhidas estão entre os principais patógenos que ocorrem no Brasil, que possuem disseminação rápida quando não combatida em tempo hábil e que o seu controle possa ser feito por meio de produtos químicos, sem a necessidade de erradicar a planta infectada [17, 18, 19, 20]. Sendo assim, para este trabalho, os testes serão realizados em imagem de folhas que se apresentam lesionadas pelos patógenos *Ramulária* (RA), Mancha Angular (MA) e Mancha de *Ascochyta* (AS).

A *Ramulária*, também conhecida como mancha-branca, míldio, oídio, míldio areolado ou falso oídio, é causada pelo fungo *Ramularia aréola* [19]. Ela é considerada uma das principais doenças foliares do algodoeiro, ocorrendo em quase todas as regiões produtoras no Brasil, principalmente no Centro-Oeste [20]. Na Figura 2.1 (a), é exibida uma imagem da folha do algodão atacada com esta doença. Nota-se que seus sintomas são visíveis pelas lesões brancas de formato angular e aspecto cotonoso [27]. Sua disseminação é rápida e pode ocasionar perdas consideráveis na colheita, caso não seja combatida com fungicidas em tempo hábil para efetuar o seu controle. Quando a planta atinge infecções severas, ocorre o desfolhamento extensivo o que resulta em perdas qualitativas e quantitativas na produção do algodão [28].

A Mancha Angular é causada pela bactéria *Xanthomonas pv. Malvacearum*. Suas reações são visíveis na Figura 2.1 (b), sendo caracterizada por regiões angulares “(mesmo formato e dimensão das causadas por *Ramulária aréola*) delimitadas pelas nervuras secundárias e terciárias” [27]. Este patógeno ocorre praticamente em quase todas as regiões produtoras de algodão no mundo. No Brasil, dependendo do ano e do cultivar plantado, a doença pode constituir-se num grave problema, principalmente nos estados do Paraná, Goiás, Mato Grosso e São Paulo; pois a sua disseminação é rápida e de alta variabilidade [18, 19]. É possível visualizar o início do seu ataque nas folhas do algodoeiro, por meio do aparecimento de manchas que possuem aspecto encharcado (úmido) com coloração verde, tornando-se pardas e necrosadas com o passar o tempo. Na face inferior da folha, as lesões prolongam a aparência úmida.

A Mancha de *Ascochyta* possui como agente causal o fungo *Ascochyta gossypii* [30]. Ela é considerada um dos principais patógenos que ocorrem na cotonicultura no Brasil [17]. A severidade e disseminação da doença podem aumentar em alta umidade relativa do ar (acima de 80%) e temperaturas abaixo de 23°C. Esta doença pode causar sérios problemas em condições de inverno chuvoso [19]. É possível visualizar na Figura 2.1 (c) as lesões causadas por esse fungo. Observa-se que os seus sintomas são visíveis pelo aparecimento de manchas circulares, pardas, revestidas de pontuações pretas, que referem-se aos picnídios do fungo.



Figura 2.1: Doenças do Algodão. Em (a) doença Ramulária, (b) Mancha Angular e Mancha de *Ascochyta* [29, 30].

2.3. Processamento de Imagens

A procura e utilização por métodos de processamento de imagens advêm de muito tempo. Uma das primeiras aplicações foi idealizada nos anos vinte do século 20. Consistia em um sistema que fazia transmissão de imagens via cabo submarino, através do oceano Atlântico, de Londres para *New York*. O sistema foi criado por Bartlane que conseguiu na época a redução do tempo de envio da imagem de mais de uma semana, para menos de três horas [22].

Desde então, a busca por recursos de processamento de imagens ampliou-se consideravelmente, bem como a inovação e o surgimento de novos métodos e algoritmos. Seus recursos podem ser aplicados em diversas áreas, como agrícolas, satélites, médicas e robótica.

O uso da tecnologia de processamento de imagens, aplicadas a pesquisas na engenharia agrícola, acontece desde o final de 1970. Suas aplicações estão voltadas principalmente à inspeção e classificação de qualidade de produtos, ao monitoramento no crescimento do cultivar, à identificação de doenças e pragas, entre outros [14].

O desenvolvimento de métodos de processamento de imagens digitais tem a finalidade de melhorar a qualidade da imagem para a percepção humana, na sua análise e interpretação, assim como realizar classificações automáticas de padrões.

2.3.1 Transformação de Cores

Nas imagens digitais coloridas, cada *pixel* pode representar uma dentre milhares de tons e intensidades de cores diferentes perceptíveis aos olhos humanos.

Entre os modelos, o RGB é provavelmente o mais utilizado e, através deste, é possível transformá-lo em qualquer outro espaço de cor. Em vista disto, primeiramente, será abordado o modelo de cor RGB e, depois, as transformações do RGB para níveis de cinza, HSV e HSI.

Modelo de Cor RGB

O modelo de cor RGB pode ser representado como coordenadas 3D, como visto na Figura 2.2. Na Figura 2.2 (a), é ilustrado o modelo RGB e, na Figura 2.2 (b), exibe-se o cubo de cores RGB. Nas coordenadas cartesianas estão as cores primárias (Vermelha, Verde e Azul) e nos outros vértices estão as cores secundárias (Ciana, Magenta e Amarela). Um ponto entre o plano azul e o plano verde, que seja equidistante, define a cor ciana. O ponto, quanto mais próximo da origem mais escura, torna-se essa cor. Nos planos entre as cores azul e vermelha, um ponto, que seja equidistante, define a cor magenta. O ponto, quanto mais próximo da origem mais escura, torna-se essa cor. Um ponto nos planos entre as cores vermelha e verde, que seja equidistante, define a cor amarela. O ponto, quanto mais próximo da origem mais escura, torna-se essa cor. Na origem, localiza a cor preta e, no seu vértice oposto, a cor branca. Os níveis de cinza ficam na diagonal do cubo entre a cor preta e branca.

Uma imagem colorida, representada pelo modelo de cor RGB, constitui-se de três matrizes de $M \times N$, onde N e M referem-se à resolução horizontal (linha) e vertical (coluna) da imagem. Cada matriz correspondente as componentes espectrais, vermelha (R - *Red*), verde (G - *Green*) e azul (B - *Blue*). Visualiza-se na Figura 2.3 a representação dos três canais de cores que compõem o modelo de cor RGB. A imagem exibida na Figura 2.3 (a) é a original e as outras exibem a sua decomposição nos canais R visto na Figura 2.3 (b), G visto na Figura 2.3 (c) e B visto na Figura 2.3 (d). Dessa forma, cada *pixel*, em uma localização espacial específica, é composto pelo arranjo da tripla correspondência dos canais R, G e B.

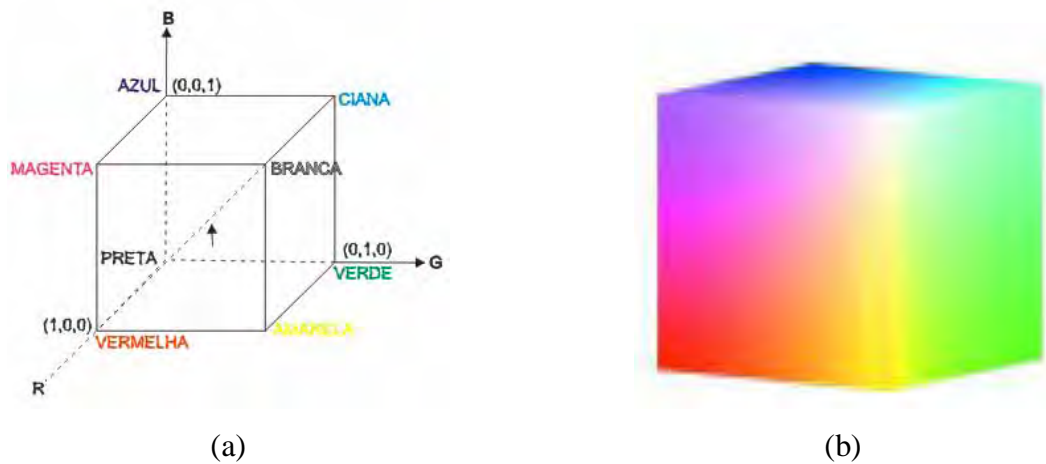


Figura 2.2: (a) Representação do modelo de cor RGB, (b) cubo de cores RGB [22].



Figura 2.3: Decomposição da imagem no modelo RGB (a) em seus respectivos canais de cores: Vermelho (b), Verde (c) e Azul (d).

Transformação de RGB para Níveis de Cinza

A transformação de uma imagem em níveis de cinza é caracterizada pela união das três bandas de cores RGB, formando-se uma nova banda, sendo esta monocromática. Existem várias fórmulas para realizar esta transformação. Portanto, será apresentada uma fórmula que possui maior aproximação aos detalhes de cor e luminância no resultado, de acordo com a definição dada pela CIE (*Commission Internationale de l'Eclairage* – Comissão Internacional de Iluminação) [31, 14, 23]. Essa transformação pode ser obtida pela equação 2.1,

$$I_{\text{cinza}(i,j)} = 0.3 I_{R(i,j)} + 0.59 I_{G(i,j)} + 0.11 I_{B(i,j)} \quad \text{eq. (2.1)}$$

sendo que, as variáveis i e j representam as coordenadas dos eixos cartesianos, o I_R , I_G , I_B indicam canais de cores e I_{cinza} representa a imagem formada em níveis de cinza. O resultado dessa conversão é visualizado na Figura 2.4 (b) e a imagem colorida está na Figura 2.4 (a).




Figura 2.4: Imagem convertida em níveis de cinza (a) Imagem original (b) Imagem convertida em níveis de cinza

Transformação de RGB para HSV

Espaço de cor HSV é composto por três canais diferentes: *Hue* (cor, matiz), *Saturation* (saturação) e *Value* (valor). O canal matiz é a banda que define a cor do objeto, possui valores que estão na faixa de 0° a 360° . Quando normalizado, esse valor varia de 0 a 1. O canal saturação também é conhecido como pureza. Quanto maior o seu valor, mais pura é a cor da imagem e quanto menor o valor, a mesma estará mais próxima ao tom de cinza. O canal “valor” define o brilho da cor da imagem. A saturação e o valor podem possuir valores de 0 a 1 [32].

O espaço de cor HSV pode ser representado por uma pirâmide de base hexagonal, sendo ilustrada na Figura 2.5. Nesta figura, é vista a representação do espaço de cor HSV (na Figura 2.5 (a)) e o sólido de cores do sistema HSV (Figura 2.5 (b)). Na Figura 2.5 (a), observa-se nos vértices do hexágono a disposição das cores definidas pelo ângulo do elemento H , sendo 0° a cor vermelha, 120° verde, 240° azul. A saturação é definida pelo elemento S e ela diminui à medida que se aproxima do centro radial. O eixo central do hexágono define o elemento V , que determina as cores acromáticas do espaço, sendo 0 a cor preta, 1 a cor branca e os valores entre 0 e 1 correspondem às tonalidades de cinza.

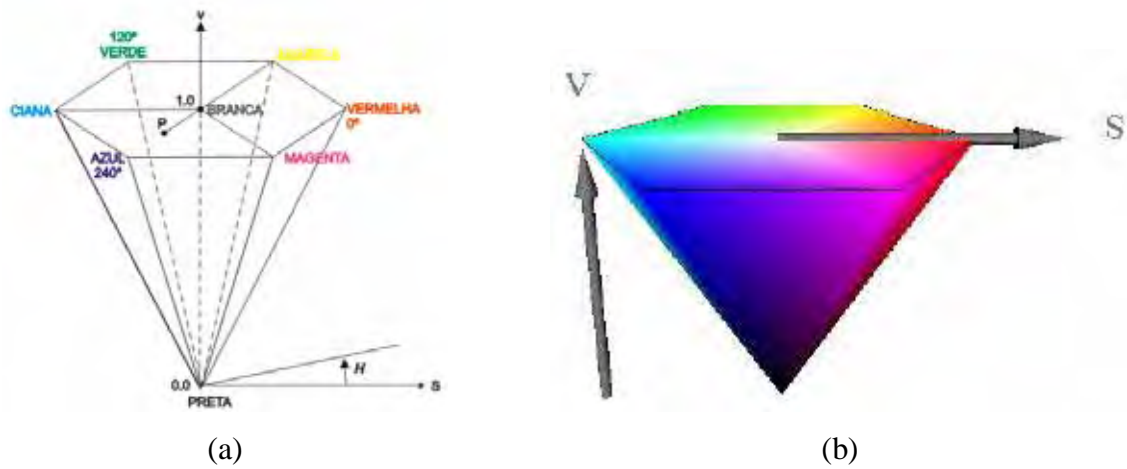


Figura 2.5: Representação do espaço de cor HSV. Em (a), hexágono de cores HSV e, (b), o sólido de cores do Sistema HSV (adaptado de [33, 32]).

Seja “I” definida pelo espaço de cor RGB, em que R, G e B estão entre 0 e 1. A transformação de RGB para o espaço de cor HSV, são obtidas pelas fórmulas presentes na equação 2.2.

$$mx_{(i,j)} = \max(I_{R(I,J)}, I_{G(I,J)}, I_{B(I,J)}) ; mn_{(i,j)} = \min(I_{R(I,J)}, I_{G(I,J)}, I_{B(I,J)}) \quad \text{eq. (2.2)}$$

$$H(i,j) = \begin{cases} -SE \ I_{R(I,J)} > \text{maior} \ (I_{G(I,J)}, I_{B(I,J)}) \text{ então calcular } \frac{60 \times (I_{G(I,J)} - I_{B(I,J)})}{mx - mn}; \\ -SE \ I_{G(I,J)} > \text{maior} \ (I_{R(I,J)}, I_{B(I,J)}) \text{ então calcular } \frac{60 \times (I_{B(I,J)} - I_{R(I,J)})}{mx - mn}; \\ -SE \ I_{B(I,J)} > \text{maior} \ (I_{B(I,J)}, I_{G(I,J)}) \text{ então calcular } \frac{60 \times (I_{R(I,J)} - I_{G(I,J)})}{mx - mn}; \end{cases}$$

$$S(i,j) = \left(\frac{mx - mn}{mx} \right)$$

$$V(i,j) = (mx),$$

sendo:

H: corresponde ao canal matiz

S: corresponde ao canal saturação

V: corresponde ao canal “valor”

mx: maior nível de intensidade entre os canais de cor R, G e B

mn: menor nível de intensidade entre os canais de cor R, G e B

Transformação de RGB para I1I2I3

O espaço de I1I2I3 foi definido por Ohta [34] após vários testes para segmentar imagens. Foram utilizados mais de 100 características de cores adquiridas em oito tipos de imagens coloridas. O modelo I1I2I3 atingiu melhores resultados na segmentação comparados a outros seis espaços de cores (RGB, HSI, CIE (L*a*b), Nrgb, XYZ e YIQ).

Sendo “I” pertencente ao modelo de cor RGB, então, o cálculo do espaço de cor I1I2I3 é dada pela equação 2.3,

$$I_1 = (I_{R(i,j)} + I_{G(i,j)} + I_{B(i,j)})/3$$

$$I_2 = (I_{R(i,j)} - I_{B(i,j)})/2 \quad \text{eq. (2.3)}$$

$$I_3 = ((2 * I_{G(i,j)}) \sum I_{R(i,j)} + \sum I_{B(i,j)})/4$$

sendo, $0 \leq \{I_R, I_G, I_B\} \leq 255$, $\sum I_{R(i,j)}$ é o somatório de todos os *pixels* do canal R, $\sum I_{B(i,j)}$ é o somatório de todos os *pixels* do canal B.

Camargo [21] promoveu modificações no canal de cor I_3 , criando dois novos canais, o I3a e o I3b. Essas modificações foram feitas nas constantes m e d dadas pela equação 2.4,

$$I3 = ((m \times I_{G(i,j)}) \sum I_{R(i,j)} \sum I_{B(i,j)})/d \quad \text{eq. (2.4)}$$

sendo, $0 \leq \{I_R, I_G, I_B\} \leq 255$. As modificações dos valores das constantes de m e d constituíram os canais I3a e I3b, definidos pela equação 2.5. No canal I3a, foi alterado o valor da constante m de 2 para 2,5 e, no canal I3b, foi alterado o valor da constante d de 4 para 2.

$$I3a = ((2.5 \times I_{G(i,j)}) \sum I_{R(i,j)} \sum I_{B(i,j)})/4 \quad \text{eq. (2.5)}$$

$$I3b = ((2 \times I_{G(i,j)}) \sum I_{R(i,j)} \sum I_{B(i,j)})/2$$

Os canais de cores I3a e I3b foram obtidos empiricamente, conseguindo destacar melhor as áreas foliares lesionadas pelas doenças no algodão, milho, banana, alfafa e soja [21].

2.4 Extração de Características

A extração de características geralmente é um processo que sucede a segmentação (separa as áreas de interesse da imagem que se deseja analisar). Após as regiões serem segmentadas, elas podem ser representadas e descritas em formatos apropriados, permitindo, posteriormente, que seus resultados sejam analisados e usados no processo de reconhecimento e interpretação de padrões.

Em uma imagem, pode haver dois tipos de características, as naturais e as artificiais. As características naturais correspondem à aparência de uma imagem, como luminosidade de uma região de *pixels* e regiões texturais de nível de cinza. Nas características artificiais, são analisadas as manipulações diretamente na imagem, por meio da análise de seu histograma e dos níveis de cinza das texturas das regiões analisadas [35].

Uma determinada área em uma imagem pode ser representada pelas suas características externas (fronteira) e internas (região). As características externas correspondem às fronteiras das regiões. As características internas referem-se aos níveis de cores dos *pixels* que constituem as regiões, sendo estas, estudadas neste trabalho.

2.4.1 Descritores Regionais

Descritores regionais são técnicas que analisam os níveis de cores dos *pixels* que compõem as áreas internas de regiões de uma imagem, sendo descritas pelas suas propriedades de textura.

A textura é observada nos padrões estruturais das superfícies dos objetos. As características da textura podem ser grosseiras, finas, lisas, granuladas, regulares, irregulares e lineares. Dessa forma, duas imagens exatamente com a mesma cor e tamanho podem ser consideradas diferentes somente pelo fato de possuírem texturas desiguais [3].

Descritores Simples de Região

As regiões de descritores simples são compostas pelos *pixels* internos de uma região. Podem ser representadas através de descritores topológicos, tendo como foco imagens que não se afetam quando estendidas ou rotacionadas. Um descritor topológico pode ser definido pela quantidade de buracos existentes em uma determinada, região ou pelo número de componentes conexos. Um componente conexo corresponde a um conjunto de *pixels* tal que cada um deles seja alcançável a partir de outro. Esse tipo topológico é utilizado para computar o número de *Euler*.

Número de *Euler*: é um descritor topológico que pode descrever regiões globais no plano da imagem. O número de *Euler* “E” é definido pela equação 2.6, em que B representa o número de buracos na imagem e C o número de componentes conexos. Nota-se na imagem exibida na Figura 2.6, o número de *Euler* igual a “-1” de suas regiões, tal que a imagem possui um componente conexo e dois buracos [22, 36].

$$E = C - B \quad \text{eq. (2.6)}$$




Figura 2.6: Regiões com números de Euler = -1 (adaptado de [22]).

Existem outras formas de representar regiões internas, como as abordagens heurísticas. Entre os vários métodos das abordagens heurísticas, são citados alguns: métodos de retangularidade, excentricidade, projeção, compacidade. Essas abordagens produzem resultados aceitáveis na descrição de regiões simples, sendo assim, não aconselhados para serem aplicados em objetos de formas mais complexas. Além disso, estes descritores não podem ser usados para reconstrução da região [36].

Compacidade: é um dos descritores de características de região que medem a densidade do objeto, em comparação com uma região perfeitamente densa [36]. A compacidade, normalmente, é utilizada quando o tamanho dos objetos não varia. Para o cálculo desse descritor, são usados dois parâmetros: área (número de *pixels* contidos dentro da

fronteira do objeto) e perímetro (tamanho da fronteira) [22]. A compacidade é expressa pela equação 2.7,

$$C = \frac{P^2}{A} \quad \text{eq. (2.7)}$$

em que, P é o perímetro da fronteira e A é a área da região.

Projeção: é uma descrição de características de região, geralmente utilizada em imagens binarizadas. Pode-se realizar a projeção horizontal $p_h(x)$ em cada linha da imagem e a projeção vertical $p_v(y)$ em cada coluna da imagem. Para obter a projeção horizontal em uma linha é calculado o somatório dos *pixels* que não possui buracos (*pixels* com intensidade de cinza igual a um). O mesmo cálculo é realizado para se obter a projeção vertical, mas o somatório é feito nos *pixels* posicionados nas colunas da imagem digital e não mais nas linhas. A altura da projeção é dada pelo maior valor do somatório entre a projeção horizontal e a largura pelo maior valor do somatório da projeção vertical, como ilustrado na Figura 2.7. Na Figura 2.7 (a), é mostrada a região em que se deseja obter a projeção. Na Figura 2.7 (b), é exibida a projeção vertical, realizada em cada linha, sendo a largura definida pelo maior valor da projeção vertical e, na Figura 2.7 (c), é vista, a projeção horizontal de cada coluna, em que o seu maior valor define a altura.




Figura 2.7: Exemplo de Projeção. Em (a), região original e suas projeções vertical em (b) e horizontal em (c) [36].

Seja “I” uma imagem e suas coordenadas definidas por x e y, então a projeção é expressa pelas fórmulas apresentadas na equação 2.8 [36].

$$p_h(x) = \sum_y I_{(x,y)}$$

$$p_v(y) = \sum_x I_{(x,y)}$$

eq. (2.8)

Sendo:

$p_h(x)$: projeção horizontal;

$p_v(y)$: projeção vertical;

$\sum_y I_{(x,y)}$: somatório dos *pixels* da linha que possui intensidade de nível de cinza igual a 1;

$\sum_x I_{(x,y)}$: somatório dos *pixels* da coluna que possui intensidade de nível de cinza igual a 1.

2.5 Reconhecimento e Interpretação de Padrões

Os seres humanos são organismos inteligentes que possuem a capacidade de adquirirem conhecimentos através da experiência, possibilitando transformar informações imprecisas e incompletas em reações que são utilizadas nas ações e decisões tomadas constantemente durante a vida [37]. Neste contexto, um ser humano é dotado de capacidade de processar uma imagem, analisá-la e compreendê-la. Apesar deste fato, às vezes, é considerado difícil identificar e reconhecer o que é visto, quando o que se espera é desconhecido [36].

No âmbito de processamento de imagens, a compreensão de um cenário pode demandar de muitas etapas de processamento. Então, antes de uma imagem ser analisada, normalmente ela é adquirida. Depois, se necessário, ela é suavizada para amenizar os possíveis ruídos. Continuando esse processo, ela pode ainda ser segmentada para separar as áreas de interesses, seguida da extração de características. No processo de extração de características, é feita a seleção de atributos, com o objetivo de obter informações úteis que

possam representar o contexto alvo que se deseja analisar em uma imagem. Por fim, essas informações extraídas passam pelo processo de reconhecimento de padrões, sendo uma das etapas finais, que analisa as características para rotular um objeto a que categoria ele pertence.

Contudo, o reconhecimento e a interpretação de padrões são dois processos que visam encontrar meios de transformar o comportamento humano em sistemas de computadores, para que seja possível analisar, distinguir e decifrar imagens.

Para realizar o reconhecimento e a interpretação de padrões, podem-se utilizar métodos de reconhecimento por decisão teórica, métodos estruturais para o reconhecimento e métodos para a interpretação de imagens. Os métodos de reconhecimento por decisão teórica fundamentam-se na representação de padrões na forma numérica atribuída a um vetor de características. Uma das principais abordagens deste método são os classificadores de distância mínima, classificadores bayesianos e redes neurais. O reconhecimento estrutural refere-se a métodos que se baseiam na representação na forma simbólica, como cadeias e árvores. A interpretação de imagens está relacionada, na atribuição de significado, a um conjunto de elementos reconhecidos de uma imagem [22].

Será apresentado um exemplo do método decisão teórica, seguida de uma seção sobre MVS (Máquina de Vetor de Suporte), que é a técnica que este trabalho utilizou, para classificar os patógenos da doença do algodoeiro.

2.5.1 Métodos de Decisão Teórica

Seja $x = (x_1, x_2, \dots, x_n)^T$ um vetor de padrões n -dimensional. A dificuldade no reconhecimento de padrões, por decisão teórica de M classes de padrões $\omega_1, \dots, \omega_M$, consiste em definir M funções de decisões $d_1(x), d_2(x), \dots, d_M(x)$, para determinar se o padrão x pertence à classe ω_i . Os empates são resolvidos arbitrariamente.

O limite de decisão que separa as classes ω_i e ω_j é definido pelos valores de x para os quais $d_i(x) = d_j(x)$. Normalmente, a identificação do limite de decisão entre duas classes é expressa pela função $d_{ij}(x) = d_i(x) - d_j(x) = 0$. Quando $d_{ij}(x) > 0$ referem-se aos padrões da classe ω_i e $d_{ij}(x) < 0$ referem-se aos padrões da classe ω_j [22].

Uma das possíveis maneiras de aplicar este método é utilizando o classificador de distância mínima.

Classificador de Distância Mínima

Seja cada classe de padrões representada por um vetor médio, dada pela equação 2.9,

$$m_j = \frac{1}{N_j} \sum_{x \in \omega_j} x \quad j = 1, 2, \dots, M \quad \text{eq. (2.9)}$$

sendo que, N_j é o número de vetores de padrões da classe ω_j e a soma é feita sobre esses vetores. Uma forma de determinar a pertinência de um vetor x de padrão desconhecido é atribuí-lo à classe de seu protótipo mais próximo. Para definir essa proximidade, pode ser aplicada a distância euclidiana, dada pela equação 2.10.

$$D_j(x) = \|x - m_j\| \quad j = 1, 2, \dots, M \quad \text{eq. (2.10)}$$

Sendo $\|a\| = (a^T a)^{1/2}$ a norma euclidiana. Caso $D_j(x)$ seja a menor distância (melhor casamento dessa situação), então, x será atribuído à classe ω_j .

A superfície de separação é a bissetão perpendicular do segmento de linha entre m_i e m_j , considerando que $n=2$, “a bissetão perpendicular é uma linha, para $n=3$ é um plano, e para $n>3$ é chamada de hiperplano” [22, 23]. Na Figura 2.8, é ilustrado um exemplo de classificação pela distância mínima, onde são apresentadas duas classes, tendo a distribuição bidimensional agrupada por um classificador de menor distância. A separação da superfície é definida por uma reta.

Normalmente, o classificador de distância mínima tem um bom funcionamento “quando a distância entre as médias for grande em comparação com a dispersão ou aleatoriedade de cada classe em relação à sua média” [22].

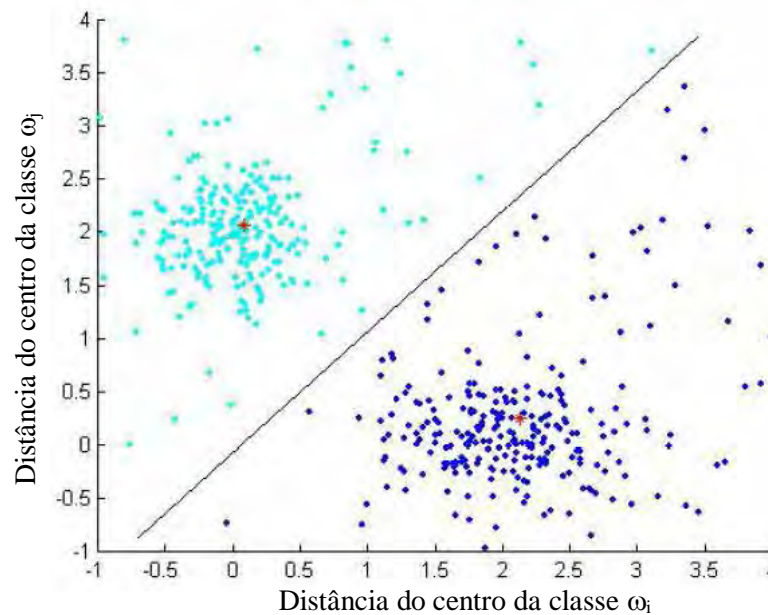


Figura 2.8: Classificação pela distância mínima [38]

2.6 Classificadores Inteligentes

A habilidade que os organismos inteligentes possuem de adquirirem conhecimentos através da experiência, inspiraram vários pesquisadores a desenvolverem estudos que são embasados na estrutura do cérebro humano e no funcionamento dos neurônios [39]. O neurônio é uma célula no cérebro, cuja principal função é coletar, processar e disseminar sinais elétricos [40].

Em vista disso, surgiu em 1943, a neurocomputação, iniciada pelo psiquiatra e neuroanatomista, Warren McCulloch, e o matemático, Walter Pitts, que escreveram o artigo “*A Logical Calculus of the Ideas Immanent in Nervous Activity*”. Neste artigo, havia uma proposta de um novo modelo matemático para descrever o comportamento neural, de modo que o neurônio poderia assumir dois estados, ficar inativo ou ficar disparando sinais por meio de um tratamento discreto e binário [41].

Esse foi o momento que surgiu “a área de conhecimento chamada de Redes Neurais Artificiais (RNA), que trata de concepções em hardware e software que exibem a capacidade de aprender com a experiência” [24].

A técnica de classificação utilizada, neste trabalho, foi desenvolvida a partir de uma ferramenta de Inteligência Artificial, usada para classificação binária, sendo relativamente mais elaborada que as RNAs [42]. Essa técnica é conhecida como *Support Vector Machine*

(MVS - Máquina de Vetor de Suporte), sendo cada vez mais utilizada na área científica, devido ao fato de possuir uma sólida fundamentação teórica e, também, por atingir alto desempenho em aplicações práticas e, muitas vezes, superiores a resultados obtidos por outros algoritmos de aprendizado, como as RNAs [42, 43, 44]. As MVS são utilizadas nas áreas de reconhecimento de padrões, processamento de imagens, aprendizagem de máquina e bioinformática [45].

Inicialmente, foi proposto em 1963 por Vladimir Vapnik, um algoritmo do hiperplano que tivesse a maior distância entre os vetores suportes, por meio de uma classificação linear, usando a metodologia de aprendizagem [46]. Em 1992, Vladimir Vapnik [47] e colaboradores desenvolveram uma estratégia para realizar a separação não linear dos hiperplanos, utilizando as funções *kernel* ou núcleo, que modificam o espaço de entrada em um espaço de dimensão maior, as quais os dados são linearmente separáveis. Os núcleos mais comuns de serem encontrados são: linear, gaussiano e polinomial. Neste trabalho, o núcleo aplicado foi o gaussiano [42, 44].

A técnica de aprendizagem de máquina MVS baseia-se no princípio de Minimização do Risco Estrutural, visando minimizar o erro com relação ao conjunto de treinamento (controlar o risco empírico) e com o risco de generalização relacionado ao conjunto de amostras não empregadas no treinamento do classificador, evitando, dessa forma, gravar ruídos ao invés de extrair as características gerais que propiciarão a generalização ou o reconhecimento de padrões não usados no treinamento do classificador [41, 42].

O hiperplano separador é uma superfície que divide o espaço de características em dois subespaços, sendo um elemento classificado como pertencente à classe -1 , se estiver mais próximo da margem negativa e será pertencente a classe $+1$, se estiver mais próximo da margem positiva.

Seja “um conjunto de vetores de treinamento $\{(\vec{x}_1, y_1); (\vec{x}_2, y_2); \dots (\vec{x}_n, y_n)\}$ pertencente a duas classes linearmente separáveis”, W_1 definida pela saída $y_i = +1$ e W_2 definida pela saída $y_i = -1$ [42]. A meta da técnica MVS é achar o melhor hiperplano, com a maior margem de separação possível entre os vetores da classe -1 e da classe $+1$. Esse princípio é ilustrado na Figura 2.9, sendo a classe W_1 representada pelo conjunto de triângulos e a classe W_2 representada pelo conjunto de círculos. Essas duas classes são linearmente separadas pela margem máxima de separação δ , definida como sendo a soma das distâncias do hiperplano até o ponto mais próximo das classes (separação ótima). Vale ressaltar que os vetores que definem os limites do hiperplano são conhecidos como vetores de suporte [18, 46].




Figura 2.9: Separação linear das classes W_1 e W_2 com base num hiperplano [42].

“Nos casos de conjuntos de treinamento não linearmente separáveis”, associa-se ao i -ésimo ponto x_i , ($0 \leq i \leq N$), a magnitude do erro de classificação que é representada pela variável σ_i . A soma dos erros de classificação pela função de penalidade é representada pela função $F(\sigma) = \sum_{i=0}^{N-1} \sigma_i$, com base na minimização dos erros de treinamento $\frac{1}{2} \vec{w}^T \vec{w} + C \sum_{i=0}^{N-1} \sigma_i$ em que \vec{w} é o vetor de peso e $C \in \mathbb{R}$, a solução da MVS é obtida [42, 44].

Na Figura 2.10, é ilustrada a arquitetura básica de uma MVS, em que é possível observar três camadas de elementos. A primeira, à esquerda, possui a função de apenas transmitir os valores de entrada para a próxima camada. A camada intermediária, também conhecida como camada oculta, é definida para realizar o mapeamento não linear. E, por fim, a terceira camada, situada à direita da figura, é constituída por um único elemento de processamento, que está associado ao vetor de pesos \vec{w} , que faz a separação linearmente das características do mapeamento anterior.

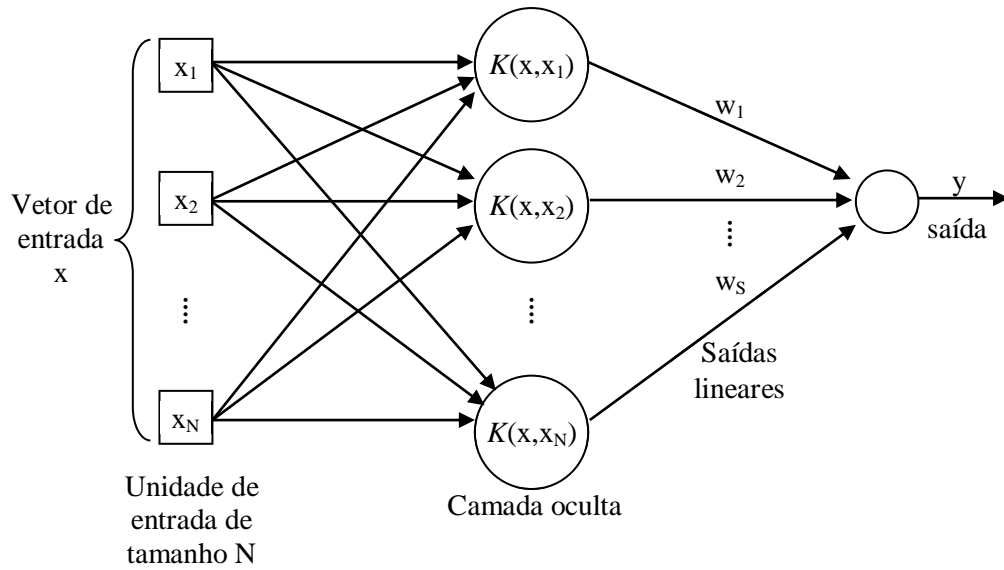


Figura 2.10: Arquitetura da MVS (adaptado de [42])

2.7 Transformada Wavelet

O termo “*wavelet*” começou a aparecer mais frequentemente no início da década de 1980, sendo introduzido por Jean Morlet, que propôs uma modificação na Transformada de *Fourier* (TF), para melhor tratar sinais geofísicos. Em seu trabalho, os dados sísmicos apresentavam o conteúdo de frequência que mudavam rapidamente ao longo do tempo. Dessa forma, a TF não era adequada como ferramenta de análise, pois utiliza apenas janelas (largura da função) de observação fixas. Além disso, a TF utiliza apenas um único conjunto de funções base, sendo estas, seno e cosseno. Inicialmente, Morlet conceituou as *wavelets* como sendo uma família de funções constituídas por meio de translações e dilatações de uma única função identificada como “*wavelet mãe*” [48, 49].

Apesar de trabalhos semelhantes à transformada *wavelet* tenham sido apresentados por Alfred Haar, desde 1910, sendo atualmente conhecida como base de *Haar*. As *wavelets* de *Haar* ficaram por um longo tempo no anonimato e, por esse período, elas continuaram sendo a única base ortogonal para as *wavelets* conhecidas [49, 50].

Um dos principais motivos que levaram à descoberta das *wavelets* e da transformada *wavelet* (TW) foi à análise feita através de TF, que não possui a informação de localização no tempo dos sinais. Deste modo, a TF não permite ser utilizada para analisar sinais no domínio do tempo e da frequência ao mesmo tempo [48]. Neste contexto, a transformada *wavelet* pode

representar uma imagem inteira por meio de uma quantidade mínima de valores (em uma escala menor da imagem) [49].

Nos últimos anos, a transformada *wavelet* tem-se demonstrado muito eficiente para realizar análise de sinais complexos não estacionários, em relação ao tempo-frequência do sinal. É notório o aumento de sua utilização, que tem sido aplicada a uma grande variedade de biossinais, como: análise de sinais neurofisiológicos, diagnósticos de sinais e imagens médicas, estimativa da pressão microvascular pulmonar, mamografias, compressão de sinais, análise dos sinais do cérebro, classificação dos distúrbios da voz, entre outros [51].

A TW decompõe um sinal em bandas de diferentes frequências, sendo o sinal utilizado, neste trabalho, uma imagem. No processo de decomposição dos sinais, dois tipos de funções são geradas, as *wavelets* (ou *wavelet* mãe) e as de escala (ou *wavelet* pai). As funções de *wavelets* correspondem aos filtros passa-altas (*High-Pass*) e as funções de escalas (*scaling*) consistem em filtros digitais passa-baixas (*Low-Pass*).

A formação das funções *wavelets* e funções de escala são construídas por operações de escalonamento (dilação) e movimentação (translação).

O **escalonamento** é o processo que comprime ou dilata o sinal, geralmente representado pela letra “a”. Na Figura 2.11, é ilustrado um exemplo do efeito do fator de escala atuando em uma função *wavelet*. Observa-se que, quanto menor o fator de escala, mais “contraído” é o sinal. Nota-se também que a escala está relacionada com a frequência do sinal, onde as baixas escalas de “a” correspondem à *wavelet* contraída, tendo os seus detalhes mudando rapidamente (alta frequência). Nas altas escalas de “a”, relacionam as *wavelets* dilatadas e seus detalhes mudam mais lentamente.

A **translação** é uma operação da *wavelet* que consiste em seu deslocamento no eixo do tempo, podendo atrasá-la ou adiantá-la em relação ao eixo das abscissas. Um exemplo matemático de atraso da função $f(t)$ de um fator k , sendo k uma constante é dado por $f(t-k)$. Essa expressão pode ser visualizada na Figura 2.12, sendo mostrada na Figura 2.12 (a), a função *wavelet* $\Psi(t)$ e, na Figura 2.12 (b), é observada a função *wavelet*, transladada por um fator k [48].

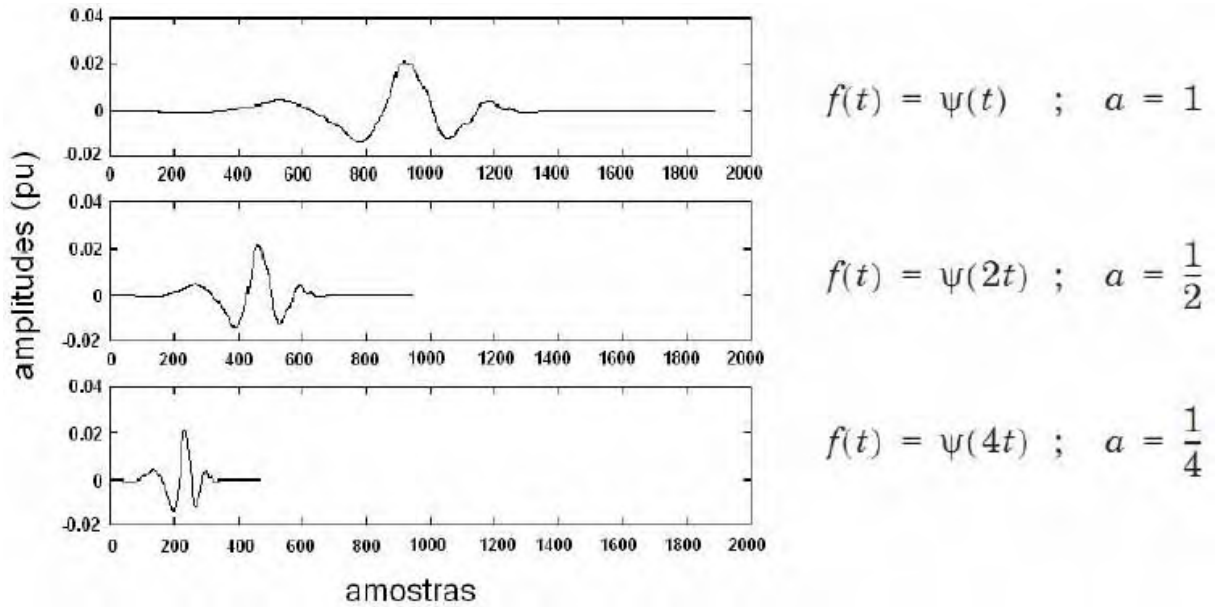


Figura 2.11: Exemplo do fator de escala atuando em uma função *wavelet* [48]




Figura 2.12: Translação de uma função *wavelet*. Em (a), Função *wavelet* $\Psi(t)$ e, em (b), função *wavelet* transladada [48]

As *wavelets* são adquiridas através de escalonamento (dilatação) e translação de uma *wavelet* original. De forma geral, as *wavelets* podem ser definidas pela equação 2.11 [48, 49, 52],

$$\Psi_{a,b}(t) = \frac{1}{\sqrt{a}} \Psi\left(\frac{t-b}{a}\right) \quad \text{eq. (2.11)}$$

sendo que, “a” representa o parâmetro escala (dilatação) e b representa o parâmetro de translação.

Será vista nesta seção uma versão da transformada *wavelet* discreta, que decompõe um sinal discreto em diferentes níveis de resolução.

2.7.1 Transformada *Wavelet* Discreta (TWD)

Na transformada *wavelet* para os sinais discretos, os parâmetros de escalonamento e translação não variam continuamente [50]. Desse modo, na TWD, é determinada somente a grade discretizada de escalas “a” e localização b, visto que, o sinal de entrada é tratado com uma aproximação inicial ao sinal de base contínua, utilizando um algoritmo de multirresolução. Portanto, a transformação da *wavelet* e sua inversa pode ser computada discretamente, de forma rápida e sem ocorrer perda do sinal. Uma forma natural de se obter amostras para os parâmetros “a” e b é a utilização de discretização logarítmica de uma escala “a”, sendo a quantidade de passos definidas entre b localidades. Para criar o vínculo entre “a” e b, move-se em etapas distintas para cada localização de b, que é proporcional à escala “a”.

Este tipo de discretização da *wavelet* é dada pela equação 2.12 [51].

$$\Psi_{m,n}(t) = \frac{1}{\sqrt{a_0^m}} \Psi\left(\frac{t - nb_0 a_0^m}{a_0^m}\right) \quad \text{eq. (2.12)}$$

Na equação 2.12, os inteiros m e n controlam a escala (dilatação) e translação; a_0 é uma dilatação fixa especificada por um conjunto de parâmetros maiores do que 1 e b_0 é o parâmetro local que deve ser maior do que 0. Normalmente, a escolha dos parâmetros da *wavelet* discreta de a_0 e b_0 são 2 e 1. Essas duas forças de escalas logarítmicas, em ambas as etapas de dilatação e translação, são chamados de grade diádica de arranjo. Quando for substituído o valor de a_0 para 2 e de b_0 para 1, então, a fórmula da *wavelet* pode ser simplificada, sendo reinscrita pela equação 2.13 [51].

$$\Psi_{m,n}(t) = 2^{\frac{m}{2}} \Psi(2^{-m}t - n) \quad \text{eq. (2.13)}$$

Observa-se, que a equação 2.13 possui a mesma notação da TWD, definida na equação 2.12. Sendo assim, $\Psi_{m,n}(t)$ será utilizado somente para especificar as etapas de escala e translação com $a_0 = 2$ e $b_0 = 1$. Para as etapas TWD de escala e translação são normalmente ortogonais entre si e normalizados para ter energia unitária, sendo definida pela expressão 2.1.

$$\int_{-\infty}^{\infty} x(t) \Psi_{m,n}(t) \Psi_{m',n'}(t) dt = \begin{cases} 1 & \text{Se } m = m' \text{ e } n = n' \\ 0 & \text{caso contrário.} \end{cases} \quad (2.1)$$

Expressão 2.1

Dessa forma, proporciona a regeneração completa do sinal original sem redundância, em que as informações armazenadas em um coeficiente *wavelet* $T_{m,n}$, obtidas a partir da transformada *wavelet*, não se repetem em outros lugares. A família referente às *wavelets* ortonormais é uma base contendo um conjunto de vetores combinados que podem definir completamente o sinal $x(t)$ e são perpendiculares entre si. Na Figura 2.13, são mostrados exemplos de *wavelets* ortonormais. Na Figura 2.13 (a), são mostradas três *wavelets* de *Haar* em três escalas consecutivas em uma grade diádica. É vista na Figura 2.13 (b), a *wavelet* de Meyer associada à função de escala (à direita). Na Figura 2.13 (c), é exibido o sinal da *wavelet* de *Daubechies* 4 e na Figura 2.13 (d) o sinal da *wavelet* de *Daubechies* D20, e em 2.13 (e), é ilustrada a *wavelet* de *Coiflets* C18, sendo a função de escala visualizada pela linha pontilhada.

Para adquirir novos sinais de alta frequência, faz-se o produto da *wavelet* da equação 2.13 com o sinal original $x(t)$, de forma que a TWD seja definida pela equação 2.14, sendo $T_{m,n}$ conhecido como coeficiente *wavelet* (ou detalhe) de escala e localização de índices (m,n) [51].

$$T_{m,n} = \int_{-\infty}^{\infty} x(t) \Psi_{m,n}(t) dt \quad \text{eq. (2.14)}$$

A decomposição da *wavelet* pode ser implementada pela análise de multirresolução. Esta análise é uma técnica de processamento de sinais, sendo utilizada como um conjunto de filtros especializados em obter informações do sinal, como suas frequências e sua localização no tempo de duração, em diferentes resoluções [50].

A transformada *wavelet* de multirresolução pode decompor um sinal em dois novos sinais de diferentes frequências, como os filtros passa-baixa e passa-alta, sendo esta decomposição, definida como filtros em quadratura ou QMF (*Quadrature Mirros Filter*). Cada filtro é composto com a metade da banda do sinal original. O filtro passa-alta refere-se à função *wavelet* $\Psi(t)$, produzindo os coeficientes de detalhes da decomposição *wavelet*. Quanto à função passa-baixa, refere-se à função de escalonamento $\Phi(t)$ e está relacionada com os coeficientes de aproximação da decomposição *wavelet*.

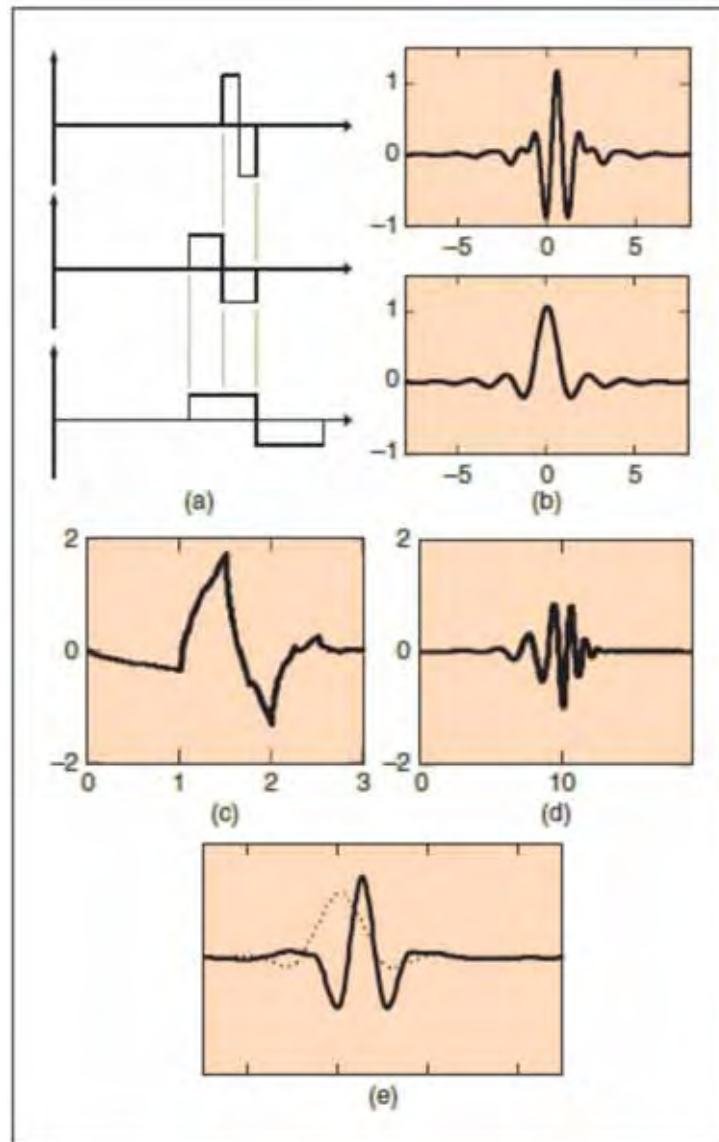


Figura 2.13: Exemplos de *wavelets* ortogonais discretas. Em (a), são exibidas três *wavelets* de *Haar*, em três escalas consecutivas em uma grade diádica. Em (b), a *wavelet* de *Meyer* e associados a função de escalonamento (à direita). Em (c), *wavelet* de *Daubechies* D4, em (d) *wavelet* de *Daubechies* D20 e, em (e), *wavelet* *Coiflets* C18 (função de escalonamento demonstrado em pontilhado) [51].

Na Figura 2.14, é ilustrada a decomposição da *wavelet* de multirresolução, em que S corresponde ao sinal original de entrada, sendo decomposto em um par de filtros digitais: passa-alta e passa-baixa. Dessa forma, o filtro passa-baixa produz o coeficiente de aproximação e o passa-alta corresponde aos filtros de detalhes.

O processo de decomposição é iterativo, com sucessivas decomposições nos coeficientes de aproximação. Portanto, cada vez que a decomposição é realizada, obtém-se dois novos sinais. Somente o filtro passa-baixa é usado para continuar o processo recursivo de

decomposição. Dessa forma, é possível representar um sinal em vários níveis de resolução [53].

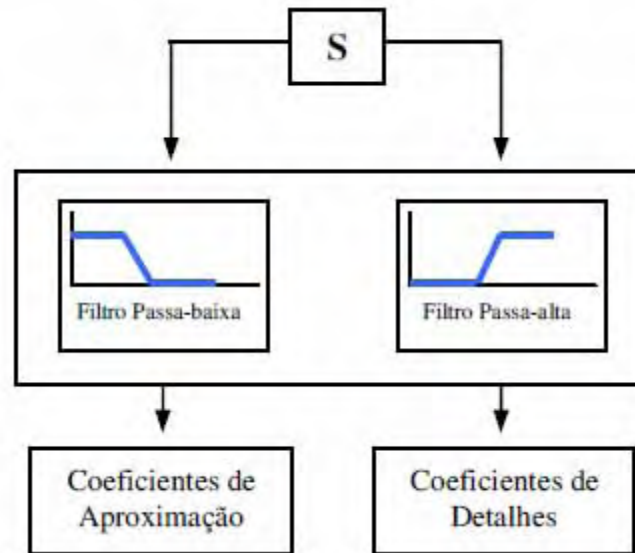


Figura 2.14: Decomposição *Wavelet* Discreta de Multirresolução [50].

Conforme se decompõe a imagem, obtém-se uma estrutura de árvore da *wavelet*, como visto na Figura 2.15. Nesta figura, observa-se que o sinal original S foi decomposto em 3 níveis, no primeiro nível S foi transformado em dois novos sinais, denominados como coeficiente de aproximação 1 (SA1) e coeficiente de detalhe 1 (SD1). No segundo nível, como já dito anteriormente, a decomposição é realizada na sub-banda do sinal SA1 (passa-baixa), criando mais dois sinais SA2 e SD2. Dessa forma, a terceira escala (decomposição) ocorre na sub-banda SA2, gerando mais duas sub-bandas SA3 e SD3.




Figura 2.15: Árvore de decomposição da *wavelet* de um sinal.

2.7.2 Wavelets e Processamento de Imagens

A imagem digital trata-se de um sinal bidimensional e, ao aplicar a TWD, ela pode ser decomposta em quatro regiões (sub-bandas), ao invés de duas, como nos sinais unidimensionais. A Figura 2.16 exibe um esquema das regiões em que a imagem é dividida após ser aplicada a TWD, na região referenciada pela letra A, tende a concentrar o coeficiente de aproximação (baixa-frequência) de linhas e colunas da imagem, na região DL corresponde à concentração do coeficiente de detalhes das linhas e aproximações de colunas, na região DC, refere-se à concentração do coeficiente de detalhes das colunas e aproximação de linhas, e, na região D, tende a apresentar o coeficiente de detalhes (alta-frequência) de linhas e colunas.




Figura 2.16: Esquema de decomposição da *wavelet*.

Da mesma forma que no sinal unidimensional, em um sinal bidimensional podem ser aplicadas sucessivas decomposições. Esquemáticamente, a decomposição da TWD de uma imagem em três níveis é representada pela Figura 2.17. Cada nível ocorrido na imagem é identificado pelo seu número. No primeiro nível de decomposição, são geradas as sub-bandas A1 (coeficiente de aproximação de linhas e colunas do primeiro nível), DL1 (coeficiente de detalhes das linhas), DC1 (coeficiente de detalhes de colunas) e D1 (coeficiente de detalhes de linhas e colunas). O segundo nível é aplicado no coeficiente de aproximação, denominado A1, em que é decomposto em mais quatro sub-bandas, sendo estas representadas por A2, DL2, DCL2 e D2. Ao suceder o terceiro nível, a região A2 é subdivida em mais quatro sub-bandas, sendo constituídas pelas regiões definidas como A3, DL3, DC3 e D3. Desse modo, observa-se que, a partir do primeiro nível, a decomposição ocorre sempre na região correspondente ao coeficiente de aproximação e, a cada nova decomposição da imagem, são produzidas mais quatro sub-bandas, como já dito anteriormente [49, 54, 55, 56].




Figura 2.17: Esquema de decomposição da *wavelet* até o terceiro nível

Na Figura 2.18 (b), exibe-se um exemplo de decomposição de uma imagem, após aplicada a TWD sobre a imagem 2.18 (a). Na região referenciada por A da Figura 2.18 (b), exibe o subespaço amostral referente aos coeficientes de aproximação, que é uma versão de baixa resolução muito semelhante à imagem original e, nas outras regiões, são exibidos os coeficientes de detalhes: das linhas na região DL, das colunas na região DC e de linhas e colunas na região D.

A energia é uma característica muito utilizada para caracterização de texturas e pode ser calculada para cada região decomposta da imagem pela TWD. O cálculo da energia, que pode ser aplicado a cada sub-banda da imagem, é definido pela equação 2.15 [57],

$$\text{EnergiaSb} = \sqrt{\frac{1}{N} \sum_{x,y} (\text{Sb}(x,y))^2} \quad \text{eq. (2.15)}$$

em que, $\text{Sb}(x,y)$ corresponde ao coeficiente da sub-banda na coordenada (x,y) .




Figura 2.18: Exemplo de decomposição de uma imagem. Em (a), Imagem Original e, em (b), imagem resultante, após aplicada a TWD no primeiro nível.

2.7.3 Famílias de Transformadas *Wavelets*

A função *wavelet* e a função de escala (*scaling*), muitas vezes, são denominadas *wavelet*-mãe $\Psi(t)$ e *wavelet*-pai $\Phi(t)$ [49], pois, a partir destas funções, torna-se possível aplicar muitas outras variações, que diferem no suporte dos filtros, nas características de resposta em frequência e na fase dos mesmos. Para encontrar a melhor *wavelet*, foram realizados testes em várias, a saber: *Beylkin*, *Coiflets*, *Daubechies*, *Haar*, *Symmlets* e *Vaidyanathan* [53].

Na Tabela 2.1, estão relacionadas algumas das características destas *wavelets*, em que estão descritos: o nome de sua família, seguido da coluna suporte, que define o número de coeficientes não nulos para cada *wavelet* [52] e a coluna fase que exhibe se a *wavelet* é linear ou não, seguida de uma pequena descrição dada pela coluna de observação.

Na Figura 2.19, é exibido o formato das respostas ao impulso dos filtros de *Haar*, *Daubechies*, *Vaidyanathan*, *Beylkin*, *Coiflets* e *Symmlets*; as quais estão situadas na figura na ordem em que foram citadas. Nota-se que é possível obter sinais diferentes, mudando o coeficiente em que é aplicado a *wavelet*. A escolha de qual função *wavelet* será utilizada, dependerá dos sinais e da informação desejada [49].

Tabela 2.1: Características das famílias de *wavelets* utilizadas neste trabalho (adaptado [53]).

Família	Suporte(n)	Fase	Observação
<i>Haar</i>	2	Linear	é a mais simples das <i>wavelets</i> , criadas por Alfred Haar.
<i>Daubechies</i>	par, maior que 4	não linear	maximamente plana, criadas por Ingrid Daubechies
<i>Vaidyanathan</i>	24	não linear	otimizada para áudio, criada por P. P. Vaidyanathan
<i>Beylkin</i>	18	não linear	otimizada para áudio, criada por G. Beylkin
<i>Coiflets</i>	par, múltiplo de 6	não linear	resposta ao impulso quase simétrica, criadas por Ronald Coifman
<i>Symmlets</i>	par, múltiplo de 8	não linear	resposta ao impulso mais simétrica, criadas também por Ingrid Daubechies.

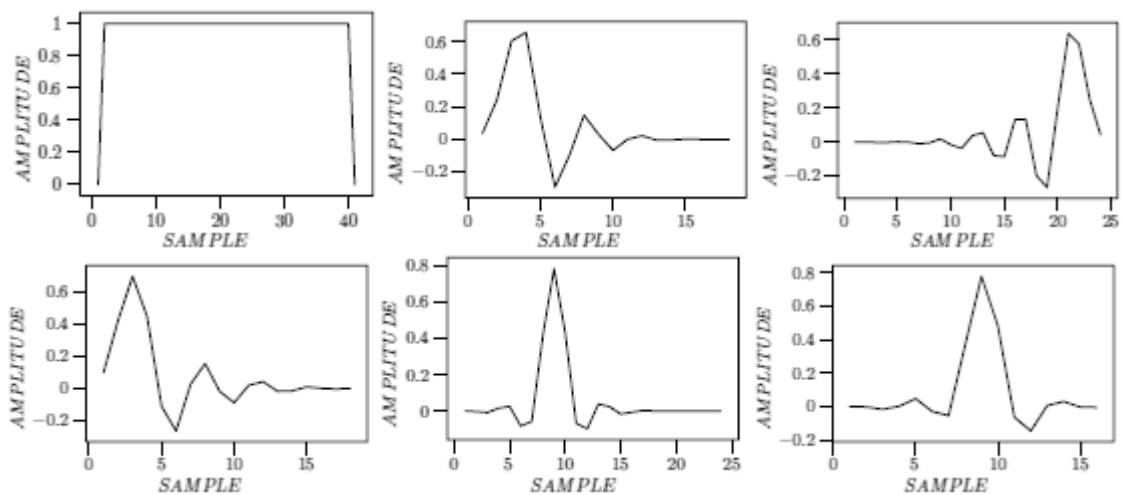


Figura 2.19: Formato das respostas ao impulso dos filtros de *Haar*, *Daubechies*, *Vaidynathan*, *Beylkin*, *Coiflets* e *Symmlets* [53].

Na Figura 2.20, é mostrado o formato das funções de escala (scaling) dos filtros de *Haar*, *Daubechies*, *Vaidynathan*, *Beylkin*, *Coiflets* e *Symmlets*, e cada função está situada na figura, na ordem em que foram citadas.




Figura 2.20: Formato das funções de escala dos filtros de *Haar*, *Daubechies*, *Vaidynathan*, *Beylkin*, *Coiflets* e *Symmlets* [53].

Na Figura 2.21, é exibido o formato das funções *wavelet* dos filtros de *Haar*, *Daubechies*, *Vaidynathan*, *Beylkin*, *Coiflets* e *Symmlets*, e cada função está situada na figura, na ordem em que foram citadas.




Figura 2.21: Formato das funções *wavelet* dos filtros de *Haar*, *Daubechies*, *Vaidynathan*, *Beylkin*, *Coiflets* e *Symmlets* [53].

2.8 Considerações Finais

Neste capítulo apresentou-se um estudo do estado da arte sobre os assuntos relacionados ao trabalho.

CAPÍTULO 3 – MATERIAL E MÉTODOS

Neste capítulo, são discorridas as características e a aquisição das imagens que foram utilizadas neste trabalho, bem como a descrição da forma que foi implementado o sistema proposto, para identificar a existência de doenças em imagens de folhas do algodão. Então, quando detectada a existência de patógenos, é realizada a classificação para rotular em qual dos três tipos de doenças do algodoeiro a que mais se assemelha. O sistema de classificação proposto foi implementado no ambiente integrado de desenvolvimento *Bloodshed Dev-C++* na versão 4.9.9.2, utilizados para aplicações em C e C++ e, para manipulação de imagens, foi usada a biblioteca *OpenCV* versão 1.0 cr.

3.1 Banco de Imagens

Foi obtido o total de 420 imagens da região foliar do algodão de dois bancos de dados diferentes. Uma parte das imagens foi cedida pelo engenheiro agrônomo Dr. Nelson Dias Suassuna, D. Sc. em Fitopatologia, pesquisador da Embrapa Algodão de Campina Grande, da Paraíba [29]. Esse banco foi complementado com outras imagens obtidas do portal Forestry Images [30]. Deste banco foram separadas, manualmente, as regiões foliares, totalizando 420 imagens, as quais 210 são de folhas com regiões sadias e 210 imagens de folhas infectadas com doenças. As imagens das folhas obtidas, que se apresentam lesionadas, estão separadas em três classes de patógenos (Ramulária, Mancha Angular e Mancha de

Ascochyta), possuindo 70 imagens cada. Foi definido para o tamanho da largura e altura de cada imagem números múltiplos de 2, para realizar a decomposição das *wavelets*.

As imagens coletadas possuem tamanho, brilho, contraste e resoluções diferentes, se constituindo num banco muito heterogêneo, o que tornou um problema para realizar a classificação de um elemento entre as classes. Para exemplificar, são exibidas na Figura 3.1, algumas imagens de regiões saudáveis de folhas do algodoeiro, em que é possível notar essas diferenças. Além disso, as imagens das folhas infectadas apresentam vários graus de severidade das doenças, como exemplificado nas imagens exibidas na Figura 3.2, sendo estas pertencentes ao patógeno MA. A Figura 3.2 (a) exibe a região foliar com estágio inicial da doença, sendo observada pelo aparecimento de manchas de aspecto encharcado (úmido), com coloração verde um pouco mais escura. Na Figura 3.2 (b), é mostrada a folha infectada, apresentando o estágio médio da doença, sendo os seus sintomas vistos pelas pequenas manchas marrons, com pequenas regiões amareladas e, na Figura 3.2. (c), nota-se o estágio avançado da doença, pois a região lesionada identificada pela coloração marrom e amarelada está ocupando quase toda a região da folha.



Figura 3.1: Algumas imagens da região foliar sadia do algodoeiro [29, 30].




Figura 3.2: Grau de severidade da doença de MA do algodoeiro. Em (a), exibe região com estágio inicial da doença; em (b) grau médio de infecção e, em (c), estágio avançado da doença [29].

3.2 Decomposição das Imagens

A decomposição da imagem é o primeiro processo que o sistema executou. A imagem que compõe o banco está no formato “jpg”, que é lido no sistema operacional *Windows Vista* pelo modelo de cor RGB, sendo descomposta pelos seus canais R, G e B. A partir desta decomposição, a imagem é transformada para o espaço de cor HSV, para os canais I3a, I3b e em níveis de cinza. Resumidamente, este processo pode ser observado na Figura 3.3, em que uma imagem é decomposta em nove canais diferentes: R, G, B, H, S, V, I3A, I3B e Cinza.




Figura 3.3: Decomposição da imagem em vários canais

3.3 Vetor de Características

Para cada um dos nove canais de cores é criado um vetor de características de dez elementos, sendo, obtido em duas etapas. A primeira etapa refere-se a decomposição pela

Transformada *Wavelet* Discreta (TWD) em três níveis. Quando a imagem é decomposta em três níveis, ela possuirá dez sub-bandas, conforme ilustrado na Figura 3.4. Nota-se nesta figura que cada sub-banda é identificada por um número que está entre 1 e 10. A região A1 e as sub-bandas identificadas por 8, 9 e 10, são geradas pelo primeiro nível de decomposição da TWD. A região A2 e as sub-bandas 5, 6 e 7 referem-se ao nível dois de decomposição e o terceiro nível é formado pelas sub-bandas 1, 2, 3 e 4.




Figura 3.4: Esquema de decomposição da *wavelet*.

Depois de aplicada a TWD até o terceiro nível, segue-se a segunda etapa para compor o vetor de características. Nesta etapa, é calculada a energia da *wavelet* para cada sub-banda, sendo cada valor obtido, inserido no vetor de características que está ilustrado na Figura 3.5. Observa-se nesta figura que o vetor é composto por dez elementos, a qual cada elemento é identificado por um número, sendo, em cada um, armazenado o valor da energia obtida do seu número correspondente da sub-banda ilustrada na Figura 3.4.

Vetor de Caraterísticas	1	2	3	4	5	6	7	8	9	10
-------------------------	---	---	---	---	---	---	---	---	---	----

Figura 3.5: Exemplo de um vetor de características utilizado neste trabalho.

Descreveu-se até o momento, o procedimento para compor “um” vetor de características. Com o objetivo de encontrar o melhor descritor para cada classe, foram calculados, para cada canal de cor, seis coeficientes diferentes, em que foram utilizados, para alguns destes coeficientes, números do suporte diferente, totalizando doze vetores de características. Na tabela 3.1, é exibido o nome do coeficiente da *wavelet*, seguido do número do suporte que foi utilizado e das abreviaturas empregadas neste trabalho, que associa o nome do coeficiente ao número do suporte.

Tabela 3.1: Tabela de coeficiente e número de suportes utilizados neste trabalho

Nome do Coeficiente	Número do Suporte	Abreviatura utilizada
<i>Beylkin</i>	18	Bey18
<i>Coiflets</i>	12 e 30	Coif12 e Coif30
<i>Daubechies</i>	4, 14, 34, 64 e 74	Dau4, Dau14, Dau34, Dau64 e Dau74
<i>Haar</i>	1	<i>Haar</i>
<i>Symmlets</i>	8 e 16	Sym8 e Sym16
Vaidyanathan	24	Vai24

Na Figura 3.6, estão relacionados os vetores de características criados para o canal de cor R, em que esse canal foi decomposto até o terceiro nível pelas *wavelets* Bey18, Coif12, Coif30, Dau4, Dau14, Dau34, Dau64, Dau76, *Haar*, Sym8 e Vai24, totalizando 12 vetores. O mesmo procedimento foi realizado para os outros canais, obtendo, para cada imagem, 108 vetores de características diferentes, adquiridos dos 9 canais combinados com os 12 coeficientes das *wavelets* diferentes.

R_Bey18	1	2	3	4	5	6	7	8	9	10
R_Coif12	1	2	3	4	5	6	7	8	9	10
R_Coif30	1	2	3	4	5	6	7	8	9	10
R_Daub4	1	2	3	4	5	6	7	8	9	10
R_Daub14	1	2	3	4	5	6	7	8	9	10
R_Daub34	1	2	3	4	5	6	7	8	9	10
R_Daub64	1	2	3	4	5	6	7	8	9	10
R_Daub76	1	2	3	4	5	6	7	8	9	10
R_Haar	1	2	3	4	5	6	7	8	9	10
R_Sym8	1	2	3	4	5	6	7	8	9	10
R_Sym16	1	2	3	4	5	6	7	8	9	10
R_Vaidy	1	2	3	4	5	6	7	8	9	10

Figura 3.6: Vetores de características criados somente para o canal de cor R

3.4 Ambiente MVS

A técnica de classificação utilizada neste trabalho é a MVS (Máquina de Vetor de Suporte), em que a arquitetura da rede usada está exibida na Figura 3.7. Nota-se nesta figura que são usados 10 elementos de entrada, sendo atribuído, para cada um, o valor do elemento do vetor de características correspondente a seu número. Na camada oculta ou intermediária, há um número de neurônios igual ao número de exemplos de treinamento representada pela letra N, o que facilita a convergência da rede [42, 44]. A função de mapeamento da rede (núcleo ou kernel) utilizada foi a Gaussiana.

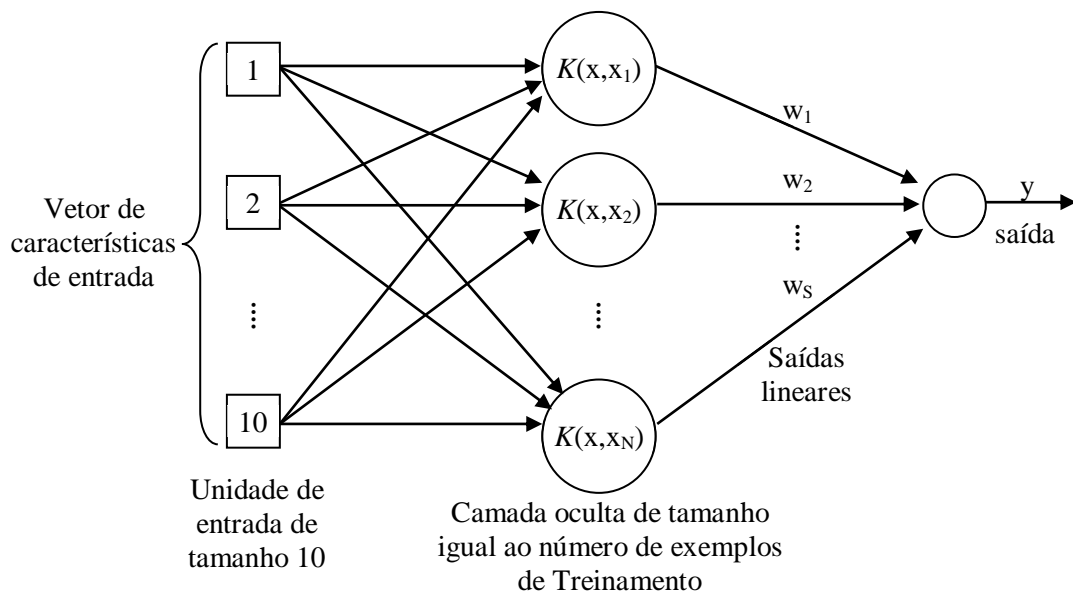


Figura 3.7: Arquitetura da MVS utilizada neste trabalho

Para avaliar a exatidão do método proposto, é separada uma parte das imagens (seus vetores de características) para o treinamento e outra parte para realizar os testes. Vale ressaltar que, na fase de treinamento, para cada entrada existe uma saída correspondente, conhecida como abordagem supervisionada de treinamento, sendo esta identificada com o valor 1 para especificar que o elemento faz parte da classe ou -1, para definir que o elemento não faz parte da classe. Esta foi a forma de implementação da MVS utilizada neste trabalho, em que utiliza apenas uma rede.

Quando é necessário classificar um elemento entre duas ou mais classes, que é o caso deste trabalho, é possível realizar a classificação de outra forma. Por exemplo, caso seja necessário classificar um elemento entre duas classes, então, será criado um sistema de

classificação que irá conter duas redes, sendo uma para cada classe. Cada rede é treinada independentemente da outra. A Figura 3.8 exemplifica o processo de classificação, sendo R1 a rede treinada pertencente à classe 1 e R2 a rede treinada referindo-se à classe 2. Para realizar a classificação, o mesmo elemento percorrerá as duas redes, gerando dois números: o n1 da R1 e n2 da R2. Caso a variável resposta n1 for mais próximo de 1, do que a variável de resposta n2, então o elemento foi classificado pertencente a classe 1, senão será classificado como n2. Desse modo, o elemento sempre será classificado pertencente à classe cujo número obtido for mais próximo do número 1, que é a resposta ideal para identificar que o elemento pertencente à classe, como foi especificado na fase de treinamento.




Figura 3.8: Exemplo do sistema de classificação MVS entre duas classes

Quando existe mais de duas classes, serão avaliados qual dentre todos os resultados mais se aproximam do número 1, sendo este considerado pertencente a classe.

3.5 Uso da MVS para Classificação de Imagens

O processo de classificação foi dividido em duas etapas diferentes, sendo a primeira responsável em rotular se a imagem da folha está sadia (SA) ou lesionada (LE). A segunda será realizada somente entre os três tipos de patógenos (RA, MA e AS), em que uma imagem será identificada como pertencente a uma dessas doenças. Dessa forma, foi possível encontrar o melhor descritor (vetor de características) que representou cada classe.

3.5.1 Descrição da Etapa de Classificação entre as Classes SA e LE

Nesta etapa, foi criado um sistema de classificação MVS, composto por duas redes, em que uma refere-se à classe SA e a outra à classe LE. Na Tabela 3.2, é exibida a relação de imagens que foram utilizadas para treinamento e teste dessa etapa, tendo, no total, 420 imagens, sendo 210 pertencentes a cada classe (folhas saudáveis e lesionadas). Para cada classe, 105 imagens foram usadas para compor o vetor de características, para realizar o treinamento e 105 foram usadas para os testes.

Tabela 3.2: Relação de imagens que são utilizadas para o treinamento e teste no sistema de classificação MVS entre as classes SA e LE

Etapa 1 de classificação			
Imagens	Saudáveis	Lesionadas	Total
Amostras	105	105	210
Teste	105	105	210
Total	210	210	420

Com a pretensão de encontrar o vetor de características que melhor represente a separação dessas classes, foram criados 108 sistemas de classificação MVS diferentes, sendo estes originados da combinação dos nove canais e dos doze coeficientes *wavelets*. Os resultados estão exibidos no capítulo de resultados na seção 4.1.1, deste trabalho.

3.5.2 Descrição da Etapa de Classificação entre as Classes RA, MA e AS

Nesta etapa, foi criado um sistema de classificação MVS, composto por três redes. A primeira rede refere-se à classe RA, a segunda à classe MA e a terceira à classe AS. Na Tabela 3.3, é exibida a relação de imagens que são utilizadas para treinamento e teste dessa etapa, tendo, no total, 210 imagens, sendo 70 pertencentes a cada classe (RA, MA e AS). Para cada classe, 35 imagens são usadas para compor o vetor de características, para realizar o treinamento e 35 são usadas para os testes.

Tabela 3.3: Relação de imagens que são utilizadas para o treinamento e teste no sistema de classificação MVS entre as classes RA, MA e AS

Etapla 2 de Classificação				
Imagens	RA	MA	AS	Total
Amostras	35	35	35	105
Teste	35	35	35	105
Total	70	70	70	210

Com a pretensão de encontrar o vetor de características que melhor represente a separação dessas classes, foram criados 108 sistemas de classificação MVS diferentes, sendo estes originados da combinação dos nove canais e dos doze coeficientes das *wavelets*. Os resultados estão exibidos na seção 4.1.2, deste trabalho.

3.6 Escolha da MVS de Melhor Desempenho

Na seção 4.1, são exibidas as porcentagens de acertos dos 108 vetores de características entre as classes SA e LE, seguidas da porcentagem de acertos entre as classes RA, MA e AS. A importância dessa fase, nesta pesquisa, foi identificar o vetor de características que melhor representasse, primeiramente, as duas classes SA e LE, depois, as classes RA, MA e AS. Portanto, foram observados os resultados dos testes e os melhores são listados na Tabela 3.4, na qual é exibido o nome da classe, o canal, o coeficiente e a porcentagem de acerto. Entre as classes SA e LE, o melhor vetor de características que separou as duas classes foi no canal H, usando a *wavelet* Vai24, em que, na classe AS, atingiu 96,2% de acerto e, na LE, 100% de acerto. Estes resultados foram extraídos da Tabela 4.4. Na classe MA, o melhor resultado foi no canal I3b, nos coeficientes Coi12, Sym16, em que atingiu 97,1% de acertos, foram obtidos estes resultados da Tabela 4.17. Para a classe RA, atingiram-se 88,6% de acertos, utilizando o vetor de características do canal H e da *wavelet* Dau4, resultado retirado na Tabela 4.13. Nesta mesma tabela, foi visto que a classe AS obteve o melhor resultado, atingindo, também, 88,6% de precisão, no canal H, porém o coeficiente foi a *wavelet* Bey18.

Tabela 3.4: Melhores resultados obtidos entre as classes

Nome da Classe	Canal	Coefficiente	Porcentagem de Acerto
SA	H	Vai24	96,2%
LE	H	Vai24	100%
MA	I3b	Coi12 e Sym16	97,1%
RA	H	Dau4	88,6%
AS	H	Bey18	88,6%

3.7 Processo de Treinamento e de Teste Usando a MVS

Na seção anterior, foram identificados os melhores descritores para cada classe. Portanto, nesta seção, é descrita a metodologia para compor o sistema final de classificação, em que se criou uma estrutura usando MVS que combina os melhores resultados para cada classe. A estrutura do sistema de classificação está ilustrada de forma simplificada na Figura 3.9, em que, primeiramente, a imagem da folha será rotulada entre SA e LE. Caso indique que a imagem pertença a classe LE, então, a imagem irá passar pela segunda fase, a qual a imagem percorrerá os outros três sistemas MA ou “não MA”, RA ou “não RA”, AS ou “não AS”. Depois de realizado este processo, a imagem do sistema de classificação faz o diagnóstico final, em que classifica a imagem entre uma das classes SA, MA, RA, AS ou não pertencente a nenhuma das classes. Este processo de classificação será detalhado no decorrer deste capítulo.

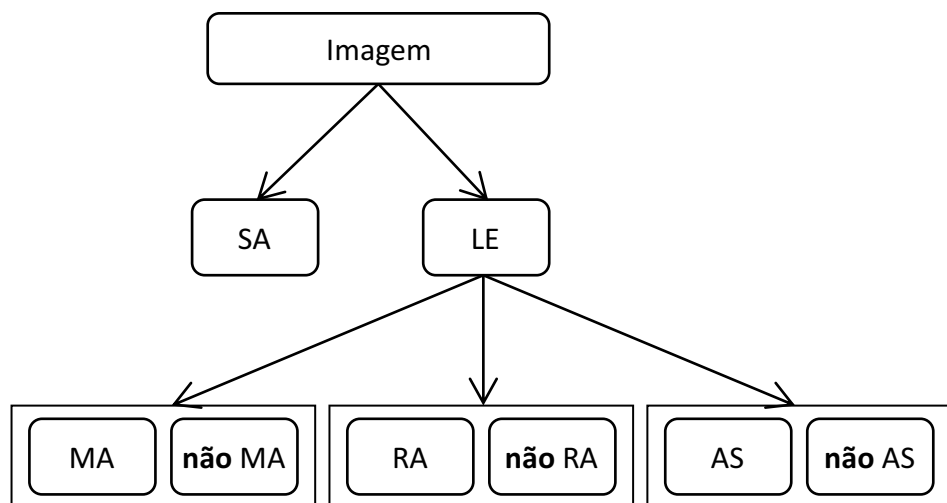


Figura 3.9: Estrutura simplificada do sistema geral de classificação

3.7.1: Estrutura Geral de Classificação

Na Figura 3.10, está ilustrada a estrutura geral de classificação. Observa-se que foram criados quatro sistemas de classificação diferentes, um para cada classe. Cada sistema foi treinado e testado com os melhores vetores de características, conforme discutidos na seção 3.5. As descrições desta figura são feitas em cada sistema de classificação, sendo estes, relacionados na Figura 3.10.

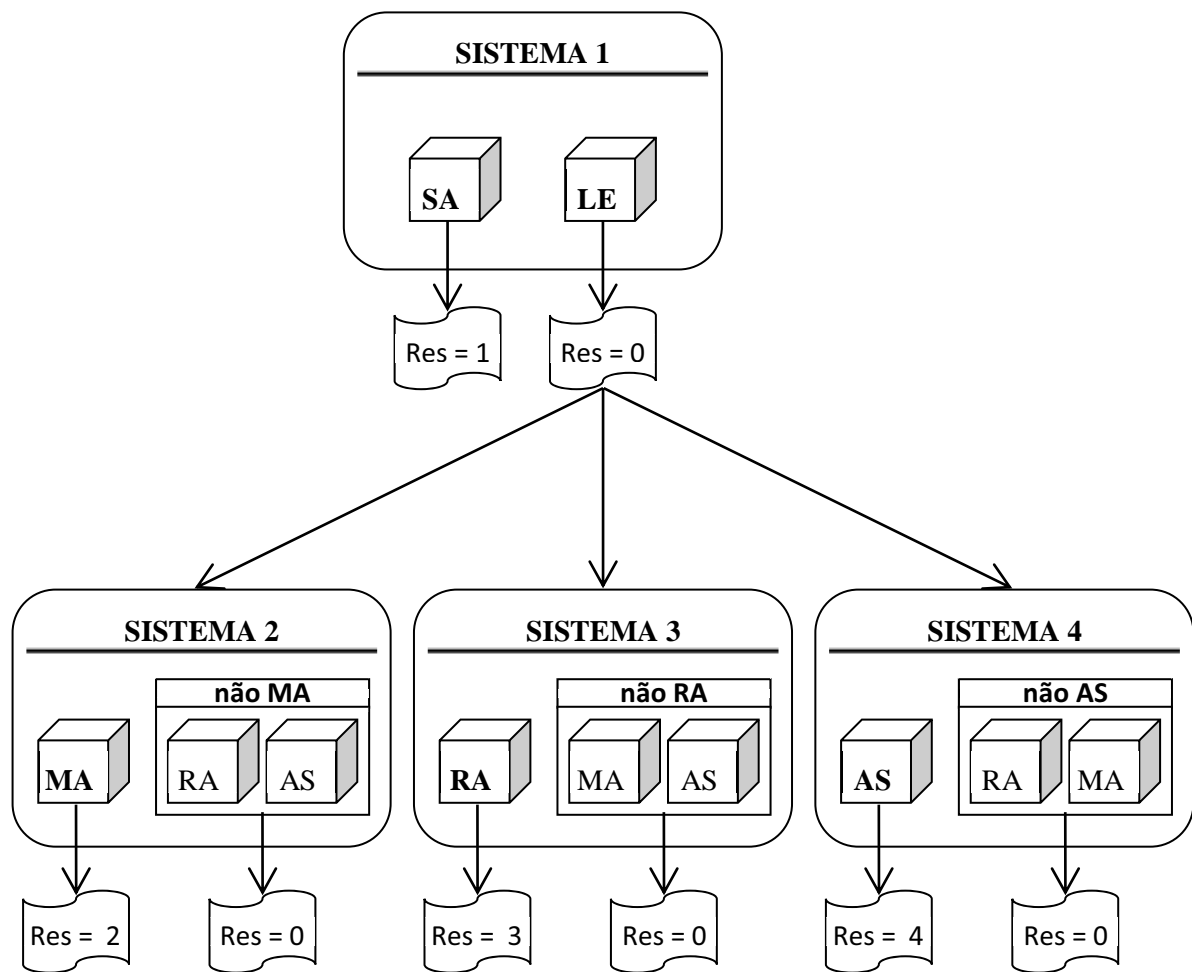


Figura 3.10: Estrutura geral de classificação

- Sistema 1

O Sistema 1 refere-se ao sistema de classificação MVS que objetiva separar as imagens de folhas em sadias e lesionadas. Para isso, foram criadas duas redes, a SA e a LE, ambas treinadas e testadas com o canal H, aplicando a *wavelet* Vai4, conforme exibidos na

Tabela 3.5. Nesta tabela, são também exibidas as relações de imagens utilizadas, totalizadas em 420 imagens, destas, 210 pertencem a cada classe (SA e LE). Para cada classe, 105 imagens foram usadas para os testes e 105 para o treinamento. Durante o teste, quando a imagem for classificada como SA, então, será retornado como resposta o número 1, de acordo com a indicação da seta que está ligada à rede sadia direcionada para o número de resposta 1. Quando a imagem for classificada como LE, a mesma imagem percorrerá os outros três sistemas (Sistema 2, Sistema 3 e Sistema 4).

Tabela 3.5: Relação dos canais utilizados para constituir o conjunto de vetores de características e das imagens que são utilizadas para o treinamento e teste no Sistema 1.

Sistema 1 de classificação			
Canal	H		
Coeficiente	Vai4		
Imagens	Sadias	Lesionadas	Total
Amostras	105	105	210
Teste	105	105	210
Total	210	210	420

- Sistema 2

O vetor de características da imagem irá percorrer o Sistema 2 quando for classificada como LE no Sistema 1. O Sistema 2 refere-se ao sistema de classificação MVS que objetiva separar as imagens de folhas lesionadas com MA, da “não MA” (RA e AS). Para isso, foram criadas três redes, cada uma treinada com o conjunto de vetores de características pertencente a sua classe (MA, RA e AS), no canal I3a, aplicando a *wavelet* Coif12, sendo seus dados exibidos na Tabela 3.6. Nesta tabela, são também exibidas as relações de imagens utilizadas, totalizadas em 210 imagens, destas, 70 pertencem a cada classe (MA, RA e AS). Para cada classe, 35 imagens foram usadas para os testes e 35 para o treinamento.

Durante o teste, quando a imagem for classificada como sendo da classe MA, então, será retornado como resposta o número de resposta 2, de acordo com a indicação da seta que está ligada à rede MA direcionada para o número 2. Vale ressaltar que, neste sistema de classificação, o objetivo é distinguir as imagens lesionadas por MA das outras, por isso, quando a imagem for classificada como pertencente a RA ou AS, será retornado o número 0, significando que a imagem não pertence à classe MA.

Tabela 3.6: Relação dos canais utilizados para constituir o conjunto de vetores de características e das imagens que são utilizadas para o treinamento e teste no Sistema 2.

Sistema 2 de classificação				
Canal	I3b			
Coeficiente	Coi12			
Imagens	MA	Não MA		Total
		RA	AS	
Amostras	35	35	35	105
Teste	35	35	35	105
Total	70	70	70	210

- Sistema 3

O vetor de características da imagem irá percorrer o Sistema 3 quando for classificada como LE no Sistema 1. O Sistema 3 refere-se ao sistema de classificação MVS que objetiva separar as imagens de folhas lesionadas com RA, das não RA (MA e AS). Para isso, foram criadas três redes, cada uma treinada com o conjunto de vetores de características pertencentes a sua classe (RA, MA e AS), no canal H, aplicando o *wavelet* Dau4, sendo seus dados exibidos na Tabela 3.7. Nesta tabela, são também exibidas as relações de imagens utilizadas, totalizadas em 210 imagens, destas, 70 pertencem a cada classe (RA, MA e AS). Para cada classe, 35 imagens foram usadas para os testes e 35 para o treinamento.

Durante o teste, quando a imagem for classificada como sendo da classe RA, então, será retornado como resposta o número de resposta 3, de acordo com a indicação da seta que está ligada à rede RA direcionada para o número 3. Vale ressaltar que, neste sistema de classificação o objetivo é distinguir as imagens lesionadas por RA das outras, por isso, quando a imagem for classificada como pertencente a MA ou AS retornou 0, definindo que a imagem não pertence à classe RA.

Tabela 3.7: Relação dos canais utilizados para constituir o conjunto de vetores de características e das imagens que são utilizadas para o treinamento e teste no Sistema 3.

Sistema 3 de classificação				
Canal	H			
Coeficiente	Dau4			
Imagens	RA	Não RA		Total
		MA	AS	
Amostras	35	35	35	105
Teste	35	35	35	105
Total	70	70	70	210

- Sistema 4

O vetor de características da imagem irá percorrer o Sistema 4 quando for classificada como LE no Sistema 1. O Sistema 4 refere-se ao sistema de classificação MVS que objetiva separar as imagens das folhas lesionadas com AS, das “não AS” (MA e RA). Para isso, foram criadas três redes, cada uma treinada com o conjunto de vetores de características pertencentes a sua classe (AS, MA e RA), no canal H, aplicando a *wavelet* Bey18, sendo seus dados exibidos na Tabela 3.8. Nesta tabela, são também exibidas às relações de imagens utilizadas, totalizadas em 210 imagens, destas, 70 pertencem a cada classe (AS, MA e RA). Para cada classe, 35 imagens foram usadas para os testes e 35 para o treinamento.

Durante o teste, quando a imagem for classificada como sendo da classe AS, então, será retornada como resposta o número 4, de acordo com a indicação da seta que está ligada à rede AS direcionada para o número de resposta 4. Vale ressaltar que, neste sistema de classificação, o objetivo é distinguir as imagens lesionadas por AS das outras, por isso, quando a imagem for classificada como pertencente a MA ou RA retornará 0, definindo que a imagem não pertence à classe AS.

Tabela 3.8: Relação dos canais utilizados para constituir o conjunto de vetores de características e das imagens que são utilizadas para o treinamento e teste no Sistema 4.

Sistema 4 de classificação				
Canal	H			
Coeficiente	Bey18			
Imagens	AS	Não AS		Total
		MA	Ra	
Amostras	35	35	35	105
Teste	35	35	35	105
Total	70	70	70	210

3.7.2: Composição dos Vetores de Características para Realizar os Testes

Depois de desenvolvido o sistema de classificação MVS, será percorrido nesta seção a forma como foram constituídos os conjuntos vetores de características para realizar os testes. A Figura 3.11 faz uma representação da composição de um conjunto de vetores de características, em que é constituído por 210 linhas, sendo, cada linha um descritor de uma

imagem, composta por 10 colunas, correspondentes à energia das dez sub-bandas da decomposição da imagem pela *wavelet* até o terceiro nível, a qual a sua descrição está na seção 3.3 deste trabalho. Nota-se ainda, na Figura 3.11, que o vetor possui 105 imagens de folhas saudáveis e 105 imagens de folhas lesionadas, sendo estas agrupadas pelos patógenos MA, RA e AS, contendo 35 imagens cada um. As 105 primeiras linhas do conjunto de vetores de características referem-se à classe SA. As linhas 106 a 140 correspondem aos descritores para os testes da MA; as linhas 141 a 175 referem-se à classe RA e as linhas 176 a 210 pertencem à classe AS.

LE	SA	img 1	1	2	3	4	5	6	7	8	9	10
		img 2	1	2	3	4	5	6	7	8	9	10
		⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
	MA	img 105	1	2	3	4	5	6	7	8	9	10
		img 106	1	2	3	4	5	6	7	8	9	10
		⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
	RA	img 140	1	2	3	4	5	6	7	8	9	10
		img 141	1	2	3	4	5	6	7	8	9	10
		⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
	AS	img 175	1	2	3	4	5	6	7	8	9	10
		img 176	1	2	3	4	5	6	7	8	9	10
		⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
		img 210	1	2	3	4	5	6	7	8	9	10

Figura 3.11: Representação de um conjunto de vetores de características utilizado na fase de testes

Foi exemplificada a composição de um conjunto de vetores de características para realizar os testes, porém, foram criados 4 conjuntos de vetores, um para cada sistema de classificação, sendo estes, identificados como Vet1, Vet2, Vet3 e Vet4. Para melhor explicar cada um desses vetores, foram dispostos os seus dados na Tabela 3.9, em que são mostrados o nome do vetor, a classe a que pertence, o canal em que foi obtido e o nome da *wavelet* aplicada. O Vet1 foi utilizado no Sistema 1 de classificação MVS, que tem a função de definir para cada vetor de características, encontra-se “sadio” ou não. Os seus descritores foram obtidos com o mesmo tipo de canal e da *wavelet* do Sistema 1 de classificação MVS, sendo utilizados, para sua aquisição, o canal H e a *wavelet* Vai24. Da mesma forma, são constituídos os outros vetores, sendo o Vet2 utilizado no Sistema 2 de classificação MVS, constituídos a partir do canal I3b e da *wavelet* Coi12, cujo objetivo é identificar as imagens pertencentes à classe MA. O Vet3 foi utilizado no Sistema 3 de classificação MVS,

constituídos a partir do canal H e da *wavelet* Dau4, tendo como meta identificar as imagens pertencentes à classe RA e, por fim, o Vet4 foi utilizado para classificar os elementos da AS, utilizado no Sistema 4 de classificação MVS, também constituído pelo canal H, mas a *wavelet* utilizada foi a Bey18.

Tabela 3.9: Descrição dos vetores de características

Nome do Vetor	Sistema de Classificação	Canal	Coefficiente
Vet1	Sistema 1	H	Vai24
Vet2	Sistema 2	I3b	Coi12
Vet3	Sistema 3	H	Dau4
Vet4	Sistema 4	H	Bey18

3.7.3: Descrição dos Vetores que Armazenaram os Resultados

Descritos o sistema geral de classificação e a composição dos quatro conjuntos de vetores de características, será exposta nesta seção a forma de obtenção dos resultados. Vale ressaltar que, cada conjunto de vetores de características terá um vetor de resposta, cuja quantidade de posições é igual ao número de linhas dos vetores de características (210 posições), em que cada posição deste vetor foi inserido o valor de resposta de cada linha (vetor de características). Desta forma, foram quatro vetores de respostas criados, sendo identificados como Res1, Res2, Res3 e Res4. Na Tabela 3.10, são exibidos os nomes dos vetores de respostas, os nomes dos conjuntos de vetores de características, os sistemas de classificações de redes MVS utilizados, os tipos de respostas e as descrições dos tipos de respostas. O Res1 armazenou a resposta obtida de cada vetor de características do Vet1, em que foi armazenado o número 1, quando a imagem foi classificada pertencente à classe SA e pelo número 0 quando a imagem pertence à classe LE. O Res2 foi utilizado para armazenar resposta dos vetores de características do Vet2, a qual é identificada uma imagem pertencente à classe MA, armazenando, como resposta, o número 2 e, caso contrário, é armazenado o número 0 para esta imagem. No Res3, foi armazenado o resultado obtido das imagens do Vet3, em que foi definido para o resultado, a atribuição do número 3, quando a imagem for classificada como sendo RA e pelo número 0 quando não for classificada como RA. No Res4, foram atribuídos os resultados gerados dos vetores de características do Vet4, em que foi

definido para armazenar o número 4, quando identificada esta imagem pertencente à classe AS e pelo número 0 quando não pertencente.

Tabela 3.10: Descrição dos vetores de respostas

Vetor de Resposta	Vetor de características	Sistema de Classificação	Tipos de Respostas	Descrição da Resposta
Res1	Vet1	Sistema1	1	quando classificado como SA
			0	quando classificado como LE
Res2	Vet2	Sistema2	2	quando classificado como MA
			0	quando classificado como não MA
Res3	Vet3	Sistema3	3	quando classificado como RA
			0	quando classificado como não RA
Res4	Vet4	Sistema4	4	quando classificado como AS
			0	quando classificado como não AS

3.7.4: Forma de Obtenção da Tabela de Resultados a Partir do Conjunto de Vetores de Características

Nesta seção, são descritos os procedimentos que foram utilizados para obter os resultados de cada vetor de resposta. Esses resultados são exibidos na Tabela 4.19.

Para explanação dos testes, será feito uso novamente da Figura 3.10, para melhor compreensão desta etapa. Para auferir os resultados, primeiramente, foi utilizado o vetor de características Vet1, em que cada vetor de características de uma imagem percorreu o Sistema 1 de classificação MVS, a qual foi armazenado no vetor de resposta Res1 o resultado dessa classificação, sendo atribuído o número 1, quando rotulado que a imagem pertence à classe SA e atribuído o número 0 para a classe LE. Quando o vetor de características da imagem for classificado como SA, nessa mesma posição, foi atribuído o valor 0 para os outros vetores de resposta (Res2, Res3 e Res4). Por exemplo, ao observar imagem 1 da Tabela 4.19, na coluna Res1, o número está 1. Isto significa que a imagem foi classificada como SA, então, automaticamente os, outros vetores de respostas Res2, Res3 e Res4, nesta mesma posição da imagem, receberam o número 0.

Quando uma imagem do vetor de resposta Res1 retornar 0 (imagem considerada lesionada), ela irá percorrer o Sistema 2, Sistema 3 e Sistema 4 de classificação MVS, conforme ilustrado na Figura 3.10, em que as setas ligadas a resposta da rede LE estão direcionadas para cada um desses sistemas de classificação MVS.

Depois que um vetor de características de uma imagem foi classificado sendo LE, esse vetor será substituído pelo vetor de características Vet2 de mesma posição, ou seja, caso a imagem 1 seja classificada como lesionada, será obtido o vetor de características da imagem 1 do conjunto de vetores de características Vet2. Isto se deve, porque o vetor de características deve ser obtido do mesmo canal e coeficiente do Sistema de classificação MVS que foi treinado. Vale lembrar que cada sistema de classificação usado neste trabalho é treinado com a combinação de canal e *wavelet* diferente. Portanto, esse mesmo procedimento ocorreu toda vez que o teste, para a mesma imagem, for realizado em outro sistema de classificação MVS.

O vetor de características, ao percorrer o Sistema 2 de classificação MVS, foi obtida uma posição do vetor resultado Res2, em que está armazenado o diagnóstico das imagens pertencentes à classe MA, identificadas com o número 2 e pelo número 0 quando não classificadas como MA. Depois de percorrido o Sistema 2, esse vetor de características passou pelo Sistema 3, em que foram detectadas as imagens classificadas como RA, em que foi atribuído o vetor de resposta Res3, o número 3 para as imagens classificadas como RA e pelo número 0 quando não classificadas. O mesmo ocorre no Sistema 4 de classificação MVS, em que a imagem é classificada pertencente à classe AS, atribuída ao vetor de resposta Res4, o número 4 e, quando não pertencente, foi atribuído o número 0. Os resultados dos vetores de respostas Res1, Res2, Res3 e Res4 estão exibidos na Tabela 4.19, na coluna correspondente ao seu nome.

3.8 Considerações Finais

Com esta avaliação pode-se escolher o conjunto que apresentou melhor desempenho para cada caso de identificação de doenças foliares no algodoeiro.

CAPÍTULO 4 – RESULTADOS DOS TESTES COM A MVS

Neste capítulo, são exibidas as porcentagens de acertos dos 108 vetores de características para distinguir uma imagem sendo pertencente à classe SA ou LE e dos 108 vetores de características para classificação de uma imagem entre as classes RA, MA e AS. Depois, são descritas as metodologias adotadas para compor o sistema final de classificação, os resultados obtidos, os critérios utilizados para a classificação final em que, rotula uma imagem como sendo pertencente a classe SA, MA, RA, AS ou pertencente a nenhuma das classes. E por fim, são exibidos os resultados finais da classificação, seguida de uma breve exibição dos resultados obtidos por outros autores em outros cultivares.

4.1 Resultados da Classificação MVS

Nesta seção, são exibidas as porcentagens de acertos dos 108 vetores de características em que, foi encontrado o melhor vetor de características que distinguiu as imagens entre as classes SA e LE. Depois são exibidas as porcentagens de acertos dos 108 vetores de características das classes RA, MA e AS.

4.1.1 Exibição dos Resultados da Etapa de Classificação entre as Classes SA e LE

Com a pretensão de encontrar o vetor de características que melhor represente a separação das classes SA e LE, foram criados 108 sistemas de classificação MVS diferentes, sendo estes originados da combinação dos nove canais e dos doze coeficientes *wavelets*. A seguir, serão exibidas as tabelas que possuem porcentagens de acertos, seguidas de seus gráficos.

Na Tabela 4.1, é exibida a relação de acertos do canal R, obtida em cada *wavelet*, para as classes SA e LE. Nota-se que a melhor porcentagem de acerto para a classe SA foi 94,3% atingido pela *wavelet* de *Haar* e o melhor resultado da classe LE foi na *wavelet* *Coi30* e *Dau34* com 75,2% de acertos. Para melhor visualização desta tabela, é exibido o seu gráfico na Figura 4.1, em que o eixo x refere-se aos coeficientes das *wavelets* e o eixo y refere-se à taxa de porcentagem de acerto, que pode variar entre 0% e 100%.

Tabela 4.1: Relação de acertos do canal R de cada *wavelet* utilizada neste trabalho

Canal R												
Classe	Bey18	Coi12	Coi30	Dau4	Dau14	Dau34	Dau64	Dau76	Haar	Sym8	Sym16	Vai24
SA	83,8%	85,7%	84,8%	86,7%	86,7%	84,8%	84,8%	84,8%	94,3%	86,7%	85,7%	84,8%
LE	71,4%	70,5%	75,2%	72,4%	72,4%	75,2%	70,5%	70,5%	69,5%	69,5%	66,7%	73,3%




Figura 4.1: Gráfico referente à porcentagem de acertos do canal R obtido em cada *wavelet* utilizada neste trabalho

Na Tabela 4.2, é exibida a relação de acertos do canal G, obtida em cada *wavelet*, para as classes SA e LE. Nota-se que a melhor porcentagem de acerto para a classe SA foi 80% atingido pela *wavelet* de *Haar* e o melhor resultado da classe LE foi na *wavelet* *Vai24*

com 79% de acertos. Para melhor visualização desta tabela, é exibido o seu gráfico na Figura 4.2, em que o eixo x refere-se aos coeficientes das *wavelets* e o eixo y refere-se à taxa de percentagem de acerto, que pode variar entre 0% e 100%.

Tabela 4.2: Relação de acertos do canal G de cada *wavelet* utilizada neste trabalho

Canal G												
Classe	Bey18	Coi12	Coi30	Dau4	Dau14	Dau34	Dau64	Dau76	Haar	Sym8	Sym16	Vai24
SA	75,2%	76,2%	75,2%	76,2%	73,3%	73,3%	76,2%	76,2%	80,0%	79,0%	73,3%	77,1%
LE	77,1%	75,2%	75,2%	72,4%	77,1%	75,2%	78,1%	78,1%	69,5%	73,3%	73,3%	79,0%




Figura 4.2: Gráfico referente à percentagem de acertos do canal G obtido em cada *wavelet* utilizada neste trabalho

Na Tabela 4.3, é exibida a relação de acertos do canal B, obtida em cada *wavelet*, para as classes SA e LE. Nota-se que a melhor percentagem de acerto para a classe SA foi 79% atingido pela *wavelet* de Dau4 e o melhor resultado da classe LE foi na *wavelet* Coi12 com 72,4% de acertos. Para melhor visualização desta tabela, é exibido o seu gráfico na Figura 4.3, em que o eixo x refere-se aos coeficientes das *wavelets* e o eixo y refere-se à taxa de percentagem de acerto, que pode variar entre 0% e 100%.

Tabela 4.3: Relação de acertos do canal B de cada *wavelet* utilizada neste trabalho

Canal B												
Classe	Bey18	Coi12	Coi30	Dau4	Dau14	Dau34	Dau64	Dau76	Haar	Sym8	Sym16	Vai24
SA	78,1%	76,2%	75,2%	79,0%	77,1%	77,1%	78,1%	78,1%	75,2%	75,2%	76,2%	78,1%
LE	71,4%	72,4%	67,6%	71,4%	68,6%	70,5%	69,5%	69,5%	69,5%	71,4%	65,7%	70,5%




Figura 4.3: Gráfico referente à porcentagem de acertos do canal B obtido em cada *wavelet* utilizada neste trabalho

Na Tabela 4.4, é exibida a relação de acertos do canal H, obtida em cada *wavelet*, para as classes SA e LE. Nota-se que os resultados mais promissores ocorreram neste canal, em que a melhor porcentagem de acerto para a classe SA foi 97,1% atingido pela *wavelet* de Sym8 e o melhor resultado da classe LE foi na *wavelet* Vai24 com 100% de acertos. Para melhor visualização desta tabela, é exibido o seu gráfico na Figura 4.4, em que o eixo x refere-se aos coeficientes das *wavelets* e o eixo y refere-se à taxa de porcentagem de acerto, que pode variar entre 0% e 100%.

Tabela 4.4: Relação de acertos do canal H de cada *wavelet* utilizada neste trabalho

Canal H												
Classe	Bey18	Coi12	Coi30	Dau4	Dau14	Dau34	Dau64	Dau76	Haar	Sym8	Sym16	Vai24
SA	92,4%	95,2%	94,3%	93,3%	90,5%	96,2%	96,2%	96,2%	94,3%	97,1%	91,4%	96,2%
LE	99,0%	99,0%	99,0%	96,2%	99,0%	99,0%	96,2%	96,2%	99,0%	97,1%	98,1%	100,0%




Figura 4.4: Gráfico referente à porcentagem de acertos do canal H obtido em cada *wavelet* utilizada neste trabalho

Na Tabela 4.5, é exibida a relação de acertos do canal S, obtida em cada *wavelet*, para as classes SA e LE. Nota-se que a melhor porcentagem de acerto para a classe SA foi 84,8% atingido pela *wavelet* de *Haar* e o melhor resultado da classe LE foi também na *wavelet Haar* com 73,3% de acertos. Para melhor visualização desta tabela, é exibido o seu gráfico na Figura 4.5, em que o eixo x refere-se aos coeficientes das *wavelets* e o eixo y refere-se à taxa de porcentagem de acerto, que pode variar entre 0% e 100%.

Tabela 4.5: Relação de acertos do canal S de cada *wavelet* utilizada neste trabalho

Canal S												
Classe	Bey18	Coi12	Coi30	Dau4	Dau14	Dau34	Dau64	Dau76	Haar	Sym8	Sym16	Vai24
SA	79,0%	79,0%	80,0%	82,9%	81,9%	80,0%	78,1%	78,1%	84,8%	81,9%	78,1%	81,9%
LE	65,7%	69,5%	67,6%	61,0%	65,7%	64,8%	63,8%	63,8%	73,3%	66,7%	62,9%	61,9%




Figura 4.5: Gráfico referente à porcentagem de acertos do canal S obtido em cada *wavelet* utilizada neste trabalho

Na Tabela 4.6, é exibida a relação de acertos do canal V, obtida em cada *wavelet*, para as classes SA e LE. Nota-se que a melhor porcentagem de acerto para a classe SA foi 79% atingido pela *wavelet* de Coi12 e o melhor resultado da classe LE foi também na *wavelet Coi12* com 84,8% de acertos. Para melhor visualização desta tabela, é exibido o seu gráfico na Figura 4.6, em que o eixo x refere-se aos coeficientes das *wavelets* e o eixo y refere-se à taxa de porcentagem de acerto, que pode variar entre 0% e 100%.

Tabela 4.6: Relação de acertos do canal V de cada *wavelet* utilizada neste trabalho

Canal V												
Classe	Bey18	Coi12	Coi30	Dau4	Dau14	Dau34	Dau64	Dau76	Haar	Sym8	Sym16	Vai24
SA	75,2%	79,0%	74,3%	75,2%	75,2%	74,3%	75,2%	75,2%	75,2%	77,1%	73,3%	74,3%
LE	80,0%	84,8%	79,0%	78,1%	79,0%	79,0%	79,0%	79,0%	74,3%	81,0%	75,2%	79,0%




Figura 4.6: Gráfico referente à porcentagem de acertos do canal V obtido em cada *wavelet* utilizada neste trabalho

Na Tabela 4.7, é exibida a relação de acertos do canal I3a, obtida em cada *wavelet*, para as classes SA e LE. Nota-se que a melhor porcentagem de acerto para a classe SA foi 86,7% atingido pela *wavelet* de *Haar* e o melhor resultado da classe LE foi também na *wavelet Haar* com 75,2% de acertos. Para melhor visualização desta tabela, é exibido o seu gráfico na Figura 4.7, em que o eixo x refere-se aos coeficientes das *wavelets* e o eixo y refere-se à taxa de porcentagem de acerto, que pode variar entre 0% e 100%.

Tabela 4.7: Relação de acertos do canal I3a de cada *wavelet* utilizada neste trabalho

Canal I3a												
Classe	Bey18	Coi12	Coi30	Dau4	Dau14	Dau34	Dau64	Dau76	Haar	Sym8	Sym16	Vai24
SA	65,7%	78,1%	68,6%	84,8%	67,6%	66,7%	65,7%	65,7%	86,7%	70,5%	63,8%	64,8%
LE	71,4%	61,0%	66,7%	64,8%	66,7%	69,5%	69,5%	69,5%	75,2%	69,5%	72,4%	68,6%




Figura 4.7: Gráfico referente à porcentagem de acertos do canal I3a obtido em cada *wavelet* utilizada neste trabalho

Na Tabela 4.8, é exibida a relação de acertos do canal I3b, obtida em cada *wavelet*, para as classes SA e LE. Nota-se que a melhor porcentagem de acerto para a classe SA foi 77,1% atingido pela *wavelet* de *Haar* e o melhor resultado da classe LE foi também na *wavelet Haar* com 88,6% de acertos. Para melhor visualização desta tabela, é exibido o seu gráfico na Figura 4.8, em que o eixo x refere-se aos coeficientes das *wavelets* e o eixo y refere-se à taxa de porcentagem de acerto, que pode variar entre 0% e 100%.

Tabela 4.8: Relação de acertos do canal I3b de cada *wavelet* utilizada neste trabalho

Canal I3b												
Classe	Bey18	Coi12	Coi30	Dau4	Dau14	Dau34	Dau64	Dau76	Haar	Sym8	Sym16	Vai24
SA	69,5%	71,4%	67,6%	71,4%	67,6%	72,4%	73,3%	73,3%	77,1%	73,3%	72,4%	68,6%
LE	76,2%	76,2%	76,2%	77,1%	75,2%	78,1%	73,3%	73,3%	88,6%	75,2%	70,5%	74,3%





Figura 4.8: Gráfico referente à porcentagem de acertos do canal I3b obtido em cada *wavelet* utilizada neste trabalho

Na Tabela 4.9, é exibida a relação de acertos dos Níveis de Cinza da imagem, obtida em cada *wavelet*, para as classes SA e LE. Nota-se que a melhor porcentagem de acerto para a classe SA foi 81% atingido pelas *wavelets* de Sym8 e Vai24 e o melhor resultado da classe LE foram nas *wavelets* de Dau4 e *Haar* com 68,6% de acertos. Para melhor visualização desta tabela, é exibido o seu gráfico na Figura 4.9, em que o eixo x refere-se aos coeficientes das *wavelets* e o eixo y refere-se à taxa de porcentagem de acerto, que pode variar entre 0% e 100%.

Tabela 4.9: Relação de acertos dos Níveis de Cinza de cada *wavelet* utilizada neste trabalho

Níveis de Cinza												
Classe	Bey18	Coi12	Coi30	Dau4	Dau14	Dau34	Dau64	Dau76	Haar	Sym8	Sym16	Vai24
SA	79,0%	80,0%	79,0%	77,1%	79,0%	79,0%	77,1%	77,1%	76,2%	81,0%	78,1%	81,0%
LE	65,7%	67,6%	61,9%	68,6%	61,0%	62,9%	62,9%	62,9%	68,6%	65,7%	61,0%	61,9%

Figura 4.9: Gráfico referente à porcentagem de acertos dos Níveis de Cinza obtida em cada *wavelet* utilizada neste trabalho


4.1.2 Exibição dos Resultados Obtidos da Etapa de Classificação entre as Classes RA, MA e AS

Com a pretensão de encontrar o vetor de características que melhor represente a separação dessas classes, foram criados 108 sistemas de classificação MVS diferentes, sendo estes originados da combinação dos nove canais e dos doze coeficientes das *wavelets*. A seguir, serão exibidas as tabelas que possuem porcentagens de acertos, seguidas de seus gráficos.

Na Tabela 4.10, é exibida a relação de acertos do canal R, obtida em cada *wavelet*, para as classes RA, MA e AS. Nota-se que a melhor porcentagem de acerto para a classe RA foi 74,3% nas *wavelets* Dau64 e Dau76. A melhor porcentagem de acerto da classe MA foi obtida nas *wavelets* Dau4, Haar e Sym16, com a porcentagem de acerto de 71,4%. Na classe AS atingiu no máximo de 54,3% de acerto na *wavelet* Sym8. Para melhor visualização desta tabela, é exibido o seu gráfico na Figura 4.10, em que o eixo x refere-se aos coeficientes *wavelets* e o eixo y refere-se à taxa de porcentagem de acerto, que pode variar entre 0% e 100%.

Tabela 4.10: Relação de acertos do canal R de cada *wavelet* utilizada neste trabalho

Canal R												
Classe	Bey18	Coi12	Coi30	Dau4	Dau14	Dau34	Dau64	Dau76	Haar	Sym8	Sym16	Vai24
RA	71,4%	71,4%	71,4%	71,4%	71,4%	71,4%	74,3%	74,3%	62,9%	71,4%	71,4%	71,4%
MA	65,7%	57,1%	62,9%	71,4%	68,6%	68,6%	62,9%	62,9%	71,4%	62,9%	71,4%	62,9%
AS	48,6%	51,4%	48,6%	51,4%	48,6%	45,7%	48,6%	48,6%	45,7%	54,3%	48,6%	45,7%

Figura 4.10: Gráfico referente à porcentagem de acertos do canal R obtido em cada *wavelet* utilizado neste trabalho

Na Tabela 4.11, é exibida a relação de acertos do canal G, obtida em cada *wavelet*, para as classes RA, MA e AS. Nota-se que a melhor porcentagem de acerto para a classe RA foi 62,9% em todas as *wavelets*, exceto nas de Dau4 e Haar. A melhor porcentagem de acerto da classe MA foi obtida nas *wavelets* Coi30 e Dau34, com a porcentagem de acerto de 77,1%. Na classe AS atingiu em todas as *wavelets* a porcentagem de acerto inferior a 50%. Para melhor visualização desta tabela, é exibido o seu gráfico na Figura 4.11, em que o eixo x refere-se aos coeficientes *wavelets* e o eixo y refere-se à taxa de porcentagem de acerto, que pode variar entre 0% e 100%.

Tabela 4.11: Relação de acertos do canal G de cada *wavelet* utilizada neste trabalho

Canal G												
Classe	Bey18	Coi12	Coi30	Dau4	Dau14	Dau34	Dau64	Dau76	Haar	Sym8	Sym16	Vai24
RA	62,9%	62,9%	62,9%	60,0%	62,9%	62,9%	62,9%	62,9%	51,4%	62,9%	62,9%	62,9%
MA	74,3%	71,4%	77,1%	68,6%	74,3%	77,1%	74,3%	74,3%	68,6%	68,6%	74,3%	71,4%
AS	42,9%	48,6%	40,0%	42,9%	40,0%	45,7%	45,7%	45,7%	40,0%	42,9%	45,7%	42,9%




Figura 4.11: Gráfico referente à porcentagem de acertos do canal G obtido em cada *wavelet* utilizado neste trabalho

Na Tabela 4.12, é exibida a relação de acertos do canal B, obtida em cada *wavelet*, para as classes RA, MA e AS. Nota-se que a melhor porcentagem de acerto para a classe RA foi 80% nas *wavelets* Coi30, Dau14, Dau34, Dau64, Dau76 e Vai24. A melhor porcentagem de acerto da classe MA foi obtida na *wavelet* Bey18, com a porcentagem de acerto de 74,3%. Na classe AS atingiu em todas as *wavelets* a porcentagem de acerto inferior a 43%. Para melhor visualização desta tabela, é exibido o seu gráfico na Figura 4.12, em que o eixo x refere-se aos coeficientes *wavelets* e o eixo y refere-se à taxa de porcentagem de acerto, que pode variar entre 0% e 100%.

Tabela 4.12: Relação de acertos do canal B de cada *wavelet* utilizada neste trabalho

Canal B												
Classe	Bey18	Coi12	Coi30	Dau4	Dau14	Dau34	Dau64	Dau76	Haar	Sym8	Sym16	Vai24
RA	77,1%	74,3%	80,0%	77,1%	80,0%	80,0%	80,0%	80,0%	74,3%	77,1%	77,1%	80,0%
MA	74,3%	65,7%	71,4%	68,6%	71,4%	71,4%	71,4%	71,4%	71,4%	71,4%	65,7%	71,4%
AS	40,0%	42,9%	40,0%	34,3%	40,0%	37,1%	40,0%	40,0%	31,4%	42,9%	42,9%	37,1%




Figura 4.12: Gráfico referente à porcentagem de acertos do canal B obtido em cada *wavelet* utilizado neste trabalho

Na Tabela 4.13, é exibida a relação de acertos do canal H, obtida em cada *wavelet*, para as classes RA, MA e AS. Nota-se que os resultados mais promissores pertencem a esse canal, em que a melhor porcentagem de acerto para a classe RA foi 88,6% na *wavelet* Dau4. A melhor porcentagem de acerto da classe MA foi obtida nas *wavelets* Dau64, Dau76 e Sym8, com a porcentagem de acerto de 71,4%. Na classe AS atingiu no máximo de 88,6% de acerto na *wavelet* Bey18. Para melhor visualização desta tabela, é exibido o seu gráfico na Figura 4.13, em que o eixo x refere-se aos coeficientes *wavelets* e o eixo y refere-se à taxa de porcentagem, que pode variar entre 0% e 100%.

Tabela 4.13: Relação de acertos do canal H de cada *wavelet* utilizada neste trabalho

Canal H												
Classe	Bey18	Coi12	Coi30	Dau4	Dau14	Dau34	Dau64	Dau76	Haar	Sym8	Sym16	Vai24
RA	60,0%	68,6%	68,6%	88,6%	65,7%	62,9%	60,0%	60,0%	77,1%	80,0%	65,7%	71,4%
MA	68,6%	65,7%	68,6%	65,7%	68,6%	68,6%	71,4%	71,4%	68,6%	71,4%	68,6%	68,6%
AS	88,6%	80,0%	82,9%	77,1%	80,0%	80,0%	82,9%	82,9%	68,6%	71,4%	85,7%	82,9%




Figura 4.13: Gráfico referente à porcentagem de acertos do canal H obtido em cada *wavelet* utilizado neste trabalho

Na Tabela 4.14, é exibida a relação de acertos do canal S, obtida em cada *wavelet*, para as classes RA, MA e AS. Nota-se que em todas as *wavelets* de todas as classes obtiveram os resultados inferiores a 50%, exceto na classe AS nas *wavelets* Coi12 e Sym8, que atingiu 54,3% de acertos, considerada uma porcentagem baixa, comparadas aos outros resultados apresentação anteriormente. Para melhor visualização desta tabela, é exibido o seu gráfico na Figura 3.22, em que o eixo x refere-se aos coeficientes *wavelets* e o eixo y refere-se à taxa de porcentagem de acerto, que pode variar entre 0% e 100%.

Tabela 4.14: Relação de acertos do canal S de cada *wavelet* utilizada neste trabalho

Canal S												
Classe	Bey18	Coi12	Coi30	Dau4	Dau14	Dau34	Dau64	Dau76	Haar	Sym8	Sym16	Vai24
RA	42,9%	34,3%	45,7%	40,0%	45,7%	42,9%	42,9%	42,9%	34,3%	34,3%	45,7%	42,9%
MA	45,7%	42,9%	45,7%	42,9%	45,7%	45,7%	45,7%	45,7%	42,9%	45,7%	42,9%	45,7%
AS	45,7%	54,3%	45,7%	48,6%	48,6%	45,7%	45,7%	45,7%	42,9%	54,3%	42,9%	45,7%




Figura 4.14: Gráfico referente à porcentagem de acertos do canal S obtido em cada *wavelet* utilizado neste trabalho

Na Tabela 4.15, é exibida a relação de acertos do canal V, obtida em cada *wavelet*, para as classes RA, MA e AS. Nota-se que a melhor porcentagem de acerto para a classe RA foi 60% nas *wavelets* Bey18, Dau4, Dau14, Dau34, Dau64 e Dau76. A melhor porcentagem de acerto da classe MA foi obtida na *wavelet* de *Haar*, com a porcentagem de acerto de 71,4%. Na classe AS atingiu em todas as *wavelets* a porcentagem de acerto inferior a 46%. Para melhor visualização desta tabela, é exibido o seu gráfico na Figura 4.15, em que o eixo x refere-se aos coeficientes *wavelets* e o eixo y refere-se à taxa de porcentagem de acerto, que pode variar entre 0% e 100%.

Tabela 4.15: Relação de acertos do canal V de cada *wavelet* utilizada neste trabalho

Canal V												
Classe	Bey18	Coi12	Coi30	Dau4	Dau14	Dau34	Dau64	Dau76	Haar	Sym8	Sym16	Vai24
RA	60,0%	57,1%	57,1%	60,0%	60,0%	60,0%	60,0%	60,0%	48,6%	57,1%	57,1%	57,1%
MA	65,7%	68,6%	62,9%	65,7%	68,6%	68,6%	65,7%	65,7%	71,4%	65,7%	65,7%	62,9%
AS	37,1%	34,3%	40,0%	40,0%	37,1%	45,7%	42,9%	42,9%	25,7%	42,9%	34,3%	45,7%




Figura 4.15: Gráfico referente à porcentagem de acertos do canal V obtido em cada *wavelet* utilizado neste trabalho

Na Tabela 4.16, é exibida a relação de acertos do canal I3a, obtida em cada *wavelet*, para as classes RA, MA e AS. Nota-se que a melhor porcentagem de acerto para a classe RA foi 65,7% nas *wavelets* Haar, Sym8 e Vai24. A melhor porcentagem de acerto da classe MA foi obtida na *wavelet* Haar, com a porcentagem de acerto de 91,4%. Na classe AS atingiu no máximo de 80% de acerto na *wavelet* Sym16. Para melhor visualização desta tabela, é exibido o seu gráfico na Figura 4.16, em que o eixo x refere-se aos coeficientes *wavelets* e o eixo y refere-se à taxa de porcentagem de acerto, que pode variar entre 0% e 100%.

Tabela 4.16: Relação de acertos do canal I3a de cada *wavelet* utilizada neste trabalho

Canal I3a												
Classe	Bey18	Coi12	Coi30	Dau4	Dau14	Dau34	Dau64	Dau76	Haar	Sym8	Sym16	Vai24
RA	48,6%	62,9%	57,1%	54,3%	48,6%	60,0%	51,4%	51,4%	65,7%	65,7%	45,7%	65,7%
MA	85,7%	80,0%	88,6%	82,9%	88,6%	85,7%	85,7%	85,7%	91,4%	80,0%	82,9%	85,7%
AS	71,4%	65,7%	77,1%	71,4%	77,1%	74,3%	74,3%	74,3%	71,4%	62,9%	80,0%	74,3%




Figura 4.16: Gráfico referente à porcentagem de acertos do canal I3a obtido em cada *wavelet* utilizado neste trabalho

Na Tabela 4.17, é exibida a relação de acertos do canal I3b, obtida em cada *wavelet*, para as classes RA, MA e AS. Nota-se que a melhor porcentagem de acerto para a classe RA foi 62,9% na *wavelet Haar*. A melhor porcentagem de acerto de todos os testes foi neste canal para a classe MA, em que foi obtida nas *wavelets* Coi12 e Sym16, com a porcentagem de acerto de 97,1%. Na classe AS atingiu no máximo de 77,1% de acerto na *wavelet* Sym16. Para melhor visualização desta tabela, é exibido o seu gráfico na Figura 4.17, em que o eixo x refere-se aos coeficientes *wavelets* e o eixo y refere-se à taxa de porcentagem de acerto, que pode variar entre 0% e 100%.

Tabela 4.17: Relação de acertos do canal I3b de cada *wavelet* utilizada neste trabalho

Canal I3b												
Classe	Bey18	Coi12	Coi30	Dau4	Dau14	Dau34	Dau64	Dau76	Haar	Sym8	Sym16	Vai24
RA	54,3%	60,0%	57,1%	57,1%	57,1%	48,6%	51,4%	51,4%	62,9%	57,1%	51,4%	60,0%
MA	91,4%	97,1%	91,4%	94,3%	94,3%	91,4%	91,4%	91,4%	94,3%	91,4%	97,1%	88,6%
AS	65,7%	51,4%	71,4%	71,4%	71,4%	65,7%	68,6%	68,6%	65,7%	65,7%	77,1%	68,6%




Figura 4.17: Gráfico referente à porcentagem de acertos do canal I3b obtido em cada *wavelet* utilizado neste trabalho

Na Tabela 4.18, é exibida a relação de acertos nos Níveis de Cinza, obtida em cada *wavelet*, para as classes RA, MA e AS. Nota-se que a melhor porcentagem de acerto para a classe RA foi obtidas em todas *wavelets* a porcentagem entre 60% e 62,9%. A melhor porcentagem de acerto da classe MA foi obtida nas *wavelets* Bey18, Coi12, Dau64, Dau76 e Sym16, com a porcentagem de acerto de 74,3%. Na classe AS atingiu em todas as *wavelets* a porcentagem de acerto inferior a 49%. Para melhor visualização desta tabela, é exibido o seu gráfico na Figura 4.18, em que o eixo x refere-se aos coeficientes *wavelets* e o eixo y refere-se à taxa de porcentagem de acertos, que pode variar entre 0% e 100%.

Tabela 4.18: Relação de acertos nos Níveis de Cinza de cada *wavelet* utilizada neste trabalho

Níveis de Cinza												
Classe	Bey18	Coi12	Coi30	Dau4	Dau14	Dau34	Dau64	Dau76	Haar	Sym8	Sym16	Vai24
RA	62,9%	60,0%	62,9%	60,0%	62,9%	62,9%	62,9%	62,9%	60,0%	62,9%	62,9%	62,9%
MA	74,3%	74,3%	68,6%	71,4%	71,4%	68,6%	74,3%	74,3%	68,6%	71,4%	74,3%	68,6%
AS	48,6%	45,7%	48,6%	48,6%	48,6%	45,7%	42,9%	42,9%	45,7%	45,7%	48,6%	48,6%




Figura 4.18: Gráfico referente à porcentagem de acertos nos Níveis de Cinza obtido em cada *wavelet* utilizado neste trabalho

4.2 Resultados do Sistema Final de Classificação

Nesta seção, são dadas as explicações dos critérios utilizados para realizar a classificação final entre as classes, sendo exibidos na Tabela 4.19. Nesta tabela, estão listados o número, a classe, os vetores dos resultados Res1, Res2, Res3 e Res4 (descrição da forma de sua obtenção foi dada na seção 3.7.3); e a coluna classificação de todas as imagens que foram utilizadas para os testes, bem como o canal, o coeficiente *wavelet* e o sistema de classificação utilizado para obtenção do diagnóstico final de classificação. Os detalhes desta tabela serão dados no decorrer desta seção.

Uma informação muito importante da Tabela 4.19 é a coluna classificação, pois nela está o resultado final da classificação de todas as imagens. São cinco diagnósticos diferentes, em que a imagem pode ser classificada, caso a classificação final seja 1, então, a imagem foi classificada pertencente à classe SA, se for 2, a imagem refere-se à classe MA, se for 3, a imagem foi classificada como RA, se for 4, a imagem refere-se à classe 4 e, se for 5, a imagem será classificada como não pertencente a nenhuma dessas classes.

Quando a mesma imagem foi classificada como MA e também como RA e/ou AS, constatou-se que essa imagem possui maior probabilidade de ser pertencente à classe MA, devido ao seu estágio inicial de severidade, em que ocasiona a classificação incorreta como pertencente também às outras classes de patógenos. E quando uma imagem foi classificada

pertencente a RA e AS, foi constatado que na sua grande maioria refere-se a imagens pertencentes à classe RA. Desse modo, o “desempate” das imagens classificadas em mais de um patógeno foi dado pela prioridade para a classe MA, depois para RA e por última AS.

Contudo, o processo de classificação foi realizado olhando na linha as quatro colunas Res1 a Res4, e foram adotados os seguintes critérios para a classificação:

- Se apenas uma delas for diferente de zero, foi colocado o valor (1, 2, 3 ou 4) na coluna de classificação.
- Bastando a coluna Res2 possuir o número 2, então, foi colocado o valor 2 na coluna classificação.
- Caso a coluna Res3 tenha o número 3 e a coluna Res2 seja diferente de 2, foi colocado o valor 3 na coluna classificação.
- Caso todas as colunas tenham zero, foi classificado com o valor 5.

Tabela 4.19: Resultado dos testes obtidos dos conjuntos de vetores de características.
Parte 1 de 5.

Imagem	<i>Núcleo--></i>	1	2	3	4	Classificação (Valores 1, 2, 3, 4 ou 5)
	<i>Componente --></i>	H	I3B	H	H	
	<i>Coeficiente --></i>	Vaidy24	Coif12	Daub4	Daub14	
	Classe	SADIA	MA	RA	AS	
1	Sadia	1	0	0	0	1
2	Sadia	1	0	0	0	1
3	Sadia	1	0	0	0	1
4	Sadia	1	0	0	0	1
5	Sadia	1	0	0	0	1
6	Sadia	1	0	0	0	1
7	Sadia	1	0	0	0	1
8	Sadia	1	0	0	0	1
9	Sadia	1	0	0	0	1
10	Sadia	1	0	0	0	1
11	Sadia	1	0	0	0	1
12	Sadia	1	0	0	0	1
13	Sadia	1	0	0	0	1
14	Sadia	1	0	0	0	1
15	Sadia	1	0	0	0	1
16	Sadia	1	0	0	0	1
17	Sadia	1	0	0	0	1
18	Sadia	1	0	0	0	1
19	Sadia	1	0	0	0	1
20	Sadia	1	0	0	0	1
21	Sadia	1	0	0	0	1
22	Sadia	0	0	3	0	3
23	Sadia	1	0	0	0	1
24	Sadia	1	0	0	0	1
25	Sadia	1	0	0	0	1
26	Sadia	1	0	0	0	1
27	Sadia	1	0	0	0	1
28	Sadia	1	0	0	0	1

Tabela 4.19: Resultado dos testes obtidos dos conjuntos de vetores de características.
Parte 2 de 5.

Imagem	<i>Núcleo--></i>	1	2	3	4	Classificação (Valores 1, 2, 3, 4 ou não)
	<i>Componente --></i>	H	I3B	H	H	
	<i>Coefficiente --></i>	Vaidy24	Coif12	Daub4	Daub14	
	Classe	SADIA	MA	RA	AS	
29	Sadia	1	0	0	0	1
30	Sadia	1	0	0	0	1
31	Sadia	1	0	0	0	1
32	Sadia	1	0	0	0	1
33	Sadia	1	0	0	0	1
34	Sadia	1	0	0	0	1
35	Sadia	1	0	0	0	1
36	Sadia	1	0	0	0	1
37	Sadia	1	0	0	0	1
38	Sadia	1	0	0	0	1
39	Sadia	1	0	0	0	1
40	Sadia	1	0	0	0	1
41	Sadia	1	0	0	0	1
42	Sadia	1	0	0	0	1
43	Sadia	1	0	0	0	1
44	Sadia	1	0	0	0	1
45	Sadia	1	0	0	0	1
46	Sadia	1	0	0	0	1
47	Sadia	1	0	0	0	1
48	Sadia	1	0	0	0	1
49	Sadia	1	0	0	0	1
50	Sadia	1	0	0	0	1
51	Sadia	1	0	0	0	1
52	Sadia	1	0	0	0	1
53	Sadia	1	0	0	0	1
54	Sadia	1	0	0	0	1
55	Sadia	1	0	0	0	1
56	Sadia	1	0	0	0	1
57	Sadia	1	0	0	0	1
58	Sadia	1	0	0	0	1
59	Sadia	1	0	0	0	1
60	Sadia	1	0	0	0	1
61	Sadia	1	0	0	0	1
62	Sadia	1	0	0	0	1
63	Sadia	1	0	0	0	1
64	Sadia	1	0	0	0	1
65	Sadia	1	0	0	0	1
66	Sadia	1	0	0	0	1
67	Sadia	1	0	0	0	1
68	Sadia	1	0	0	0	1
69	Sadia	1	0	0	0	1
70	Sadia	1	0	0	0	1
71	Sadia	0	0	3	0	3
72	Sadia	1	0	0	0	1
73	Sadia	1	0	0	0	1
74	Sadia	1	0	0	0	1
75	Sadia	1	0	0	0	1
76	Sadia	1	0	0	0	1
77	Sadia	1	0	0	0	1
78	Sadia	1	0	0	0	1
79	Sadia	1	0	0	0	1

Tabela 4.19: Resultado dos testes obtidos dos conjuntos de vetores de características.
Parte 3 de 5.

Imagem	Núcleo-->	1	2	3	4	Classificação (Valores 1, 2, 3, 4 ou não)
	Componente -->	H	I3B	H	H	
	Coefficiente -->	Vaidy24	Coif12	Daub4	Daub14	
	Classe	SADIA	MA	RA	AS	
80	Sadia	1	0	0	0	1
81	Sadia	1	0	0	0	1
82	Sadia	1	0	0	0	1
83	Sadia	1	0	0	0	1
84	Sadia	1	0	0	0	1
85	Sadia	0	2	0	0	2
86	Sadia	1	0	0	0	1
87	Sadia	1	0	0	0	1
88	Sadia	1	0	0	0	1
89	Sadia	1	0	0	0	1
90	Sadia	1	0	0	0	1
91	Sadia	1	0	0	0	1
92	Sadia	1	0	0	0	1
93	Sadia	0	2	0	0	2
94	Sadia	1	0	0	0	1
95	Sadia	1	0	0	0	1
96	Sadia	1	0	0	0	1
97	Sadia	1	0	0	0	1
98	Sadia	1	0	0	0	1
99	Sadia	1	0	0	0	1
100	Sadia	1	0	0	0	1
101	Sadia	1	0	0	0	1
102	Sadia	1	0	0	0	1
103	Sadia	1	0	0	0	1
104	Sadia	1	0	0	0	1
105	Sadia	1	0	0	0	1
106	MA	0	2	0	0	2
107	MA	0	2	0	0	2
108	MA	0	2	0	0	2
109	MA	0	2	0	0	2
110	MA	0	2	0	0	2
111	MA	0	2	0	4	2
112	MA	0	2	0	0	2
113	MA	0	2	0	0	2
114	MA	0	2	3	0	2
115	MA	0	2	0	0	2
116	MA	0	2	3	0	2
117	MA	0	2	0	4	2
118	MA	0	2	3	0	2
119	MA	0	2	0	4	2
120	MA	0	2	0	4	2
121	MA	0	2	0	0	2
122	MA	0	2	0	0	2
123	MA	0	2	3	0	2
124	MA	0	2	3	4	2
125	MA	0	2	0	0	2
126	MA	0	2	0	0	2
127	MA	0	2	0	0	2
128	MA	0	2	0	0	2
129	MA	0	2	0	0	2
130	MA	0	2	0	0	2

Tabela 4.19: Resultado dos testes obtidos dos conjuntos de vetores de características.
Parte 4 de 5.

Imagem	Núcleo-->	1	2	3	4	Classificação (Valores 1, 2, 3, 4 ou não)
	Componente -->	H	I3B	H	H	
	Coefficiente -->	Vaidy24	Coif12	Daub4	Daub14	
	Classe	SADIA	MA	RA	AS	
131	MA	0	2	0	4	2
132	MA	0	2	0	0	2
133	MA	0	2	3	0	2
134	MA	0	2	0	0	2
135	MA	0	0	0	0	0
136	MA	0	2	0	0	2
137	MA	0	2	0	0	2
138	MA	0	2	0	0	2
139	MA	0	2	0	0	2
140	MA	0	2	3	0	2
141	RA	0	0	3	0	3
142	RA	0	2	3	0	2
143	RA	0	0	3	0	3
144	RA	0	0	3	0	3
145	RA	0	0	3	0	3
146	RA	0	0	3	0	3
147	RA	0	0	3	0	3
148	RA	0	0	3	4	3
149	RA	0	0	3	0	3
150	RA	0	0	3	4	3
151	RA	0	0	3	0	3
152	RA	0	0	0	4	4
153	RA	0	0	3	4	3
154	RA	0	0	3	0	3
155	RA	0	0	0	4	4
156	RA	0	0	3	0	3
157	RA	0	0	3	0	3
158	RA	0	0	3	4	3
159	RA	0	0	0	4	4
160	RA	0	0	3	0	3
161	RA	0	0	3	4	3
162	RA	0	0	0	4	4
163	RA	0	0	3	0	3
164	RA	0	0	3	0	3
165	RA	0	0	3	4	3
166	RA	0	0	3	4	3
167	RA	0	0	3	0	3
168	RA	0	0	3	0	3
169	RA	0	0	3	4	3
170	RA	0	2	3	0	2
171	RA	0	0	3	0	3
172	RA	0	0	3	0	3
173	RA	0	2	3	0	2
174	RA	0	0	3	0	3
175	RA	0	0	3	0	3
176	AS	0	0	0	4	4
177	AS	0	0	3	4	3
178	AS	0	0	0	0	0
179	AS	0	0	3	4	3
180	AS	0	0	0	4	4

Tabela 4.19: Resultado dos testes obtidos dos conjuntos de vetores de características.
Parte 5 de 5.

Imagem	<i>Núcleo--></i>	1	2	3	4	Classificação (Valores 1, 2, 3, 4 ou não)
	<i>Componente --></i>	H	I3B	H	H	
	<i>Coefficiente --></i>	Vaidy24	Coif12	Daub4	Daub14	
	Classe	SADIA	MA	RA	AS	
181	AS	0	0	0	4	4
182	AS	0	0	0	4	4
183	AS	0	0	3	4	3
184	AS	0	0	0	4	4
185	AS	0	0	0	4	4
186	AS	0	0	0	4	4
187	AS	0	0	0	4	4
188	AS	0	0	0	4	4
189	AS	0	2	0	4	2
190	AS	0	2	0	0	2
191	AS	0	2	0	4	2
192	AS	0	0	0	4	4
193	AS	0	0	0	4	4
194	AS	0	0	0	4	4
195	AS	0	0	0	4	4
196	AS	0	0	0	4	4
197	AS	0	0	0	4	4
198	AS	0	0	0	4	4
199	AS	0	0	0	4	4
200	AS	0	0	0	4	4
201	AS	0	0	3	0	3
202	AS	0	0	0	4	4
203	AS	0	0	0	4	4
204	AS	0	0	3	4	3
205	AS	0	0	0	4	4
206	AS	0	0	0	4	4
207	AS	0	0	0	4	4
208	AS	0	0	0	4	4
209	AS	0	0	0	4	4
210	AS	0	2	0	0	2

4.3 Análise dos Resultados

Observando a coluna de classificação da tabela 4.19, a partir das 210 imagens, constatou-se que foram classificadas corretamente o total de 188 imagens (101 imagens SA, 34 imagens MA, 28 imagens RA e 25 imagens AS) correspondendo a um pouco mais de 89,5% de acerto geral do sistema.

Para a classe sadia, na classificação de 105 imagens, constatou-se que 101 foram classificadas corretamente. Na Tabela 4.20, é exibida a porcentagem de classificação das imagens “Sadias” para cada diagnóstico. Nota-se na tabela que 96,2% das imagens foram classificadas corretamente, 3,8% são de falsos positivos em que, 1,9% foram classificadas

como pertencente à classe Mancha Angular, 1,9% foram classificadas como RA, nenhuma imagem foi classificada como pertencente a classe AS e à nenhuma das classes.

Tabela 4.20: Resultados dos testes, em que 105 imagens “Sadias” foram classificadas como:

SA	Falso Positivo			
	MA	RA	AS	NENHUMA
96,2%	1,9%	1,9%	0,0%	0,0%

Para a classe Mancha Angular, na classificação de 35 imagens, constatou-se que 34 foram classificadas corretamente. Na Tabela 4.21, é exibida a porcentagem de classificação das imagens “Mancha Angular” para cada diagnóstico. Nota-se na tabela que 97,1% das imagens foram classificadas corretamente e apenas 2,9% são de falso positivo em que, a imagem foi classificada como não pertencente a nenhuma das classes. Para as outras classes (SA, RA e AS), nenhuma imagem foi classificada.

Tabela 4.21: Resultados dos testes, em que 35 imagens “Mancha Angular” foram classificadas como:

MA	Falso Positivo			
	SA	RA	AS	NENHUMA
97,1%	0,0%	0,0%	0,0%	2,9%

Para a classe Ramulária, na classificação de 35 imagens, constatou-se que 28 foram classificadas corretamente. Na Tabela 4.22, é exibida a porcentagem de classificação das imagens “Ramulária” para cada diagnóstico. Nota-se na tabela que 80% das imagens foram classificadas corretamente, 20% foram de falso positivo, em que 8,6% foram classificadas como sendo MA, 11,4% foram classificadas sendo AS e nenhuma imagem foi classificada como sadia ou nenhuma das classes.

Tabela 4.22: Resultados dos testes, em que 35 imagens “Ramulária” foram classificadas como:

RA	Falso Positivo			
	SA	MA	AS	NENHUMA
80,0%	0,0%	8,6%	11,4%	0,0%

Para a classe Mancha de *Ascochyta*, na classificação de 35 imagens, constatou-se que 25 foram classificadas corretamente. Na Tabela 4.23, é exibida a porcentagem de classificação das imagens “Mancha de *Ascochyta*” para cada diagnóstico. Nota-se na tabela que 71,4% das imagens foram classificadas corretamente e 29,6% foram de falso positivo,

sendo 11,4% classificadas como MA, 14,3% classificadas RA, 2,9% classificadas como não pertencentes a nenhuma das classes e nenhuma imagem foi classificada como pertencente à classe SA.

Tabela 4.23: Resultados dos testes, em que 35 imagens “Mancha de *Ascochyta*” foram classificadas como:

AS	Falso Positivo			
	SA	MA	RA	NENHUMA
71,4%	0,0%	11,4%	14,3%	2,9%

Como observado na coluna SA das tabelas 4.11, 4.12 e 4.13, nota-se que nenhuma imagem das folhas lesionadas foi classificada como sadia, então, conclui-se que as 105 imagens lesionadas com os patógenos Mancha Angular, Ramulária e Mancha de *Ascochyta* foram classificadas como lesionadas, atingindo 100% de acerto na separação das imagens lesionadas e consequentemente com 0% de falso positivo.

4.4 Resultados Obtidos por Outros Autores em Trabalhos Correlatos

Foram encontrados quatro trabalhos que fazem a classificação de doenças em plantas, sendo estes descritos abaixo:

- Huang [8] fez a classificação de quatro classes de orquídeas. Uma classe refere-se à folha sadia e as outras três classes referem-se a tipos de doenças: podridão bacteriana, mancha bacteriana marrom e podridão negra. Neste trabalho, os testes foram realizados somente com imagens de folhas lesionadas, em que foram usadas para o treinamento 145 imagens e para os testes foram 144 imagens. Destas imagens de teste 97,2% foram classificadas corretamente como sendo lesionadas. A média de acertos na classificação entre as três doenças foi de 89,6%.

- Abdullah [12] desenvolveu dois modelos de RNA, para classificação de três doenças foliares da seringueira. O sistema desenvolvido utilizou 600 amostras, para realizar o treinamento e 200 amostras para os testes da RNA. Os testes foram feitos somente com imagens de um tipo das doenças. Os resultados, neste trabalho, mostraram que a rede reduzida produziu cerca de 70% na precisão de diagnósticos e a outra rede obteve 80% de acertos dos diagnósticos entre as três doenças.

– Meunkaewjinda [15] propôs um sistema híbrido, para distinguir doenças da folha da uva. Este trabalho divide-se em três partes principais: segmentação da cor da folha da uva, segmentação das doenças foliares e análise e classificação de doenças. Foram utilizadas 1478 imagens para realizar o treinamento e 115 imagens para realizar os testes. A classificação é feita em três classes: doença verrugose, ferrugem e nenhuma doença. Foram obtidos 86,03% de acertos da classificação das imagens entre essas três classes.

– Phadikar [25] descreveu quatro RNAs, sendo cada uma delas treinada de forma diferente. O objetivo de seu trabalho foi identificar dois tipos de doenças do arroz, brusone e mancha marrom. Foram utilizadas 300 imagens para os treinamentos e a mesma quantidade para os testes das quatro redes. Entre as RNAs, o melhor resultado apresentado foi de 92% de acertos.

CAPÍTULO 5 – CONCLUSÕES

O trabalho em questão apresentou um sistema de classificação para identificar automaticamente a existência ou não de patógenos, por meio de imagens de órgãos foliares do algodoeiro. Além de classificar qual dos três tipos de patógenos (RA, MA e AS) está causando a lesão, o sistema realiza a discriminação de uma imagem não pertencente a nenhuma das classes.

A maior dificuldade deste trabalho foi compor um vetor de características que representasse cada classe, pois o banco de imagens utilizado é muito heterogêneo, com tamanho, brilho, contraste e resoluções diferentes.

Para resolver este problema, foi calculada a energia da transformada *wavelet* de cada sub-banda formada pela decomposição da imagem até o terceiro nível, para compor o vetor de características. Com o propósito de encontrar o melhor descritor para cada classe, foram desenvolvidos 108 vetores de características diferentes, a partir da decomposição da imagem nos canais R, G, B, H, S, V, I3A, I3B e no nível de cinza da imagem, e das *wavelets* Bey18, Coi12, Coi30, Dau4, Dau14, Dau34, Dau64, Dau76, *Haar*, Sym8, Sym16 e Vai24.

Depois dos vetores de características constituídos, eles passaram pelo sistema de classificação. A técnica de classificação utilizada foi a MVS, que vem apresentando resultados mais promissores comparados a outros tipos de algoritmos de aprendizado, como as RNAs [42, 43]. Foi utilizada a abordagem de aprendizado supervisionado e a função Gaussiana para realizar mapeamento da rede (núcleo ou *kernel*).

Com base nos resultados obtidos, o vetor de características composto, partindo do canal H e da *wavelet* Vai24, foi o melhor classificador para distinguir as imagens folhas saudáveis com 96,2% de acerto e 100% de acerto para as imagens “lesionadas”. Entre as três classes de patógenos, os melhores resultados encontrados para a classe MA foi 97,1% de

acertos obtidos do canal I3b e nas *wavelets* Coi12 e Sym16. Para as classes RA e AS foram atingidos 88,6% de acertos, ambas no canal H, porém na RA, foi aplicada a *wavelet* Dau4 e, na classe AS, foi utilizada a *wavelet* Bey18.

Observa-se dos resultados que o canal H foi o melhor canal para a extração de características para distinguir todas as classes, com exceção da classe MA, em que o canal que melhor a representou foi o I3b.

Os melhores vetores de características foram utilizados no sistema de classificação final, cuja classificação foi realizada de forma encadeada, em que a imagem será classificada primeiramente como sadia, seguidas das classes MA, RA, AS e nenhuma das classes. Desta forma, a classificação final obteve 96,2% de acertos para a classe SA, 97,1% de acertos para a classe MA, 80% de acertos para a classe RA e 71,4% de acertos para AS.

Outro fator relevante, desenvolvido neste trabalho, foi a realização dos estudos com a cotonicultura, pois, durante a revisão bibliográfica, não foi encontrada nenhuma pesquisa que realizasse trabalhos nesta mesma linha. O que foi encontrado foram trabalhos em outras culturas, como o de Huang [8], em que fez quatro diagnósticos diferentes (“sadia” e entre três doenças) da seringueira, em que atingiu 97,2% para as folhas lesionadas e a média geral de acertos foi de 89,6%, porém os testes foram realizados somente com folhas lesionadas. No trabalho de Abdullah [12], fez-se a classificação de três classes de patógenos da seringueira, em que seu melhor resultado de classificação foi de 80%, sendo os testes realizados com somente um tipo de patógeno. O trabalho de Meunkaewjinda [15] possui três tipos de diagnósticos (entre duas doenças e nenhuma doença) da uva, em que atingiu 86,3% de acertos. Foram utilizadas, para o treinamento da rede, 1478 imagens. Phadikar [25] fez seu trabalho sobre a cultura do arroz, que atingiu 92% de acertos na classificação de doenças, porém foram utilizadas somente duas classes para a classificação.

Contudo, conclui-se que, em relação às outras culturas, o presente trabalho apresentou melhores resultados, visto que se utilizou uma pequena quantidade de amostras para realizar o treinamento da rede MVS, por ter criado descritores que representassem cada classe, mesmo que o banco de imagens utilizado tenha sido heterogêneo, por realizar a classificação com uma quantidade maior de diagnósticos, sendo cinco tipos diferentes (SA, MA, RA, AS e nenhuma das classes), obtendo uma porcentagem considerável, com pouco mais de 89,5% na classificação geral da quantidade de acertos.

Trabalhos Futuros

No propósito de evoluir o processo de classificação e melhorar a identificação das imagens de folhas do algodoeiro, podem ser consideradas algumas melhorias no método desenvolvido. Com o objetivo de deixar o banco de imagens mais homogêneo, poderiam ser aplicados filtros de suavização, como o filtro gaussiano, para reduzir ou eliminar os possíveis ruídos na imagem. Para melhorar a precisão dos resultados entre as classes lesionadas, poderiam ser aplicados métodos de limiarização automático, como o método *Otsu* e método do Vale, ou métodos de crescimento de região por fusão ou *watershed*, para identificar a melhor técnica que realiza a segmentação das regiões lesionadas da imagem, para serem aplicadas as *wavelets* somente nas regiões que realmente devam ser analisadas. Realizar testes com outros coeficientes e suporte das *wavelets*, como o de *Gabor*, *Morlet* e *Meyer*, com o intuito de identificar um descritor que melhor represente as classes.

REFERÊNCIAS BIBLIOGRÁFICAS

- [1] MOSHOU, Dimitrios; BRAVOA, Cédric; WESTB, Jonathan; WAHLENA, Stijn; MCCARTNEYB, Alastair; Ramona, Herman. Automatic detection of ‘yellow rust’ in wheat using reflectance measurements and neural networks; *Computers and Electronics in Agriculture*; v. 44, n. 3, p. 173-188, Setembro, 2004.
- [2] ZHANG, Yan-Cheng; MAO, Han-Ping; HU, Bo; LI, Ming-Xi; Features selection of cotton disease leaves image based on fuzzy feature selection techniques; *Wavelet Analysis and Pattern Recognition*, 2007. ICWAPR '07. International Conference on v. 1, p. 124 – 129, 2-4 Novembro, 2007.
- [3] SANYAL, P.; PATEL, S. C. Pattern recognition method to detect two diseases in rice plants; *Source: Imaging Science Journal, The*, v. 56, n. 6, p. 319-325(7), Dezembro, 2008
- [4] ANTHONYS, G.; WICKRAMARACHCHF, N. An Image Recognition System for Crop Disease Identification of Paddy fields in Sri Lanka; *Fourth International Conference on Industrial and Information Systems, ICIIS 2009, Sri Lanka*. p. 403-407, 28 - 31 Dezembro, 2009.
- [5] OTSU, Nobuyuki. A threshold selection method from gray-level histograms. *IEEE Trans. Sys., Man., Cyber.* v. 9, p. 62–66, 1979.
- [6] NAKANO, Kazuhiro. Application of neural networks to the color grading of apples. *Faculty of Agriculture, Niigata University*, 2-8050 Ikarashi, Niigata 950-21, Japan Available online, v. 18, p. 105-116, 11 de dezembro, 1997.
- [7] SENA JUNIOR, Darly G. de; PINTO, Francisco de A. de C.; QUEIROZ, Daniel M. de and MANTOVANI, Evandro C. Algoritmo para classificação de plantas de milho atacadas pela lagarta do cartucho (*Spodoptera frugiperda*, Smith) em imagens digitais. *Rev. bras. eng. agríc. ambient.* [online]. v. 5, n. 3, p. 502-509, 2001. ISSN 1415-4366.
- [8] HUANG, K. Application of artificial neural network for detecting *Phalaenopsis* seedling diseases using color and texture features. *Comput. Electron. Agric.* v. 57, n. 1, p. 3-11, Maio, 2007.
- [9] EL-HELLY, M.; EL-BELTAGY, S.; RAFEA, A. Image analysis based interface for diagnostic expert systems. In *Proceedings of the Winter international Synposium on information and Communication Technologies. ACM International Conference Proceeding Series, Cancun, México, Trinity College Dublin*, v. 58, p. 1-6, 05-08 Janeiro, 2004.

- [10] YOUWEN, Tian; TIANLAI, Li; YAN, Niu; The Recognition of Cucumber Disease Based on Image Processing and Support Vector Machine; Image and Signal Processing, 2008. CISP '08. Congress on v. 2, p. 262 – 267, 27-30 Maio, 2008.
- [11] BOISSARD, P.; MARTIN, V.; MOISAN, S. A cognitive vision approach to early pest detection in greenhouse crops. Comput. Electron. Agric. v. 62, n. 2, p. 81-93, Julho, 2008.
- [12] ABDULLAH, N.E.; RAHIM, A.A.; HASHIM, H.; KAMAL, M.M.; Classification of Rubber Tree Leaf Diseases Using Multilayer Perceptron Neural Network; Research and Development. SCOREd 5th Student Conference. p. 1 – 6, 12-11 Dezembro, 2007.
- [13] CUI, Di; ZHANG, Qin; LI, Minzan; ZHAO, Youfu; HARTMAN; Glen L. Detection of soybean rust using a multispectral image sensor, Sensing and Instrumentation for Food Quality and Safety, v. 3, n. 1, p. 49-56, 2009.
- [14] WEIZHENG, S.; YACHUN, W.; ZHANLIANG, C.; HONGDA, W. Grading Method of Leaf Spot Disease Based on Image Processing. In Proceedings of the 2008 International Conference on Computer Science and Software Engineering. CSSE. IEEE Computer Society, Washington, DC, v. 06, p. 491-494, 14 Dezembro, 2008.
- [15] MEUNKAEWJINDA, A.; KUMSAWAT, P.; ATTAKITMONGCOL, K.; SRIKAEW, A.; Grape leaf disease detection from color imagery using hybrid intelligent system; Electrical Engineering/Electronics, Computer, Telecommunications and Information Technology, 2008. ECTI-CON 2008. 5th International Conference on v. 1, , p. 513 – 516, 14-17 Maio, 2008.
- [16] POLDER, G.; VAN DER HEIJDEN; G. W.; JALINK, H.; SNEL, J. F. Correcting and matching time sequence images of plant leaves using Penalized Likelihood Warping and Robust Point Matching. Comput. Electron. Agric. v. 55, n.1, p. 1-15, Janeiro, 2007.
- [17] OLIVEIRA, Maxwell Carvalho. Agência Goiana de Defesa Agropecuária (Agrodefesa). Programa de Prevenção e Controle de Pragas em Algodão. Disponível em: http://www.agrodefesa.go.gov.br/index.php?option=com_content&view=article&id=74. Acesso em janeiro, 2010.
- [18] GALBIERI, Rafael. Comportamento de Genótipos de Algodoeiro na Presença de Patógenos e Nematoides. Dissertação (Mestrado em Agricultura Tropical e Subtropical) - Instituto Agrônomo, Campinas, SP – Brasil, 2007.
- [19] KIMATI, H.; AMORIM, L.; BERGAMIN FILHO, A.; CAMARGO L. E. A.; REZENDE, J. A. M. Manual de Fitopatologia. Volume 2: Doenças de Plantas Cultivadas. São Paulo: Agronômica Ceres Ltda, 1997.
- [20] CURVELO, Carmen R. S; RODRIGUES, Fabrício A; BERGER, Paulo G and REZENDE, Dalilla C. Microscopia eletrônica de varredura do processo infeccioso de Ramularia areola em folhas de algodoeiro. Trop. plant pathol. [online]. v. 35, n.2, p. 108-113, 2010. ISSN 1982-5676.
- [21] CAMARGO A., SMITH J.S. An image-processing based algorithm to automatically identify plant disease visual symptoms. Biosystems Engineering, v. 102 , n. 1, p. 9-21, 2009.

- [22] GONZALEZ, Rafael C.; WOODS, Richard E. Processamento de Imagens Digitais. São Paulo: Edgard Blücher, 2000.
- [23] SCARANTI, Alexander; BERNARDI, Ronaldo; PLOTZE, Rodrigo de Oliveira. Identificação de Órgãos Foliares utilizando as *wavelets* de *Daubechies*. FCT/UNESP. VI Workshop de Visão Computacional de Presidente Prudente, Presidente Prudente, SP. v. 6, p. 211-216, 4-7 de Julho, 2010.
- [24] BABINI, Maurizio; MARRANGHELLO, Norian. Introdução às Redes Neurais Artificiais. São Paulo: Cultura Acadêmica, 2007.
- [25] PHADIKAR, Santanu; SIL, Jaya; Rice Disease Identification using Pattern Recognition Techniques; Proceedings of 11th International Conference on Computer and Information Technology (ICCIT 2008), Khulna, Bangladesh. p. 420-423, 25-27 Dezembro, 2008.
- [26] ARAUJO, Ricardo Silva; RAVA, Carlos Agustín; STONE, Luis Fernando; ZIMMERMANN, Maria José de Oliveira. Cultura do Feijoeiro Comum no Brasil. Piracicaba: Patafos, 1996.
- [27] SUASSUNA, Nelson Dias; ARAÚJO, Alderí Emídio. Guia de identificação e Controle das Principais Doenças do Algodoeiro no Estado de Goiás. Campina Grande: EMBRAPA Centro Nacional de Pesquisa do Algodão, 2003. ISSN 0103-0205.
- [28] CHITARRA, Luiz Gonzaga; ZANCAN, Willian Luís Antônio; LIRA, Adelardo José Silva; MENEZES, Valdemir Lima Menezes; RODRIGUES, Sandra Maria Morais. Avaliação Da Eficiência Do Fungicida Tiofanato Metílico-Ciproconazole No Controle Da Mancha De Ramulária (Ramularia Areola) Em Algodoeiro. Congresso Brasileiro Do Algodão, 7., 2009, Foz do Iguaçu. Sustentabilidade da Cotonicultura Brasileira e Expansão dos Mercados: Anais. Campina Grande: Embrapa Algodão, p. 1044-1050, 2009.
- [29] SUASSUNA, Nelson Dias. Engenheiro Agrônomo, D. Sc. Em Fitopatologia, Pesquisador da Embrapa Algodão (Empresa Brasileira de Pesquisa Agropecuária), Campina Grande/PB.
- [30] FI. Forestry Images. A joint project of the Center for Invasive Species and Ecosystem Health, USDA Forest Service and International Society of Arboriculture. The University of Georgia - Warnell School of Forestry and Natural Resources and College of Agricultural and Environmental Sciences. disponível em: <http://www.forestryimages.org>. acesso em agosto, 2010.
- [31] CIE. Commission Internationale de L'Eclairage. Proceedings of de eight session, Cambridge, Inglaterra. Bureau Central de La Commission Internationale de l'Eclairage. 326 p. 1931.
- [32] BRYIS, Leonardo Monteiro. Página Para Aprendizado do Sensoriamento Remoto. Dissertação (Mestrado em Sensoriamento Remoto) - Universidade Federal do Rio Grande do Sul, Porto Alegre, RS – Brasil, 2008.
- [33] GOMES, Jonas; VELHO, Luiz. Fundamentos da Computação Gráfica. 2 ed., Rio de Janeiro: IMPA, 2002.

- [34] OHTA, Y.; KANADE, T., SAKAI, T. Color information for region segmentation. *Computer Graphics and Image Processing*. Department of Information Science, Kyoto, Japan, v. 13, n. 3, p. 222–241, Julho, 1980.
- [35] PRATT, William K. *Digital Image Processing*. 3 ed. Pks Inside, 2001.
- [36] SONKA, Milan; HLAVAC, Vaclav; BOYLE, Roger; *Image Processing, Analysis, and Machine Vision*, 2ed. ITP, 1998.
- [37] FAYAL, Marcelo Alfredo de Assis. *Previsão de vazão por Redes Neurais Artificiais e Transformada Wavelet*, 2008. Dissertação (Mestrado em Engenharia Elétrica) - Pontifícia Universidade Católica do Rio de Janeiro, Rio de Janeiro, RJ – Brasil, 2008.
- [38] DIAS, Anfranseraí Moraes. *Controle de Manipulador Redundante Utilizando Realimentação Visual*, 2002. Dissertação (Mestrado em Ciências) - Universidade Federal do Rio Grande do Norte, Natal, RN – Brasil, 2002.
- [39] MOUZINHO, Lucilene Ferreira. *Estimação de Velocidade em Máquinas de Indução*. Dissertação (Mestrado em Engenharia Elétrica) - Universidade Federal do Maranhão, Maranhão, MA – Brasil, 2003.
- [40] RUSSELL, Stuart; NORVING, Peter. *Inteligência Artificial*. 2ed. Rio de Janeiro: Elsevier, 2004.
- [41] FERNANDES, Anita Maria da Rocha. *Inteligência Artificial: noções gerais*. Florianópolis: Visual Books, 2003.
- [42] SOUZA, L.M. *Deteção Inteligente de Patologias na Laringe Baseada em Máquinas de Vetores de Suporte e na Transformada Wavelet*. Dissertação (Mestre em Computação Aplicada a Física) – Universidade de São Paulo de São Carlos, SP, Brasil, 2011.
- [43] BISOGNIN, Gustavo. *Utilização de Máquinas de Suporte Para Predição de Estruturas Terciárias de Proteínas*. Dissertação (Mestrado em Computação Aplicada) – Universidade do Vale do Rio dos Sinos, São Leopoldo, RS - Brasil, 2007.
- [44] FONSECA, E. ; GUIDO, R. C. ; SCALASSARA, P. R. ; MACIEL, C. D. ; PEREIRA, J. C. *Wavelet Time-frequency Analysis and Least-Squares Support Vector Machine for the Identification of Voice Disorders*. *Computers in Biology and Medicine*, Elsevier, v. 37, n. 4, p. 571-578, 2007.
- [45] YU, Z.; WONG, H.; WEN, G. A Modified Support Vector Machine and its Application to Image Segmentation. *Image and Vision Computing*, v. 29, p. 29-40, 2011.
- [46] ALES, Vanessa Terezinha. *O Algoritmo Sequential Minimal Optimization para Resolução do Problema Support Vector Machine: Uma Técnica de Reconhecimento de Padrões*. Dissertação (Mestrado em Ciências) – Universidade Federal do Paraná, Curitiba, PR – Brasil, 2008.
- [47] VAPNIK, V. *Statistical Learning Theory*. Springer Werlang: 2. ed., New York, 1998.

- [48] POZZEBON, Giovani Guarienti. Transformada *Wavelet* e Redes Neurais Artificiais na Análise de Sinais Relacionados à Qualidade da Energia Elétrica. Dissertação (Mestrado em Engenharia Elétrica) - Universidade Federal de Santa Maria, Santa Maria, RS – Brasil, 2009.
- [49] CASTELANO, Célio Ricardo. Estudo Comparativo da Transformada *Wavelet* no Reconhecimento de Padrões da Íris Humana. Dissertação (Mestrado em Engenharia Elétrica) - Universidade de São Paulo, São Carlos, SP – Brasil, 2006.
- [50] SOARES, Heliana Bezerra. Análise e Classificação de Imagens de Lesões da Pele por Atributos de Cor, Forma e Textura Utilizando a Máquina de Vetor de Suporte. Tese (Doutorado em Engenharia Elétrica e de Computação) - Universidade Federal do Rio Grande do Norte, Natal, RN – Brasil, 2008.
- [51] ADDISON, P.S.; WALKER, J.; GUIDO, R.C. Time--frequency analysis of biosignals, *Engineering in Medicine and Biology Magazine, IEEE* , v. 28, n. 5 , p. 14-29, Setembro – Outubro, 2009.
- [52] DÓCUSSE, Tiago Alexandre. Um Método para Melhoria de Qualidade de Imagens Médicas Utilizando a Transformada *Wavelet*, 2008. Dissertação (Mestrado em Ciência da Computação) - Universidade Estadual Paulista, São José do Rio Preto, SP – Brasil, 2008.
- [53] BARBON JÚNIOR, Sylvio. Dynamic Time Warping baseado na Transformada *Wavelet*. Dissertação (Mestrado em Ciências – Física Aplicada – Opção Física Computacional). Universidade de São Paulo, São Carlos, SP – Brasil, 2007.
- [54] PAKER, James, R. *Algorithms for Image Processing and Computer Vision*. New York:Wiley, 1996.
- [55] FONSECA, Marcello Santos. Um estudo sobre a influência das Famílias *wavelets* na Compressão de Imagem. Dissertação (Mestrado em Computação) - Universidade Federal Fluminense, Niterói, RJ – Brasil, 2004.
- [56] JÚNIOR FONINI, Décio Angelo. Quantização por Aproximações Sucessivas. Tese (Doutorado em Ciências em Engenharia Elétrica) - Universidade Federal do Rio de Janeiro, RJ – Brasil, 2003.
- [57] SILVA, Ricardo Dutra; SCHWARTZ, William Robson; PEDRINI, Hélio. Avaliação da Invariância à Rotação de Descritores Texturais Extraídos por Transformadas *wavelets*. INPE. XIV Simpósio Brasileiro de Sensoriamento Remoto, Natal, RN. 25-30, Abril, 2009.