

Capítulo

10

Técnicas de Processamento de Imagens em Diagnóstico Auxiliado por Computador

Rodrigo M. S. Veras, Iális C. Paula Jr. e Fátima N. S. Medeiros

Abstract

Computer-aided diagnosis systems (CAD) are defined to improve the accuracy of diagnosis by health experts, as well as consistency of interpretation of imaging tests by using the computer's response as a reference. Large collections of medical imaging have brought the necessity of using computational techniques to process analyze and retrieve pictorial information related to them. Therefore, computer-aided diagnosis has been attracting great interest. The aim of this chapter is to introduce the main concepts related to CAD systems: kinds of CAD and major areas of activity, techniques of Digital Image Processing, Pattern Recognition algorithms and practical applications.

Resumo

Sistemas de Diagnóstico Auxiliado por Computador (CAD - Computer-aided diagnosis) são definidos para aprimorar a acurácia do diagnóstico realizado por especialistas de saúde, assim como a consistência da interpretação de exames de imagens, mediante o uso da resposta do computador como referência. Grandes coleções de imagens médicas trouxeram consigo a necessidade de utilizar técnicas computacionais para processar, analisar e recuperar a informação pictórica relacionada às mesmas. Dessa forma, o diagnóstico auxiliado por computador vem atraindo grande interesse. O objetivo deste capítulo é apresentar os principais conceitos ligados aos sistemas CAD: tipos de CAD e principais áreas de atuação, técnicas de Processamento Digital de Imagens, algoritmos de Reconhecimento de Padrões e aplicações práticas.

10.1. Introdução

A demanda crescente dos hospitais por um diagnóstico de exames baseados em imagens de forma rápida e precisa, somada aos avanços computacionais e de processamento de

imagens, fizeram surgir novas frentes de pesquisa relacionadas ao diagnóstico médico auxiliado por computador [Marques 2001]. Diagnóstico auxiliado por computador, também conhecido pela sigla CAD (*Computer-Aided Diagnosis*) é definido como um diagnóstico realizado pelo especialista, utilizando o resultado de análises quantitativas automatizadas de imagens como auxílio para tomada de decisões diagnósticas. A finalidade do diagnóstico auxiliado por computador é melhorar a acuidade do diagnóstico, assim como a consistência da interpretação da imagem, mediante o uso da resposta do computador como referência. A ideia do CAD pode ser aplicada em todas as modalidades de obtenção de imagem, incluindo a radiografia convencional, tomografia computadorizada, ressonância magnética, ultra-sonografia e medicina nuclear.

Podem-se desenvolver sistemas CAD para todos os tipos de exame de todas as partes do corpo, incluindo, o crânio, tórax, abdome, estrutura óssea, sistema vascular e outros. O objetivo deste capítulo é apresentar os principais conceitos ligados aos sistemas CAD: tipos de CAD e principais áreas de atuação, técnicas de Processamento Digital de Imagens, algoritmos de Reconhecimento de Padrões e aplicações práticas.

10.2. Diagnóstico Auxiliado por Computador

Diagnóstico auxiliado por computador pode ser definido como um diagnóstico feito por um médico que utiliza o resultado de análises quantitativas automatizadas de imagens como uma “segunda opinião” para a tomada de decisões diagnósticas [Doi 2007]. É importante ressaltar que o computador é utilizado somente como uma ferramenta para obtenção de informação adicional, sendo o diagnóstico final sempre feito pelo especialista, o que diferencia claramente o conceito básico de CAD do conceito de “diagnóstico automatizado”, que foi um conceito proposto e estudado nas décadas de 60 e 70 [Doi 2007].

A finalidade do CAD é melhorar a acurácia do diagnóstico, assim como a consistência da interpretação da imagem, mediante o uso da resposta do computador como referência. A resposta do computador pode ser útil, uma vez que o diagnóstico do especialista é baseado em avaliação subjetiva, estando sujeito a variações intra e interpessoais, bem como perda de informação devido à baixa qualidade da imagem, sobreposição de estruturas, fadiga visual ou distração. Além disso, foi demonstrado que uma dupla leitura (por dois especialistas) pode aumentar a sensibilidade do diagnóstico [Thurfjell et al. 1994]. A proposta do CAD é funcionar como um segundo especialista.

Basicamente, existem dois tipos de aplicações de sistemas CAD. Um é o auxílio à detecção de lesões, a partir da localização de padrões anormais através da varredura da imagem pelo computador (por exemplo, agrupamentos de microcalcificações em imagens mamográficas ou nódulos pulmonares em imagens de tórax). O outro é o auxílio ao diagnóstico, através da quantificação de características da imagem e sua classificação como correspondendo a padrões normais ou anormais (por exemplo, a associação da quantidade e forma das microcalcificações presentes em um agrupamento com a malignidade ou não do tumor, ou a associação da textura dos pulmões com lesões intersticiais em imagens de tórax).

Em geral, os sistemas CAD utilizam-se de técnicas provenientes de duas áreas do conhecimento: visão computacional, que envolve o processamento de imagem para realce, segmentação e extração de atributos, e inteligência artificial, que inclui métodos

para seleção de atributos e reconhecimento de padrões.

10.2.1. Auxílio à Detecção

A detecção automatizada de lesões envolve a localização pelo computador de regiões contendo padrões suspeitos, porém com a classificação da lesão sendo feita exclusivamente pelo especialista. Sistemas para auxílio à detecção têm sido desenvolvidos, principalmente, para imagens radiológicas de tórax e de mama.

10.2.2. Auxílio ao Diagnóstico

Uma vez que um padrão suspeito foi detectado, cabe ao especialista decidir o encaminhamento do caso, ou seja, se é necessária a realização de algum outro exame ou de uma biópsia, por exemplo. Ou então, se um simples acompanhamento é suficiente e, neste caso, qual deve ser o intervalo até o próximo exame.

Sistemas de análise computadorizada estão sendo desenvolvidos para auxiliar a distinção entre lesões e não-lesões e aumentar a sensibilidade e especificidade do diagnóstico. Estes sistemas utilizam atributos extraídos e quantificados de forma automatizada e também por especialistas.

A vantagem da extração automatizada é a objetividade e reprodutibilidade da medida dos atributos escolhidos. Por outro lado, os especialistas utilizam uma grande quantidade de atributos, os quais são extraídos e interpretados simultânea e instantaneamente.

No caso de exames relacionados a câncer, um dos objetivos dos sistemas de auxílio à classificação é a redução do número de casos benignos encaminhados para biópsia. Porém, como o “custo” da perda de uma lesão maligna é muito maior que o de uma classificação errônea de um caso benigno, os sistemas de auxílio ao diagnóstico devem ser desenvolvidos com o propósito de aumentar a especificidade, porém sem reduzir a sensibilidade.

10.2.3. Estratégias dos Sistemas CAD

Em [Hong Shao 2004] são propostas estratégias para diagnóstico de imagens, particularmente, aplicados à análise de patologias nos tecidos do cérebro (edema, tumor, etc.), tais como:

1. Análise comparativa de imagens do mesmo paciente, obtidas pelo mesmo equipamento, com os mesmos parâmetros de escaneamento, mas em diferentes instantes de tempo
2. Análise comparativa de imagens do mesmo paciente, obtidas pelo mesmo equipamento, no mesmo instante, mas com parâmetros de escaneamento diferentes. Este tipo de análise é denominado análise multi-espectral.
3. Análise comparativa de imagens do mesmo paciente, mas obtidas através de diferentes tecnologias de escaneamento, tais como, tomografia computadorizada, ressonância magnética, PET e SPECT.
4. Análise comparativa da imagem do paciente com um padrão obtido de pessoas sau-

dáveis, denominado atlas anatômico. Na prática, esta técnica não mostrou muita eficiência dado sua complexidade e dificuldade de estabelecer um padrão anatômico.

Ainda como técnica de análise comparativa, pode-se acrescentar a técnica de comparação de duas imagens do mesmo paciente, mas obtida em diferentes partes do corpo. Essa metodologia desenvolvida para detecção de nódulos em mamogramas, por exemplo, a qual é baseada na simetria de arquitetura entre as mamas esquerda e direita, com as assimetrias indicando possíveis nódulos, conforme descrito em [F.F. et al. 1991].

10.3. Conhecimentos Envolvidos

Em geral, os sistemas CAD utilizam-se de técnicas provenientes de duas áreas do conhecimento, visando a extração e quantificação de atributos de uma imagem em formato digital. Neste capítulo direcionamos este estudo com base nas seguintes técnicas:

1. Processamento de Imagens: envolve o processamento de imagem para realce, segmentação e extração de atributos.
2. Reconhecimento de Padrões: inclui métodos para seleção de atributos, estatística e reconhecimento de padrões.

Utilizam-se técnicas de processamento de imagens para realce e segmentação das lesões, conforme o tipo do exame. Por exemplo, utilizam-se propriedades de descontinuidade dos níveis de cinza, detecção de contorno, bordas ou segmentação para separação de regiões que apresentem determinada característica. Após o realce e segmentação, segue o processamento envolvendo a quantificação de atributos da imagem, como, tamanho, contraste e forma dos seus objetos constituintes.

A descrição dos atributos da imagem relaciona as características reconhecidas subjetivamente pelos especialistas. De um modo geral, os atributos são quantificados a partir de propriedades métricas, topológicas e de textura dos objetos.

Após a extração e quantificação dos atributos, utiliza-se o reconhecimento de padrões para distinção entre padrões normais e anormais. Esta área do conhecimento abrange técnicas de distribuições de probabilidade de classe, técnicas de análise de discriminante, métodos estatísticos e redes neurais.

10.3.1. Processamento Digital de Imagens

O processamento de imagens abrange uma ampla escala de *software*, *hardware* e fundamentos teóricos [Gonzalez e Woods 2007]. Entre estes fundamentos, discutiremos nesta seção técnicas importantes na caracterização e representação das informações relevantes de uma imagem ao usuário de sistema CAD.

Esta subseção descreve algumas funções de processamento digital de imagens abordadas em sistema CAD. Inicialmente discute-se sobre o processo de aquisição de imagens. A subseção 10.3.1.2 descreve estratégias para adequar a imagem ao processamento em que ela será submetida. Técnicas para separar as regiões de interesse de uma

imagem são apresentadas na subseção 10.3.1.3. A subseção 10.3.1.4 expõe métodos para representação e descrição de formas.

10.3.1.1. Aquisição de Imagens

Considera-se aquisição de uma imagem o processo de conversão de uma cena real tridimensional em uma imagem digital produzida por um ou vários sensores. A aquisição de imagens requer um sensor para imageamento e capacidade de digitalizar o sinal produzido pelo sensor [Burger e Burge 2009]. Este pode ser caracterizado por um dispositivo físico que seja sensível a uma banda do espectro eletromagnético (como raios-X, ultravioleta, visível ou banda infravermelha), gerando um sinal elétrico proporcional ao nível de energia recebida. Por fim, converte-se a saída elétrica deste sensor para a forma digital num outro dispositivo, conhecido como digitalizador [Azevedo et al. 2007]. Dependendo do tipo do sensor, o resultado pode variar entre uma imagem bidimensional, uma cena tridimensional ou ainda uma sequência de imagens.

$$f(x,y) \approx \begin{bmatrix} f(0,0) & f(0,1) & \cdots & f(0,M-1) \\ f(1,0) & f(1,1) & \cdots & f(1,M-1) \\ \vdots & & & \vdots \\ f(N-1,0) & f(N-1,1) & \cdots & f(N-1,M-1) \end{bmatrix} \quad (1)$$

O termo imagem refere-se a uma função de intensidade luminosa bidimensional, denotada por $f(x,y)$. O valor ou amplitude de f nas coordenadas espaciais (x,y) dá a intensidade (brilho) da imagem naquele ponto. Para adequar-se a um sistema computacional, a função $f(x,y)$ precisa ser digitalizada tanto espacialmente quanto na amplitude. A digitalização de suas coordenadas espaciais é denominada amostragem da imagem e a digitalização da amplitude é chamada quantização em níveis de cinza. Supondo que uma imagem contínua $f(x,y)$ é aproximada por amostras igualmente espaçadas, arranjadas na forma de uma matriz $N \times M$ (Equação (1)) com cada elemento apresentando uma quantidade discreta. O lado direito desta equação traz a representação de uma imagem digital [Gomes e Velho 1994]. Cada elemento desta matriz é definido como um elemento da imagem ou *pixel* (abreviação do termo *picture element*, elemento da figura) [Azevedo et al. 2007]. Os valores dos *pixels* podem indicar, além da intensidade da luz, uma ou várias faixas de cor (gerando imagens em tons de cinza ou coloridas), mas também podem indicar valores físicos como profundidade e absorção ou reflexão das ondas eletromagnéticas.

Considerando a Equação (1) uma aproximação de uma imagem contínua, deve-se avaliar quantas amostras e níveis de cinza são suficientes para esta aproximação. A resolução desta imagem dependerá destes dois parâmetros. Maiores valores nestes índices indicam maior aproximação da matriz digitalizada à imagem original. Essa relação pode ser observada na Figura 10.1(b), que se apresenta diferente da Figura 10.1(a), após ser reamostrada no plano digital e com uma limitação nos níveis de cinza visíveis. Diferentes equipamentos podem ser utilizados para a aquisição de imagens, como câmeras CCD (do inglês *Charge-Coupled Device*, dispositivo de carga acoplada para vídeo e fotografia), sistema infravermelho, aparelhos para radiologia que utilizam sinais recebidos de raio-X,

tomografia computadorizada, medicina nuclear, ultra-sonografia e ressonância magnética nuclear.




Figura 10.1. Efeito da discretização da imagem: exemplo de (a) imagem contínua e (b) resultado da amostragem e quantização da mesma. Adaptado de Gonzalez & Woods (2007).

Para a realização de testes em um sistema CAD, é possível processar imagens armazenadas em repositórios disponíveis na *web*. Alguns destes podem ser abertos e oferecem a caracterização das imagens oferecidas. Como exemplo, num sistema CAD que atue com imagens de mamografia, há bases de dados que disponibilizam as imagens de mamografia com a indicação de quais destas correspondem a exames de pacientes doentes ou não.

10.3.1.2. Técnicas de Pré-Processamento

Em muitas aplicações, os métodos de processamento de imagens requerem ajustes na imagem de entrada para extrair suas informações de maneira satisfatória. Somente após estes ajustes, a imagem é processada e se torna apta para análise na aplicação. Essa etapa de pré-processamento pode ser definida por diversas técnicas como: remapeamento (para assegurar o sistema de coordenadas), redução de ruídos (para assegurar que as informações são verdadeiras) e aumento de contraste (para assegurar que as informações relevantes serão detectadas), entre outras.


Algumas distorções estão presentes em uma imagem e afetam a percepção da real informação presente na mesma. Uma distorção crítica é a presença de ruído na imagem. Esse fator implica em nova informação na imagem, diferente do seu comportamento real. Normalmente, os ruídos são definidos por uma distribuição estatística, como o modelo gaussiano, *speckle* e de *poisson* [Marques et al. 2004, Gonzalez e Woods 2007].

Para eliminação do ruído em uma imagem, faz-se necessário aplicar técnicas de realce com processamento por máscara. Isso consiste em definir uma nova imagem, de dimensão menor do que aquela a ser processada, e aplicar valores a cada um dos elementos dessa nova imagem que será chamada de máscara (ou janela). Essa janela percorre toda a imagem, e faz uma avaliação *pixel a pixel* de acordo com sua dimensão. A distribuição de valores nessa máscara define o tipo de filtragem a ser executada: passa-alta (preserva as informações de alta-frequência, como bordas e ruído, e elimina as demais) ou passa-baixa (preserva as informações de baixa-frequência, como regiões homogêneas



Figura 10.2. Exemplos de filtragem. Ao lado esquerdo estão dispostas imagens com resultados de tentativa de remoção de ruído com filtro passa-baixa. No lado direito, um exemplo de detecção de borda com um filtro passa-alta.

em suas intensidades, e elimina o restante). Na Figura 10.2 estão dispostos exemplos de filtros passa-baixa e passa-alta com suas respectivas máscaras. Cada máscara apresenta um efeito diferenciado no resultado da filtragem [Paula 2009, Velho et al. 2009].



(a) Imagem original.

(b) Fatiamento da imagem em oito pseudo-cores.

Figura 10.3. Exemplo de realce por uso de fatiamento de intensidades. Adaptado de Gonzalez & Woods (2007).

Existem ainda outras técnicas que não realizam um processamento especial como ocorre na filtragem, mas que permitem ajustar a imagem em seu pré-processamento. Uma dessas técnicas é o fatiamento de intensidades, que permite criar uma nova codificação de cores na imagem para melhor interpretá-la. Esse método é muito utilizado em aplicações médicas e meteorológicas, em que as intensidades dos *pixels* são categorizadas em intervalos específicos. Cada interstício de intensidade assume uma cor na nova representação da imagem. Um exemplo desse processo está na Figura 10.3 que apresenta uma imagem monocromática do Fantasma de tireóide de Picker [Gonzalez e Woods 2007]. Com o fatiamento de intensidades, a imagem é redefinida com oito intervalos de intensidades onde cada região assume uma pseudo-cor específica.

Há ainda técnicas de pré-processamento identificadas com a avaliação da estatística inerente à imagem para melhorar a sua aparência. Um exemplo muito prático consiste na equalização do histograma da imagem. O histograma de uma imagem digital corresponde a uma estimativa da probabilidade de ocorrência dos seus níveis de cinza. Este desenvolvimento produz uma imagem cujos níveis de cinza possuem uma densidade uniforme. Isso implica num aumento da escala dinâmica dos *pixels*, o que pode acarretar em um efeito relevante na visualização da imagem [Gonzalez e Woods 2007]. A Figura 10.4 exibe amostras em condições diferentes de contraste e suas imagens de resultado após a equalização dos seus respectivos histogramas. É possível perceber a mudança no contraste destas imagens.

10.3.1.3. Segmentação

O processo de segmentação visa à separação dos *pixels* pertencentes a cada objeto presente na imagem. Isso implica em separação de regiões dentro da imagem analisada.




Figura 10.4. Realce na imagem através da equalização do histograma. Cada coluna apresenta quatro diferentes amostras de imagens: escura, clara, com baixo contraste e com alto contraste. Analisando cada amostra a partir da imagem de topo até a de base, tem-se: imagem original, histograma, efeito do realce e histograma equalizado.

Exemplos desse processo incluem a seleção de regiões de interesse específicos e segmentação de uma ou mais regiões que contêm um objeto de interesse [Castleman 1996].

A importância do realce em uma imagem é percebida no momento em que o processo de segmentação é efetuado. O método de segmentação precisa que a imagem tratada esteja livre de distorções para atingir seu objetivo. A técnica mais simples é a limiarização (ver Figura 10.5), que consiste em definir um valor de intensidade como limiar e modificar todos os *pixels* da imagem com base no mesmo. Isso ocorre a partir de um comparativo, no qual o *pixel* com intensidade menor ou igual ao limiar recebe valor 0 (zero). Em caso contrário, a intensidade do *pixel* considerado receberá valor igual a 255. Portanto, duas regiões são separadas na imagem.




Figura 10.5. Exemplo de segmentação por limiarização: (a) imagem original e (b) seu respectivo histograma. Aplica-se o processo a partir do valor $r = 125$ aplicado na (c) função de limiarização $s = T(r)$ e obtém-se o (d) resultado da segmentação. Adaptado de Gonzalez & Woods (2007).

10.3.1.4. Representação e Descrição de Formas

Com os agrupamentos obtidos a partir da segmentação da imagem, torna-se possível representar e descrever as regiões identificadas. Inicialmente, a representação de uma região pode ser caracterizada como baseada no contorno (fronteira), ou em termos de suas características internas (*pixels* que compõem a região) [Paula et al. 2011]. Os dados da região são então transformados em uma nova representação de acordo com a abordagem escolhida e depois a mesma região é descrita. Esta descrição consiste em reconhecer características da região da imagem que possam diferenciá-la de outras regiões ou ainda de outras imagens. Sendo assim, características matemáticas da imagem são extraídas em vários níveis de complexidade. Exemplos básicos incluem detecção de bordas, cantos ou *pixels* destacados na imagem [Costa e Cesar 2009].

Normalmente uma representação externa é escolhida quando as características da forma são importantes. Por outro lado, se a atenção da aplicação está na cor e textura, utiliza-se a representação interna. De toda maneira, as características selecionadas para o descritor da forma devem ser afetadas o mínimo possível por variações de mudança de escala, rotação e translação da imagem. A representação da forma geralmente compacta os dados em esquemas consideravelmente mais úteis no cálculo de descritores. A Figura 10.6 dispõe de duas assinaturas de formas. A primeira é uma representação funcional unidi-




Figura 10.6. Exemplo de realce por uso de fatiamento de intensidades. Adaptado de Gonzalez & Woods (2007).

mensional de uma fronteira e pode ser gerada por maneiras distintas [Costa e Cesar 2009]. No exemplo apresentado, tem-se dois gráficos da distância da fronteira ao centróide em função do ângulo para as formas de círculo e quadrado. Obtém-se assim, uma redução na representação da forma a uma função unidimensional que se apresenta mais simples que a imagem original.

Tabela 10.1. Exemplo de descrição de regiões. Na imagem à esquerda, imagem do mapa da América separada em regiões. Proporção de luzes utilizado como descritor, à direita. Adaptado de Gonzalez & Woods (2007).

Região (da esq. p/ direita)	Proporção de luzes por região ao total
1	0.204
2	0.640
3	0.049
4	0.107

Para gerar uma descrição de uma região é importante avaliar quais os descritores que captam as diferenças essenciais entre os objetos ou classes de objetos. Diferentes informações da imagem podem ser tratadas como descritores. Exemplos simples são área e perímetro. A área de uma região é definida pelo número de *pixels* contidos dentro de sua fronteira. O perímetro é o tamanho dessa fronteira. A Tabela 10.1 traz um exemplo de descrição de uma representação de região. Utilizaram-se as informações de intensidade dos *pixels* para identificar quantos detalhes de luzes podem ser reconhecidos nas regiões da imagem apresentada (lado esquerdo da tabela). Um descritor foi definido a partir da contagem de pontos que representam luz em cada região e foi possível diferenciá-los entre si.

10.3.2. Reconhecimento de Padrões

Conforme [Jain et al. 2000], o estudo de reconhecimento de padrões teve início depois da década de 60, quando foi desenvolvida a maior parte da teoria estatística moderna. Com o advento dos computadores, cresceu ainda mais a demanda por aplicações de reconhecimento de padrões. Atualmente, o reconhecimento de padrões é utilizado em aplicações envolvendo visão computacional, reconhecimento de caracteres, diagnóstico auxiliado por computador, reconhecimento da fala, reconhecimento de impressão digital, autentificação de assinaturas, etc.

Existem muitos tipos de padrões, por exemplo: padrões visuais, padrões temporais, padrões lógicos. Pode-se dizer que tarefas de reconhecimento de padrões são encontradas em toda atividade inteligente. Deste modo, não há uma só teoria de reconhecimento de padrões que seja capaz de cobrir a grande quantidade de problemas possíveis. Porém, existem algumas abordagens clássicas, incluindo: Reconhecimento Estatístico de Padrões, Reconhecimento de Padrões usando Lógica Fuzzy, Reconhecimento de Padrões usando Redes Neurais, Reconhecimento Sintático (ou Estrutural de Padrões) e Reconhecimento de Padrões Baseado em Conhecimento

A abordagem mais amplamente utilizada é a estatística. Dessa forma, os problemas de reconhecimento de padrões são tratados como problemas de classificação. O que consiste em associar um conjunto de atributos (características) de entrada a uma determinada categoria ou classe (saída). Em outras palavras, pode-se dizer que reconhecer padrões equivale a classificar determinado objeto físico ou situação como pertencente ou não a um certo número de categorias previamente estabelecidas. Há dois métodos de classificação:

1. Supervisionada: em que uma amostra de dados é previamente conhecida, representada por um conjunto de padrões e suas respectivas classes. Neste método, a regra de decisão pode ser representada por uma função densidade probabilidade, previamente conhecida (parametrizada) ou não (não parametrizada), ou por uma função de classificação.
2. Não-Supervisionada: em que não há associação dos padrões e suas respectivas classes. O desafio será encontrar agrupamentos de dados e identificar suas respectivas classes. Este método também é conhecido por clustering.

10.3.3. Atributos

Uma forma de classificar um objeto ou evento é medindo algumas de suas características ou algumas de suas propriedades mais representativas (*features*). Por exemplo, para classificar uma letra impressa deve ser útil conhecer sua área e perímetro.

A especificação das características necessárias para uma boa classificação depende das características do problema que se deseja resolver. Especificar esses atributos é uma tarefa árdua que necessita de um elevado grau de experimentação com diferentes combinações de características.

Com frequência, um determinado objeto que se deseja classificar é representado por um conjunto fixo de d atributos. Neste caso, é útil pensar no conjunto de atributos

como um *vetor de atributos* x , também chamado simplesmente de *padrão*, tal que x é um vetor coluna de dimensão d .

10.3.4. Exemplos de Classificadores

O objetivo de um classificador é dividir o espaço de atributos em regiões de decisão. Dessa forma, os vetores de atributos que estiverem contidos na mesma região de decisão compartilham a mesma classe.

10.3.4.1. Vizinho mais Próximo

O algoritmo de classificação baseado no vizinho mais próximo (*Nearest Neighbor* - NN) é uma técnica amplamente empregada para reconhecer padrões. O centro de seu funcionamento está em descobrir o vizinho mais próximo de uma dada instância. O NN é considerado um dos mais simples algoritmos de aprendizagem de máquina. Ele funciona bem quando a distância entre as médias é grande quando comparada com a dispersão de cada classe em relação a sua média. Um resumo do funcionamento do classificador é mostrado no Algoritmo 1.

Algoritmo 1 Algoritmo Vizinho Mais Próximo (*Nearest Neighbor, NN*).

- 1 Armazenar os exemplos em uma tabela.
- 2 Seja x_{novo} um vetor cuja classe é desconhecida, ou seja:

$$Classe(x_{novo}) = ?$$

- 3 Procurar na tabela o vetor armazenado mais próximo de x_{novo} .
- 4 Chamar de x_{prox} o vetor armazenado mais próximo de x_{novo} .
- 5 Atribuir a x_{novo} a mesma classe de x_{prox} , ou seja:

$$Classe(x_{novo}) = Classe(x_{prox})$$

- 6 Se a classificação for correta incluir x_{novo} na tabela.
-

10.3.4.2. Distância Mínima aos Centróides (DMC)

O algoritmo Distância Mínima aos Centróides funciona de forma similar ao do Vizinho Mais Próximo. No entanto, cada classe passa a ter um único vetor que a representa, chamado de centróide. Dessa forma, não há necessidade de armazenar todos os exemplos de uma classe o que nos leva a uma economia de memória. O centróide de uma classe é o seu vetor médio; ou seja, a média dos exemplos daquela classe. Assim, pode-se dizer que o centróide de uma classe é um modelo que representa aquela classe. Um resumo do funcionamento do classificador é mostrado no Algoritmo 2.

Algoritmo 2 Algoritmo Distância Mínima aos Centróides (*DMC*).

1 Armazenar apenas os centróides das classes em uma tabela.

2 Seja x_{novo} um vetor cuja classe é desconhecida, ou seja:

$$Classe(x_{novo}) = ?$$

3 Procurar na tabela o centróide mais próximo de x_{novo} .

4 Chamar de C_j o centróide mais próximo de x_{novo} .

5 Atribuir a x_{novo} a mesma classe de centróide mais próximo, ou seja:

$$Classe(x_{novo}) = Classe(C_j)$$

6 Se a classificação for correta, usar x_{novo} para recalculr C_j .

10.3.4.3. Rede Neural Artificial

Uma rede neural artificial é composta por várias unidades de processamento, cujo funcionamento é paralelo e, por vezes, distribuído. Essas unidades, geralmente são conectadas por canais de comunicação que estão associados a determinado peso, que é denominado “peso sináptico”. As unidades fazem operações apenas sobre seus dados locais, que são entradas recebidas pelas suas conexões. O comportamento inteligente de uma rede neural artificial advém das interações entre as unidades de processamento da rede. O modelo de um neurônio artificial pode ser visto na Figura 10.3.4.3.

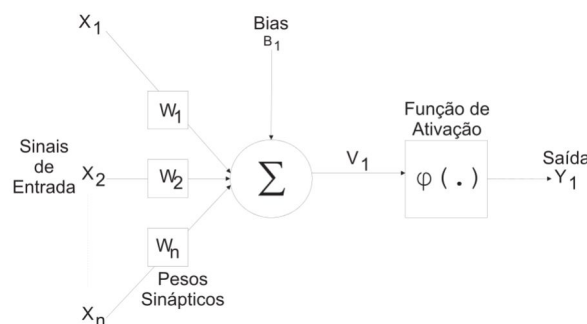


Figura 10.7. Modelo de Neurônio Artificial baseado em Haykin (2001).

O comportamento das conexões entre os neurônios é simulado por meio de seus pesos sinápticos. Os valores de tais pesos podem ser negativos ou positivos, dependendo das conexões serem inibitórias ou excitatórias. O efeito de um sinal proveniente de um outro neurônio é determinado pela multiplicação do valor (intensidade) do sinal recebido pelo peso da conexão correspondente ($x_i \cdot p_i$). É efetuada a soma dos valores $x_i \cdot p_i$ de todas as conexões, e o valor resultante é enviado para a função de ativação, que define a saída (y) do neurônio. Combinando diversos neurônios, forma-se uma rede neural artifi-

cial. De uma forma simplificada, uma rede neural artificial pode ser vista como um grafo onde os nós são os neurônios e as ligações fazem a função das sinapses.

A rede neural artificial é um sistema de neurônios ligados por conexões sinápticas e dividido em neurônios de entrada, que recebem estímulos do meio externo, neurônios internos ou hidden (ocultos) e neurônios de saída, que se comunicam com o exterior. A forma de arranjar perceptrons em camadas é denominado Multilayer Perceptron (MLP). O MLP foi concebido para resolver problemas mais complexos, os quais não poderiam ser resolvidos pelo modelo de neurônio básico. Para isto são necessárias mais conexões, os quais só existem em uma rede de perceptrons dispostos em camadas. Na Camada escondida, camada oculta ou camada intermediária, como também é conhecida os neurônios são denominados escondidos porque eles não tem acesso direto a saída da rede MLP, onde os erros de aproximação são calculados.

10.4. Aplicações

Nesta seção apresentamos duas aplicações do processamento digital de imagens no diagnóstico auxiliado por computador. A primeira é a identificação de estruturas da retina. A identificação dessas estruturas auxiliam no diagnósticos de várias doenças como a retinopatia diabética e o edema macular. A segunda envolve o reconhecimento e a análise de posturas humanas. Estas aplicações utilizam imagens obtidas em ambientes clínicos para o tratamento de desvios posturais.

10.4.1. Identificação de Estruturas da Retina

A retina constitui a membrana mais interna do olho, situando-se na parede posterior. Quando o olho focaliza uma cena, a imagem correspondente é projetada sobre a retina, na qual estão distribuídos dois tipos de receptores de luz: os cones e os bastonetes. Os cones são responsáveis pela chamada visão fotóptica ou de luz clara. Já os bastonetes são úteis para detectar detalhes.

Entre os padrões presentes no fundo do olho, encontra-se a rede de veias da retina, que pode revelar uma série de doenças ligadas às variações ocorridas no globo ocular. O tratamento para essas doenças se torna mais eficaz quanto mais cedo elas são descobertas, e isso se dá através de exames oftalmológicos periódicos [Hajer et al. 2006].

Imagens digitais de retina podem prover informações sobre mudanças patológicas causadas por doenças oculares locais e sinais recentes de doenças sistêmicas como a hipertensão, a arterioesclerose e o *Diabetes Mellitus* (DM). A análise e interpretação desse tipo de imagem vem se tornando um auxílio importante e necessário no diagnóstico dessas doenças.

10.4.1.1. Disco Óptico

Nos sistemas CAD para detecção de doenças oculares usando imagens coloridas de retina, a localização automática do disco óptico (DO) e o cálculo do seu contorno são passos fundamentais, antes de qualquer análise. A segmentação do disco óptico é um passo importante no pré-processamento de vários algoritmos desenvolvidos para a extração au-

tomática das estruturas anatômicas e para a detecção de lesões na retina. Além disso, esse processo também atua como um indicador de patologias oftalmológicas, como o glaucoma, que é uma das causas mais comuns de cegueira [Xu et al. 2007].

A identificação do disco óptico é também essencial na localização dos vasos, os quais, fornecem uma referência que pode facilitar o processo da detecção da posição de outras estruturas do fundo ocular e de lesões. Além disso, é essencial a remoção prévia do disco óptico nos algoritmos de detecção de exudatos¹, dada a semelhança entre ambos em termos de cor, brilho e contraste [Gagnon et al. 2001].

Basicamente, podemos classificar os algoritmos de detecção do disco óptico em duas classes: abordagem geográfica e abordagem baseada em características locais. Os algoritmos que usam a abordagem geográfica baseiam-se na informação fornecida pela estrutura dos vasos, isto é, no fato de todos os vasos da retina terem origem no disco óptico. Embora a detecção dos vasos seja uma operação complexa, a sua relação geométrica com o disco óptico pode ser utilizada para identificar a localização deste. Uma vez conhecida a localização do disco óptico, este é detectado como ponto inicial para determinar o respectivo contorno.

Os algoritmos baseados nas características locais levam em consideração, principalmente, a sua forma redonda e brilho relativamente elevado, quando comparado com o resto da imagem. Em [Veras et al. 2011] os principais algoritmos de detecção do disco óptico foram avaliados e o método proposto por [Hoover e Goldbaum 2003].

A Figura 10.8 apresenta três exemplos de imagens de retina. Na Figura 10.8(a) o contorno do disco óptico é bem definido o que torna mais fácil sua detecção. Já na Figura 10.8(b), o plano de fundo é bastante heterogêneo e a região central possui intensidade de cor bem próxima a da região do disco óptico. A Figura 10.8(c) apresenta uma imagem onde não é possível a identificação do disco óptico.




Figura 10.8. Exemplos de imagens da base STARE

10.4.1.2. Mácula

A detecção da mácula é uma tarefa relevante no processamento de imagens de fundo de olho (retina) e é utilizada em várias aplicações. Ela é considerada um importante

¹Produto seroso, purulento, resultante de processo inflamatório.

marcador fisiológico na análise de imagens da retina e é usada na localização de outras estruturas da retina como o DO, microvasos e exsudatos [Winder et al. 2009].

A mácula é um ponto ovalado de cor amarela junto ao centro da retina do olho humano e tem um diâmetro de cerca 1,5 mm. A região da mácula possui uma sub-região chamada fóvea, que localiza-se no centro da mácula e possui uma área menor que a mácula. É nesta última que encontramos uma maior quantidade de cones (células responsáveis pela percepção de cores). A mácula contém uma pigmentação mais escura e sua localização é aproximadamente o centro da retina. De acordo com [Tobin et al. 2007], o raio da mácula é igual ao dobro do raio do DO e a fóvea mede metade do raio do DO.

Uma detecção precisa da mácula é um importante primeiro parâmetro para determinar patologias como a Degeneração e o Edema Macular. O diagnóstico de Edema Macular, por exemplo, é realizado levando-se em consideração a quantidade de exsudatos e suas localizações com relação à região da mácula.

O algoritmo de detecção da mácula, na maioria dos trabalhos publicados, determina uma Região de Interesse (ROI - *Region of Interest*) baseado na localização do DO, como mostra a Figura 10.9. Após a determinação da ROI, algoritmos específicos são executados para definir o centro da mácula. Uma descrição e avaliação de vários métodos de detecção da mácula pode ser encontrada em [Silva et al. 2011].




Figura 10.9. Ilustração da ROI.

10.4.1.3. Microaneurismas e Exsudatos

A Retinopatia Diabética (RD) é uma doença assintomática nas fases iniciais, o que dificulta a sua detecção. Ela ocorre como resultado das alterações vasculares na retina causando inchaços de capilares, conhecidos como microaneurismas (MA). Estes podem romper-se, e, eventualmente, se tornarem uma fonte de extravasamento de plasma causando o espessamento da retina, ou edema, se ocorrem na região macular, e pode causar perda de visão de alta qualidade [Fleming et al. 2007]. O espessamento da retina não é facilmente visível nas fotografias do fundo do olho, portanto, regiões de depósitos de gordura, conhecidas como exsudatos, são usadas como marcadores. Exsudatos geralmente formam aglomerados, e podem ser distribuídos em toda a retina ou podem aparecer em um anel em torno de um ponto central do vazamento.

A Organização Mundial de Saúde estima que 135 milhões de pessoas tenham diabetes no mundo e que este número de diabéticos deverá aumentar para 300 milhões até o ano de 2025 [Amos et al. 1997]. A RD afeta uma parte considerável da população, o que justifica trabalhos avançados na área de detecção de doenças por imagens. Desenvolvendo técnicas simples, e com um custo-benefício baixo, seria possível a detecção da RD em sua fase inicial. Estudos comprovam que quanto mais cedo for detectada a RD mais chances o paciente terá de não desenvolver a doença em seu grau mais elevado.

Microaneurismas se apresentam como os primeiros padrões patológicos que surgem na retina humana, em portadores de Retinopatia Diabética, e constituem uma evidência direta de isquemia, uma vez que cada microaneurisma representa a oclusão de ao menos um vaso capilar. Portanto, existe uma relação entre o número de microaneurismas e o agravamento da doença em pacientes portadores do *Diabetes Mellitus*, ou simplesmente Diabetes, como é popularmente conhecida. Sistemas automáticos de detecção de microaneurismas vêm sendo bastante utilizados em substituição aos sistemas manuais de contagem, uma vez que estes consomem muito tempo e são mais sujeitos a erros. Alguns dos principais métodos são [Fleming et al. 2007, Walter et al. 2002, Martins et al. 2008].

Com o avanço da Retinopatia Diabética aparecem os exsudatos. Quando isso ocorre a doença já se encontra em um nível grave, mas ainda pode ser controlada. A Figura 10.10(a) é um exemplo de retina saudável. Já na Figura 10.10(b) existe alguns exsudatos bem pequenos na região central da retina. A Figura 10.10(c) apresenta vários exsudatos e hemorragias.




Figura 10.10. Exemplos de imagens com e sem exsudatos

Basicamente existem três técnicas diferentes de detecção exsudatos em imagens da retina. A primeira funciona através da definição de um limiar como foi observado em [Kavitha e Shenbaga 2005]. Essa técnica não possui um bom desempenho, pois como o disco óptico possui propriedades de cor semelhante a dos exsudatos muitas vezes ele é marcado incorretamente como exsudato. Outro problema dessa técnica ocorre quando aparecem regiões mais claras na imagem, elas também podem ser marcadas como exsudatos.

A segunda técnica utiliza agrupamento de pixels, como em [Sopharak et al. 2010]. Essa é a principal técnica usada para a detecção dos exsudatos, porém isoladamente ela não produz resultados satisfatórios, pois muitas vezes é necessário o uso de classificação ou morfologia matemática para eliminar falsos candidatos [de Araújo et al. 2011].

A terceira técnica faz uso de operações de morfologia matemática, como foi ob-

servado em [Walter et al. 2002]. Assim como no agrupamento, essa técnica não produz bons resultados isoladamente. Geralmente ela é usada para remover falsos candidatos ou pixels isolados.

10.4.1.4. Microvasos

Imagens de fundo de olho fornecem informações sobre as mudanças patológicas causadas por doenças oculares. Uma característica importante para o diagnóstico de doenças como diabetes, arteriosclerose e hipertensão é a aparência dos vasos sanguíneos na retina [Li et al. 2006]. O desenvolvimento de uma solução computacional para a segmentação dos vasos sanguíneos permite que o médico especialista diagnostique melhor os casos de vascularidade anormal. Em outros casos, o desempenho de métodos automáticos de detecção (segmentação) de vasos auxilia no diagnóstico de outras doenças como foi apresentado em [Martins et al. 2009].

Entretanto, essa segmentação é dificultada pelos seguintes fatos [Li et al. 2006]: a largura dos vasos pode variar de muito larga a muito fina e o contraste local dos vasos não é estável. Várias abordagens para segmentação de vasos são encontradas na literatura [Zana e Klein 2001, Niemeijer et al. 2004, Soares et al. 2006].

A Figura 10.4.1.4 apresenta um exemplo de imagem de retina e o resultado de dois métodos diferentes de segmentação de vasos.




Figura 10.11. Imagem de retina com duas segmentações de vasos

10.4.2. Postura

Postura é geralmente definida como o arranjo relativo das partes do corpo. Dessa maneira, a postura correta traduz o estado de equilíbrio muscular e esquelético que protege as estruturas de suporte do corpo contra lesão ou deformidade progressiva. Independente da atitude assumida pelo paciente (agachada, ereta, deitada), estas estruturas estão trabalhando ou repousando. Os órgãos torácicos e abdominais mantêm-se em posições ideais e os músculos funcionam com mais eficiência sob tais condições. [Furlaneto et al. 2007] Consequentemente, com a má postura ocorre uma relação defeituosa entre várias partes do corpo. Isso produz uma maior tensão sobre estruturas de suporte e onde ocorre um equilíbrio menos eficiente do corpo [Ferreira et al. 2011].

Entre diversos tratamentos fisioterapêuticos existentes, a Reeducação Postural Global (RPG) é um método que atua na dor e no desconforto provocados por alterações posturais. Diferente das outras abordagens, o tratamento por RPG leva em consideração que o corpo humano é um sistema muscular integrado. Portanto, há a necessidade da observação de toda a silhueta humana independentemente da localização do desvio de postura [Ferreira et al. 2010].

A Figura 10.12 traz a caracterização da coluna vertebral, que é dividida em quatro curvaturas. Duas delas com a concavidade virada para trás (lordoses nas regiões cervical e lombar) e duas delas com a concavidade virada para a frente (cifoses nas regiões torácica e pélvica, ver Figura 10.12(a)). Em geral, as imagens para o diagnóstico são tomadas em vários planos de observação. Alguns desvios da postura podem ser observados em imagens do plano frontal do paciente, como a escoliose (Figura 10.12(b)). Imagens adquiridas em plano sagital provêm conhecimento de desvios posturais, tais como hiper-cifose dorsal, hiperlordose lombar e hiperlordose cervical. Também é possível mensurar a angulação da tíbia em relação ao pé, flexão e extensão dos joelhos e inclinação anterior e posterior da pélvis [Passarinho et al. 2006, Ferreira et al. 2011].




Figura 10.12. Caracterização da (a) coluna vertebral e suas regiões ou curvaturas (Fonte: Wikipédia). Como exemplo de desvio, a (b) escoliose que pode ser percebida no plano frontal (Fonte: Wikipédia).

Passarinho e outros autores apresentaram em [Passarinho et al. 2006] uma metodologia utilizada para avaliação de mudanças no equilíbrio postural em pacientes submetidos à RPG. Este trabalho descreve uma medida de similaridade com o intuito de obter melhor desempenho na quantificação das alterações posturais.

O procedimento se inicia com o cálculo das assinaturas das formas dos pacientes. Estas formas são obtidas de segmentações aplicadas sobre as imagens obtidas pelo fisioterapeuta. Esta assinatura traz uma nova representação da forma com uma relação entre a curvatura e a informação de ângulo, em relação ao centróide, de cada um dos pontos

do contorno da forma. A função de curvatura descreve a variância da direção assumida pelo contorno da forma [Cesar e Costa 1996]. Quanto mais ereta é a postura do paciente, sua função de curvatura correspondente alcançará menor amplitude. A Figura 10.13(a) mostra a comparação entre duas assinaturas polares de um mesmo paciente antes e depois do tratamento. O método descrito em [Passarinho et al. 2006] usa como medida de similaridade o cálculo da diferença de áreas sob as assinaturas e é inversamente proporcional à diferença da área sob as curvas das assinaturas. Esta medida, SM , é calculada através da relação: $SM = 1 - 1/S$, em que S é a diferença das áreas sob as assinaturas polares dos perfis sagitais em estudo.

Este mesmo método avaliou sua medida de similaridade em comparação com a proposta em [Bernier e Landry 2003] para um conjunto de imagens adquiridas em 22 pacientes. Cada um deles possibilita a aquisição de duas imagens para que sejam obtidas suas respectivas formas. O objetivo é demonstrar que a medida SM mostra-se mais sensível às mudanças da postura do paciente após o tratamento de RPG. Os resultados podem ser vistos na Figura 10.13(b). Os valores alcançados para essa medida significam que o paciente em questão obteve resposta mais significativa ao tratamento fisioterapêutico.

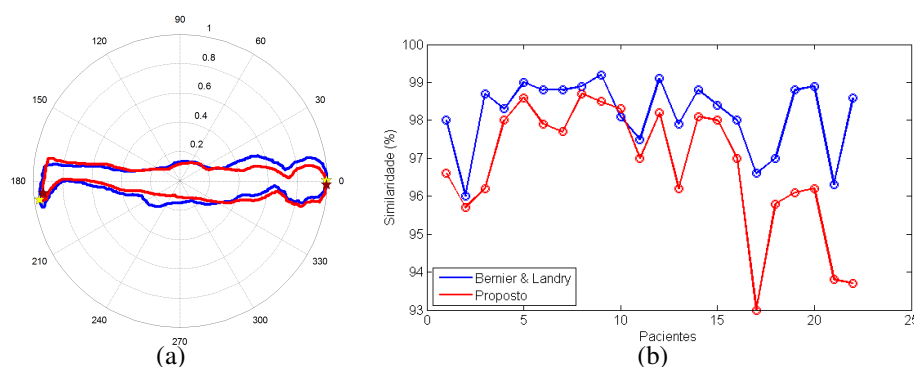


Figura 10.13. Análise de similaridade de formas: (a) há a correspondência das assinaturas polares de um paciente antes (azul) e após (vermelho) o RPG; (b) similaridade para os contornos sagitais de 22 pacientes distintos. Adaptado de [Passarinho et al. 2006].

Uma aplicação em fisioterapia utilizando o *Software* de Análise Postural (SAPO) como um sistema CAD foi proposto em [Ferreira et al. 2011]. Este possui características distintas quando comparado com outros *softwares* disponíveis, porque inclui a análise de postura global do corpo e a análise de ângulos e distâncias de maneira independente. Permite o arquivamento e comparação de fotografias para observar a evolução do paciente em determinado tratamento. O *software* também permite calibração e ajustes de foto para evitar erros de medição pequenos e aumentar a confiabilidade do método.

Ferreira e outros autores, com o auxílio deste *software* citado, realizaram uma avaliação quantitativa global do alinhamento postural de adultos jovens e saudáveis em pé, com base em pontos de vista anterior, posterior e lateral. O trabalho envolveu 122 participantes que foram submetidos a uma análise de agrupamento pela similaridade das variáveis do estudo. O sistema indica a marcação de 50 pontos anatômicos distribuídos entre as visões anterior, laterais e posterior, como o lóbulo da orelha, a linha de junção

do joelho, calcâneo, ângulo inferior da escápula, entre outros. Destes total, 16 deles eram bilaterais [Ferreira et al. 2010]. Alguns destes pontos estão visíveis na Figura 10.14. Este estudo e o *software* estão disponíveis em <http://sapo.incubadora.fapesp.br>, e inclui tutoriais científicos, bem como vários recursos de apoio à análise de fotografias.




Figura 10.14. Pontos anatômicos e ângulos avaliados nas visões laterais. Adaptado de [Ferreira et al. 2011].

Os dados foram submetidos à análise estatística descritiva. Valores quantitativos para a cabeça, membros superiores e inferiores, e alinhamento do tronco foram obtidos, juntamente com a frequência das inclinações para a esquerda e direita. As medidas utilizadas para análise da postura incluíram distâncias (em centímetros) e ângulos (em graus), extraídos da combinação de pontos anatômicos descritos em [Ferreira et al. 2011]. As variáveis da avaliação postural foram analisadas através da média, desvio padrão e valores de máximo e mínimo.

Vários valores de referência padrão de referência foram definidos neste estudo para avaliar o alinhamento postural. Membros inferiores mostraram alinhamento similar. A posição da cabeça, tronco e membros superiores e inferiores em vistas laterais são apresentados na Tabela 10.2. Medidas envolvendo o quadril, tornozelo, cifose, lordose e mostrou maior variabilidade. Existem pequenas variações no alinhamento dos segmentos corporais nas visões anterior e posterior em indivíduos saudáveis.

Os resultados do estudo demonstraram uma tendência de assimetria entre os segmentos bilaterais na visão anterior, com a pélvis, ombros e tronco mostrando ligeira inclinação para a direita. Na visão posterior, uma pequena assimetria foi observada no posicionamento da pélvis e escápula. Maiores detalhes, como identificação dos outros pontos anatômicos e o resultado detalhado da análise das variáveis da postura estão descritos em [Ferreira et al. 2011].

Tabela 10.2. Valores de média (desvio padrão), mínimo e máximo para as variáveis de postura observadas nas visões laterais, medidas em ângulos. Adaptado de [Ferreira et al. 2011].

Variáveis (°)	Média (desvio padrão)	Mínimo	Máximo
Alinhamento horizontal da cabeça	47,1 (4,8)	31,2	58,4
Alinhamento horizontal da pélvis	172,6 (4,8)	158,6	182,4
Alinhamento sagital do membro inferior	177,9 (4,8)	166,7	190,6
Ângulo de junção do quadril	149,8 (8,0)	129,7	176,2
Ângulo de junção do maléolo	86,2 (2,6)	79,9	91,6
Alinhamento vertical do torso	182,4 (2,1)	177,6	187,0
Alinhamento vertical do corpo	178,2 (0,9)	175,8	180,0
Alinhamento do membro superior	155,8 (5,1)	145,7	170,7
Alinhamento sagital do corpo	186,8 (3,6)	176,4	198,5
Ângulo da cifose torácica	55,4 (7,4)	39,3	68,2
Ângulo da lordose lombar	47,7 (15,4)	23,3	96,4

10.5. Conclusão

Este trabalho apresentou, com base em publicações científicas, que a utilização de algoritmos computacionais para auxílio à análise de imagens médicas tem-se mostrado eficiente na melhoria da detecção e classificação de lesões e/ou patologias humanas. Existem aplicações em diferentes especialidades e todas com resultados eficientes para distintas análises clínicas.

É importante ressaltar que o objetivo de um sistema CAD está na realização de uma análise automatizada como forma de auxílio, e não um substituto para o especialista da área da saúde. Portanto, é exigido que toda aplicação dessa natureza apresente um desempenho próximo ao desse especialista. O acompanhamento deste último ao processo de desenvolvimento do sistema CAD é um fator que incrementa confiança e eficiência aos resultados da aplicação.

Referências

- [Amos et al. 1997] Amos, A. F., MacCarty, D. J., e Zimmet, P. (1997). The rising global burden of diabetes and its complications: Estimates and projections to the year 2010. *Diabetic Medicine*, 14:S1–S85.
- [Azevedo et al. 2007] Azevedo, E., Conci, A., e Leta, F. R. (2007). *Computação Gráfica: Processamento de Imagens Digitais*, volume 2. Editora Campus.
- [Bernier e Landry 2003] Bernier, T. e Landry, J.-A. (2003). A new method for representing and matching shapes of natural objects. *Pattern Recognition*, 36(8):1711–1723.
- [Burger e Burge 2009] Burger, W. e Burge, M. J. (2009). *Principles of Digital Image Processing: Fundamental Techniques*. Springer.
- [Castleman 1996] Castleman, K. R. (1996). *Digital Image Processing*. Prentice Hall, Upper Saddle River.

- [Cesar e Costa 1996] Cesar, R. M. J. e Costa, L. F. (1996). Towards effective planar shape representation with multiscale digital curvature analysis based on signal processing techniques. *Pattern Recognition*, 28(9):1559–1569.
- [Costa e Cesar 2009] Costa, L. F. e Cesar, R. M. J. (2009). *Shape Analysis and Classification: Theory and Practice*. CRC Press, 2^a edição.
- [de Araújo et al. 2011] de Araújo, F., Veras, R., e Silva, R. (2011). Aperfeiçoamento da detecção de exsudatos com k-means fuzzy, detecção de vasos e morfologia matemática. In *V Escola Regional de Computação dos Estados do Ceará, Maranhão e Piauí*.
- [Doi 2007] Doi, K. (2007). Computer-aided diagnosis in medical imaging: Historical review, current status and future potential. *Computerized Medical Imaging and Graphics*, 31:198–211.
- [Ferreira et al. 2011] Ferreira, E. A., Duarte, M., Maldonado, E. P., Bersanetti, A. A., e Marques, A. P. (2011). Quantitative assessment of postural alignment in young adults based on photographs of anterior, posterior, and lateral views. *Journal of Manipulative and Physiological Therapeutics*, 34(6):371–380.
- [Ferreira et al. 2010] Ferreira, E. A. G., Duarte, M., Maldonado, E. P., Burke, T. N., e Marques, A. P. (2010). Postural assessment software (PAS/SAPO): Validation and reliability. *Clinics*, 65:675–681.
- [F.F. et al. 1991] F.F., Y., M.L., G., K., D., C.E., M., C.J., V., e R.A., S. (1991). Computerized detection of masses in digital mammograms: analysis of bilateralsubtraction images. *Med Phys*, páginas 55–63.
- [Fleming et al. 2007] Fleming, A. D., Goatman, K. A., Philip, S., Olson, J. A., e Sharp, P. F. (2007). Automatic detection of retinal anatomy to assist diabetic retinopathy screening. *Physics in Medicine and Biology*, 52(2):331–345.
- [Furlaneto et al. 2007] Furlaneto, T. S., Candotti, C. T., e Loss, J. F. (2007). Desenvolvimento de uma metodologia digital para avaliação postural no plano sagital. In *Anais do XII Congresso Brasileiro de Biomecânica*, São Pedro - SP.
- [Gagnon et al. 2001] Gagnon, L., Lalonde, M., Beaulieu, M., e Boucher, M. C. (2001). Procedure to detect anatomical structures in optical fundus images. In *Proceedings of Conference Medical Imaging*, volume 4322, páginas 1218–1225, San Diego.
- [Gomes e Velho 1994] Gomes, J. e Velho, L. (1994). *Computação Gráfica: Imagem*. IMPA.
- [Gonzalez e Woods 2007] Gonzalez, R. C. e Woods, R. E. (2007). *Digital Image Processing*. Prentice Hall, Nova York, EUA, 3^a edição.
- [Hajer et al. 2006] Hajer, J., Kamel, H., e Nouredine, E. (2006). Blood vessels segmentation in retina image using mathematical morphology and the STFT analysis. *Information and Communications Technologies*, 1:1130–1134.

- [Hong Shao 2004] Hong Shao, Wen-Cheng Cui, H. Z. (2004). Automatic analysis of brain pathology based on image content. In *IEEE International Conference on Systems*.
- [Hoover e Goldbaum 2003] Hoover, A. e Goldbaum, M. (2003). Locating the optic nerve in a retinal image using the fuzzy convergence of the blood vessels. *IEEE Transactions on Medical Imaging*, 22(8):951–958.
- [Jain et al. 2000] Jain, A. K., Duin, R. P., e Mao, J. (2000). Statistical pattern recognition: A review. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 22(1):4–37.
- [Kavitha e Shenbaga 2005] Kavitha, D. e Shenbaga, S. (2005). A cellular neurofuzzy network for contrast enhancement of fundus images with retinopathies. In *Proceeding ICS'06 Proceedings of the 10th WSEAS international conference on Systems*.
- [Li et al. 2006] Li, Q., Zhang, L., Zhang, D., e Bhattacharya, P. (2006). A new approach to automated retinal vessel segmentation using multiscale analysis. In *ICPR*, páginas 77–88. IEEE Computer Society.
- [Marques 2001] Marques, P. (2001). Diagnóstico auxiliado por computador na radiologia. *Radiol Bras*, 34(5):285–293.
- [Marques et al. 2004] Marques, R., Carvalho, E., Costa, R., e Medeiros, F. (2004). Filtering effects on sar images segmentation. *Lecture Notes in Computer Science*, 3124:1041–1046.
- [Martins et al. 2008] Martins, C., R.M.S.Veras, G.L.B.Ramalho, F.N.S.Medeiros, e Ushizima, D. M. (2008). Automatic microaneurysm detection and characterization through digital color fundus images. In *II Workshop on Computational Intelligence - SBRN*, páginas 45–50.
- [Martins et al. 2009] Martins, C. I. O., Medeiros, F. N. S., e ans F. N. Bezerra ans R. M. Cesar Jr., R. M. S. V. (2009). Evaluation of retinal vessel segmentation methods for microaneurisms detection. In *International Conference on Image Processing (ICIP)*, páginas 3365–3368.
- [Niemeijer et al. 2004] Niemeijer, M., Staal, J. J., van Ginneken, B., Loog, M., e Abramoff, M. D. (2004). Comparative study of retinal vessel segmentation methods on a new publicly available database. In Fitzpatrick, J. M. e Sonka, M., editors, *SPIE Medical Imaging*, volume 5370, páginas 648–656.
- [Passarinho et al. 2006] Passarinho, C. J. P., Cintra, L. H. S., Medeiros, F. N. S., Oliveira, I. N. S., e Paula, I. C. J. (2006). Análise de similaridade e correspondência de formas aplicada à reeducação postural global. In *Anais do XX Congresso Brasileiro de Engenharia Biomédica*, páginas 117–120, São Pedro - SP.
- [Paula 2009] Paula, I. C. J. (2009). *Livro Texto dos Minicursos - Ercemapi 2009*, capítulo Técnicas de Processamento Digital de Imagens com Java. SBC, Parnaíba - PI.

- [Paula et al. 2011] Paula, I. C. J., Medeiros, F. N. S., Bezerra, F. N., e Ushizima, D. M. (2011). Corner detection within a multiscale framework. In *Proceedings of Sibgrapi 2011 (XXIV Conference on Graphics, Patterns and Images)*, Maceió - AL. IEEE.
- [Silva et al. 2011] Silva, R., Veras, R., e de Araújo, F. (2011). Avaliação de métodos para detecção da mácula em imagens da retina. In *V Escola Regional de Computação dos Estados do Ceará, Maranhão e Piauí*.
- [Soares et al. 2006] Soares, J. V. B., Leandro, J. J. G., Cesar-Jr., R. M., Jelinek, H. F., e Cree, M. J. (2006). Retinal vessel segmentation using the 2-D Gabor wavelet and supervised classification. *IEEE Transactions on Medical Imaging*, 25:1214–1222.
- [Sopharak et al. 2010] Sopharak, A., Dailey, N., Uyyanonvara, B., Barman, S., Williamson, T., New, T. N., e Moe, A. Y. (2010). Machine learning approach to automatic exudate detection in retinal images from diabetic patients. *Journal of Modern Optics*, (57):124–135.
- [Thurfjell et al. 1994] Thurfjell, E. L., Lernevall, K. A., e Taube, A. A. (1994). Benefit of independent double reading in a population-based mammography screening program. *Radiology*, 191:241–244.
- [Tobin et al. 2007] Tobin, K. W., Chaum, E., Govindasamy, V. P., e Karnowski, T. P. (2007). Detection of anatomic structures in human retinal imagery. *IEEE Transactions on Medical Imaging*, 26(16):1729–39.
- [Velho et al. 2009] Velho, L., Frery, A., e Gomes, J. (2009). *Image Processing for Computer Graphics and Vision*. Springer, 2^a edição.
- [Veras et al. 2011] Veras, R., Araújo, F., Silva, R., Medeiros, F., e Aires, K. (2011). Comparação e avaliação de métodos de detecção do disco Óptico. In *XXXVII Conferencia Latinoamericana de Informática*.
- [Walter et al. 2002] Walter, T., Klevin, J., Massin, P., e Erginay, A. (2002). A contribution of image processing to the diagnosis of diabetic retinopathy-detection of exudates in color fundus images of the human retina. *IEEE Transactions on Medical Imaging*, 21(10):1236 – 1243.
- [Winder et al. 2009] Winder, R., Morrow, P., McRitchie, I., Bailie, J., e Hart, P. (2009). Algorithms for digital image processing in diabetic retinopathy. *Computerized Medical Imaging and Graphics*, page 15.
- [Xu et al. 2007] Xu, J., Chutatape, O., e Chew, P. (2007). Automated optic disk boundary detection by modified active contour model. *IEEE Transactions on Biomedical Engineering*, 54(3):473–482.
- [Zana e Klein 2001] Zana, F. e Klein, J. C. (2001). Segmentation of vessel-like patterns using mathematical morphology and curvature evaluation. *IEEE Transactions on Image Processing*, 10:1010–1019.